

分类号: TP393

单位代码: 10335

密 级:

学 号: 11732001

浙江大学

博士学位论文



中文论文题目: 移动网络设计与优化
——一种网络外部性的视角

英文论文题目: Mobile Network Design and Optimization
from the View of Network Externality

申请人姓名: 匿名

指导教师: 匿名

专业名称: 控制科学与工程

研究方向: 网络资源分配与优化

所在学院: 控制科学与工程学院

论文提交日期 二〇二〇年一月

移动网络设计与优化

——一种网络外部性的视角



论文作者签名: _____

指导教师签名: _____

论文评阅人 1: _____ 匿名

评阅人 2: _____ 匿名

评阅人 3: _____ 匿名

评阅人 4: _____ 匿名

评阅人 5: _____ 匿名

答辩委员会主席: _____

委员 1: _____

委员 2: _____

委员 3: _____

委员 4: _____

委员 5: _____

答辩日期: _____ 2020 年 03 月 20 日

Mobile Network Design and Optimization

from the View of Network Externality



Author's signature: _____

Supervisor's signature: _____

External Reviewers:	_____	Anonymity
	_____	Anonymity
	_____	Anonymity
	_____	Anonymity
	_____	Anonymity

Examining Committee Chairperson:

Examining Committee Members:

Date of oral defence: _____ March 20, 2020 _____

浙江大学研究生学位论文独创性声明

本人声明所呈交的学位论文是本人在导师指导下进行的研究工作及取得的研究成果。除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得 浙江大学 或其他教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示谢意。

学位论文作者签名：

签字日期： 年 月 日

学位论文版权使用授权书

本学位论文作者完全了解 浙江大学 有权保留并向国家有关部门或机构送交本论文的复印件和磁盘，允许论文被查阅和借阅。本人授权浙江大学可以将学位论文的全部或部分内 容编入有关数据库进行检索和传播，可以采用影印、缩印或扫描等复制手段保存、汇编学位论文。

(保密的学位论文在解密后适用本授权书)

学位论文作者签名：

导师签名：

签字日期： 年 月 日

签字日期： 年 月 日

摘 要

随着移动通信设备的普及,以及移动社交网络、媒体娱乐等相关领域的飞速发展,全球移动用户及数据流量近些年来一直保持着大幅增长的趋势。人们对于通信、数据服务质量上日益增高的要求不断给无线网络技术的发展带来新的挑战。除了依靠下一代 5G 技术在通信网络基础架构能力的提升外,网络数据运营商还可以通过对有限频谱资源的高效利用、对数据服务定价机制的合理设计等方式有针对性地基于需求协调供给侧的有限资源,实现网络整体性能的优化。另一方面,随着移动设备感知能力的愈发强大,移动网络俨然已经成为第三方应用对用户个人数据、城市环境数据采集的主要渠道。其一方面推动了包括移动群智感知技术在内的移动大数据技术领域的发展,而同时却也引发了人们对于个人隐私泄露的担忧。

网络外部性效应是网络经济学领域的主要研究对象之一。简单来说,其指的是一个网络中任意个体所获得的效用所受网络中其他个体的影响。这种影响可能简单取决于网络的规模大小,有时也取决于其他个体的参与程度以及个体之间的关联的强弱。近年来移动网络规模上的不断扩张使得网络外部性效应在一些移动网络的问题场景中凸显出来。具体来说,单一用户从移动网络中获取的效用可以随着网络中其余用户参与程度的增强而提高(正网络外部性)或降低(负网络外部性)。由于网络外部性效应对于网络中个体效用的显著影响,在移动网络机制设计与性能优化中对网络外部性效应进行充分考量是至关重要的。近年来,研究者在以移动网络性能优化和隐私保护为目标的机制设计方面取得了众多研究进展,然而现有工作仍然存在以下三方面的不足:1) 在解决网络性能优化的问题时缺乏从网络外部性角度的分析与讨论,缺乏对于网络外部性影响的深刻理解;2) 网络性能优化与用户隐私保护相结合的研究分析还较少,尤其缺乏针对性能-隐私权衡的刻画与考量;3) 现有激励机制设计中对于用户个体在交互中的策略性行为假设较为理想,缺乏对于个体行为理性模型差异性的考量。本文结合国内外研究现状,对频谱共享、移动群智感知、移动数据服务三个基本场景中的网络性能优化问题进行了探索和改进,具体包括以下几部分工作:

1. 概述了无线通信领域网络外部性的研究背景,并综述了本文涉及到的移动网络机制设计及隐私保护的相关研究进展。

2. 研究了隐私保护下群智感知系统平台成本最小化问题, 提出了一种用于移动群智感知中隐私数据聚合的拍卖框架。由于移动用户感知能力和提供数据的隐私成本的差异性, 作为拍卖者感知平台的挑战在于选择合适的参与用户, 针对性地为他们设计数据噪声分布, 使得用户的数据隐私得到保护, 同时数据聚合结果达到既定准确性指标。本文提出了一种用户本地数据加噪的方案, 并揭示了用户间对于隐私保护级别的负网络外部性效应。根据用户对于隐私保护级别的偏好, 本文分成“消极隐私保护”和“积极隐私保护”两种场景进行问题的建模与求解。基于问题隐藏的单调性特性, 针对两种场景分别提出了具有诚实性、个体合理性、计算高效性的激励机制设计 DPDA 和 EDPDA, 使得感知平台在满足结果准确性约束的同时可以给予用户足够的奖励并近似地实现成本最小化。本文通过理论分析结合充分的仿真实验验证了所提出的算法的表现。
3. 研究了隐私保护下具有社交意识的网络吞吐量最大化问题。在数据库辅助频谱共享的场景中研究了移动用户位置隐私保护下的频谱接入机制。其中移动用户在频谱共享决策制定中同时考虑了其在地理位置上和社交联系上与其他用户的耦合关系。这两层耦合关系分别决定了其所受周围用户的信号干扰影响（负网络外部性）以及其所受其他用户的社交效应（正网络外部性）。针对基于接收信号强度（RSS）的位置隐私攻击, 本文提出了一种信号传输功率扰动的方案以降低隐私攻击的有效性。进一步, 本文将隐私保护下次级用户的频谱共享问题建模成一个社交群体效用最大化（SGUM）博弈。其中次级用户以最大化其社交群体效用为目标进行策略性的信道接入选择。而社交群体效用即刻画了用户在两种网络外部性影响作用下所获得的实际效用。针对该博弈模型本文设计了一个基于无悔学习规则的双时间尺度分布式学习算法, 并证明其以概率 1 收敛至博弈的相关均衡集合。数值仿真结果证实所提出的算法可以在隐私保护与网络吞吐量最大化的目标之间进行权衡。
4. 研究了服务提供商收益最大化问题。在竞争性数据服务市场中多个服务提供商通过定价策略的制定以最大化自身收益。市场中移动用户的数据消费行为同时受到社交效应（正网络外部性）和拥塞效应（负网络外部性）两方面因素的影响。为了刻画移动用户和服务提供商之间的策略互动, 本文使用斯塔克伯格博弈模型对问题建模, 具体包括第一阶段的提供商博弈和第二阶段的用户博弈。针对用户博弈, 本文刻画了均衡解的特征并证明了其唯一存在性。针对提供商博弈, 本文考虑提供商行为理性与行为有限理性两种场景, 并证明了博弈中混合策略均衡解的存在性。进一步, 本文提出了一种分布式学习算法, 用于寻找提供商博弈的混合策略均衡解。数值仿真结果体现了网络

效应和拥塞效应对系统性能的影响,并验证了有限理性行为对于服务提供商收益的负面影响。

5. 对全文进行了总结,并对进一步的研究工作进行了展望。

关键词: 网络外部性; 网络性能优化; 机制设计; 隐私保护; 博弈论

Abstract

With the popularity of mobile devices and the rapid development of related fields such as mobile social networks and online entertainment, subscribed mobile users and data traffic around the world have experienced a trend of substantial growth in recent years. The enlarging demands for high-quality communication and data service give rises to new challenges to the development of wireless network technology. To optimize the overall network performance, the network operators can rely on the enhancement on network infrastructure and capabilities brought by the next-generation 5G technology. In addition, they ought to exploit the limited resource in an efficient and reasonable manner via sophisticated designed resource allocation mechanism and service pricing mechanism. On the other hand, with the growing sensing capabilities of mobile devices, the mobile network has become the main channel for third-party applications to collect users' personal data and urban environment data, which has promoted the development of mobile big data technologies. While on the other side of the coin, the exposure of personal data has incurred serious privacy crisis and raised people's concern about the risk of privacy leakage.

As one of the main topics in the research field of network economics, network externality is defined as the indirect impact on an individual's utility from other individuals in the rest of the network. Such kind of effect may simply depend on the size of the network, or depend on the degree of involvement of other individuals, as well as the strength of the association between individuals. In recent years, the continuous expansion on the network-scale has made the phenomenon of network externalities increasingly prominent in some scenarios. Specifically, the utility obtained by an individual user from the network can be increased (with positive network externality) or decreased (with negative network externality) by the enhanced involvement of other users in the network. It is due to such prominent influences that network externality has on the individuals' utility, taking the network externality into consideration is of great importance. In recent years, researchers have made a lot of progress in the protocol designs aiming for network performance optimization and privacy protection. However, there are still three aspects that require more efforts to be taken: 1)

the lack of analysis and investigation on solving network optimization from the view of network externality; 2) the lack of research work combining network performance optimization and users' privacy protection, especially the characterization on the trade-off between the system performance and the privacy; 3) the lack of heterogenous modeling about individuals' strategic behaviors. Based on the state-of-the-art, this thesis has made an effort on network performance optimization within three scenarios: the spectrum sharing network, the mobile crowdsensing network, and the mobile data service market. The main contributions are summarized as follows:

1. A brief introduction on the background of network economics and the basic concepts of network externality and some discussion on the related works about mechanism design and privacy protection in mobile networks, is provided.
2. The first part studies the cost minimization problem of privacy-preserving mobile crowdsensing system and proposes an auction based framework for privacy-preserving data aggregation. Given the heterogeneity on mobile users' sensing capabilities and their unit privacy cost, the platform is facing the challenges of determining the set of mobile users for which the noise distribution need to be carefully designed so that the privacy protection is provided and the data aggregation accuracy is satisfied. This work carries out a local data perturbation scheme and reveal the negative externality concerning the users' privacy-preserving level. And two different settings, "privacy passive" setting and "privacy proactive" setting, are discussed separately which corresponds to two kinds of privacy-preserving attitudes. Based on the hidden monotonicity of the problem, two computational efficient incentive mechanisms, DPDA and EDPDA, are proposed satisfying the truthfulness and individual rationality properties. By using the the proposed algorithms, the platform can approximately minimize the cost under the aggregation accuracy constraint in both two settings. The performance of the algorithm is validated through extensive numerical experiments.
3. The second part studies the socially-aware throughput maximization problem within the context of locational privacy-preserving database-assisted spectrum sharing. The mobile users jointly take into account their physical coupling (negative externality due to the signal interference) and social coupling (positive externality due to the social network effect) while making spectrum sharing decisions. In particular, to mitigate RSS-based PHY-layer location privacy threat, a power perturbation approach is employed where each secondary user judiciously "reduces" its transmission power by choosing a power level following a statistical

distribution (with a negative bias). Accordingly, the privacy-preserving spectrum sharing among users is cast as a stochastic channel selection game, where strategic players (secondary users) adjust their strategies dynamically aiming to maximize their social group utilities. Specifically, a two-time-scale distributed learning algorithm based on no regret-based rule is devised, which is shown to converge almost surely towards the set of socially-aware correlated equilibrium. The numerical results corroborate that the higher the privacy protection level, the more significant the degradation of the network throughput would be.

4. The third part studies the revenue maximization problem for the wireless service providers. The pricing strategies of multiple service providers in a competitive data service market are studied where mobile users' data consumption behaviors are influenced by two effects: the network effect (positive network externality) and the congestion effect (negative network externality). To analyze the strategic interactions between mobile users and service providers, a two-stage Stackelberg game is devised, consisting of a providers' game in Stage I and a users' game in Stage II, respectively. In particular, for the users' game, the equilibrium solution is characterized explicitly and its uniqueness is established. For the providers' game, the analysis indicates that a mixed-strategy equilibrium solution is guaranteed for the scenario with rational providers as well as the scenario with providers of bounded rationality. A distributed learning algorithm for finding a mixed-strategy equilibrium solution is further provided. And the numerical results provide insights into how positive network effect and congestion effect would impact the system performance, and demonstrate that the bounded rational behavior incurs degradation to service providers' revenues.
5. The conclusions are drawn with future work at the end of the dissertation.

Keywords: Network Externality; Network Performance Optimization; Mechanism Design; Privacy Protection; Game Theory

目录

摘要	I
Abstract	IV
目录	
插图	X
表格	XI
第一章 绪论	1
1.1 研究背景	1
1.1.1 移动网络中的网络经济学	1
1.1.2 移动网络性能优化机制设计	3
1.2 研究现状	5
1.2.1 移动网络中的网络外部性效应	5
1.2.2 群智感知系统中的数据隐私保护	6
1.2.3 频谱共享中的位置隐私保护	7
1.2.4 移动网络中的非完全理性行为	8
1.3 本文研究内容	8
1.3.1 研究思路	9
1.3.2 研究内容	10
第二章 单重网络外部性下群智感知系统平台成本最小化研究	12
2.1 引言	12
2.2 数据隐私保护下的移动群智感知系统	15
2.2.1 系统概况	15
2.2.2 群智感知拍卖模型	16
2.2.3 差分隐私下的数据聚合	19
2.2.4 隐私与准确性	21

2.3	消极隐私保护下的激励机制	22
2.3.1	数学模型	23
2.3.2	机制设计	24
2.3.3	DPDA 性能分析	25
2.4	积极隐私保护下的激励机制	28
2.4.1	问题建模	28
2.4.2	机制设计	29
2.4.3	EDPDA 性能分析	31
2.5	性能评估	32
2.5.1	仿真设置	32
2.5.2	结果和讨论	34
2.6	本章小结	36
第三章	双重网络外部性下频谱共享网络吞吐量最大化研究	37
3.1	引言	37
3.2	位置隐私保护下的频谱共享系统模型	39
3.2.1	基本设置	39
3.2.2	针对基于 RSS 的位置隐私攻击的随机功率扰动	41
3.3	隐私保护下带有社交意识的频谱共享	42
3.3.1	频谱共享中的社交群体效用最大化 (SGUM) 博弈	42
3.3.2	无悔学习规则 (No-regret learning rule)	43
3.4	用于隐私保护下频谱共享的分布式无悔学习算法	45
3.4.1	双时间尺度无悔学习算法	45
3.4.2	收敛性分析	47
3.5	性能评估	49
3.5.1	仿真设置	49
3.5.2	结果与讨论	49
3.6	本章小节	52
第四章	双重网络外部性下移动数据服务提供商收益最大化研究	53
4.1	引言	53
4.2	社交关系影响下移动数据的价格竞争	55

4.2.1	系统模型	55
4.2.2	斯塔克伯格博弈建模	57
4.3	用户数据使用博弈中的联结需求均衡	58
4.3.1	联结需求均衡的存在性与唯一性	59
4.4	理性服务提供商之间的定价博弈	61
4.4.1	混合策略定价均衡点的存在性	62
4.5	有限理性服务提供商之间的定价博弈	63
4.5.1	前景理论下的提供商收入期望	63
4.5.2	混合策略定价均衡点的存在性	65
4.5.3	混合策略定价均衡的分布式学习算法	66
4.6	仿真验证	69
4.7	本章小结	72
第五章	总结与展望	73
5.1	全文总结	73
5.2	研究展望	74
附录 A	第二章相关推导证明	76
A.1	定理 2.4 和推论 2.5 的证明	76
A.2	引理 2.4.3 的证明	78
附录 B	第三章相关推导证明	80
B.1	定理 3.2 的证明	80
参考文献		81

插图

1.1	全文组织结构图	9
2.1	基于拍卖模型框架的保隐私数据聚合	16
2.2	不同准确性约束下的平台支付（消极隐私保护情况）	32
2.3	数据隐私与准确性之间的关系	33
2.4	不同准确性约束下用户总量的影响（消极隐私保护情况）	33
2.5	积极隐私保护与消极隐私保护之间的结果对比（归一化失真度要求 = 0.2）	34
2.6	不同参数设置下 DPDA 的运算耗时。	36
3.1	认知无线电网络的社交域-地理域说明	40
3.2	t 时刻时效用学习与策略学习之间耦合关系的示意图	48
3.3	网络吞吐量的收敛表现	50
3.4	用户 #10 的策略收敛表现 ($M=4$)	50
3.5	几种学习算法在不同功率扰动水平下的性能比较	51
3.6	社交联系强度对吞吐量的影响	52
4.1	系统模型以及服务提供商和移动用户之间的交互关系示意图。	57
4.2	包含三个服务提供商和四个移动用户的系统示意图，系统中存在 9 条链接。 ..	59
4.3	失真参数 α 不同取值下的概率失真函数。	64
4.4	不同效用规避参数 β 和损失惩罚参数 λ 下的框架函数。	64
4.5	社交联结权值平均值 μ_G 对总数据使用量的影响。	70
4.6	归一化最佳收益与用户数量 N 变化关系。	70
4.7	归一化的最佳收益与服务成本差异之间的关系。	71
4.8	有限理性对服务提供商总收益的影响。	71

表格

1.1	针对现有移动群智感知数据保隐私方法类型的总结	7
2.1	DPDA 和 EDPDA 算法的近似率 (归一化失真度要求 = 0.2).	35

第一章 绪论

本章摘要：本章首先介绍了网络经济学的背景、网络外部性效应的基本概念及其在移动网络中的体现;接着分析总结了近些年国内外涉及到激励机制设计、隐私保护等与本文中网络性能优化场景相关领域的研究现状;最后阐述了本文的研究思路和研究内容。

关键词：网络经济学;网络外部性;机制设计;隐私保护;群智感知;研究背景;研究现状

1.1 研究背景

当今世界是一个网络的世界,各种形式的网络在人们生活中随处可见、无处不在。这其中包括,由移动通信设备作为节点、通信链路连接而成的移动通信网,节点对应每个人、连边代表人与人之间社交联系的社交网络,由发电站、配电站、工厂、办公楼、电动车充电站这些电力设施以及它们之间的电力传输线路所组成的电力网络,以及由各个运输枢纽与连接他们的运输线路、运输工具所定义的交通运输网络。在本研究中,我们所关注的主要对象是移动通信网络,同时也涉及到由移动网络中用户之间社交联系所定义的社交网络。

1.1.1 移动网络中的网络经济学

移动通信网络具有两个显著的特征。首先,相对于不断增长的用户数量以及流量需求,移动通信网络普遍存在资源有限甚至缺乏的特性。其具体表现在每一个移动设备上的通信、计算、能耗等资源都是有限的,此外移动无线通信所能使用的频谱资源是有限的,通信总带宽是一定的。由此,通信运营商始终面临的一个难题即是如何高效、公平地对带宽进行分配,使用户在通信过程中受到的信号干扰控制在可接受的范围内,实现尽可能高的通信质量保证。移动通信网络的另一个特征则是网络中的个体相对独立,且具有自利属性。这些个体大到不同的网络运营商(例如中国移动、中国联通),小到终端的一个移动设备(例如智能手机),都是以最大化自身利益为目标的。这种情况下,网络系统的全局最优解通常是难以达到的,而实现网络性能的提升与优化则依赖于个体之间在有效的激励机制作用下

的协同合作。

上述的两个特征使得移动通信网络中的很多性能优化问题具有明显的经济学特征。针对资源有限的特性，网络效用最大化（Network utility maximization）的一系列理论工具已经在对于诸如网络吞吐量、延迟、公平性等指标的优化研究中取得了显著的成果^[1]。而针对网络中用户的个体自利属性，则更多需要借助网络经济学中的一些概念工具对相关问题进行建模求解。包括“非合作博弈”、“拍卖理论”、“纳什均衡”在内的一系列经济学概念原理^[2]已经被广泛应用于各种移动通信网络中的资源分配与系统优化问题中。在一些问题背景下，移动用户的集合、他们对应的行为策略集合以及他们各自效用函数的集合即可构成一个典型的博弈模型。在博弈模型中，每个用户作为玩家以最大化自身的效用为目标，针对其他用户的策略做出最优相应（Best response）。当博弈处于其均衡状态时，给定其他用户的决策，任何用户都无法通过单独改变自己的决策以获得个体效用的提升。然而，从网络整体的角度来看，博弈均衡状态下的系统性能可能较全局优化得到的系统性能有所损失。这种损失正是由于网络中个体的自利属性以及他们决策间的关联性所导致的。

1.1.1.1 网络外部性效应

网络外部性作为网络经济学的主要研究对象之一，描述了存在于网络中个体之间相互影响的一种现象。其概念最早由 Rofls 于 1974 年提出的^[3]，之后 Katz 和 Shapiro 在 1985 年完成了正式的定义^[4]。在经济学中，网络外部性通常指某物品的一个用户给该物品对于其他用户的价值带来的影响。在本文中，网络外部性则更具一般性地指任一网络参与者受到网络中其他参与者非直接影响所导致其效用（Utility）上的损失或受益。这种影响可能简单取决于其他参与者的数量，也就是网络的规模，同时也可能取决于网络中个体的参与程度或者个体之间的关联强度^[5]。

依据不同的分析视角，网络外部性现象可以被进一步细分。常见的划分方式将网络外部性分为正网络外部性与负网络外部性两类。简单来说，如果用户所获得的效用随其他用户参与程度增加而增加，则为正网络外部性，相反若用户效用随其他用户参与程度增加而降低则为负网络外部性。典型的正网络外部性的例子包括电话网络，使用电话进行联络的用户数量越多，则对于每一个使用电话的用户其效用越大。负网络外部性现象^[6]也较为普遍的存在于生活中的很多场景中，例如机动车辆数量增多带来的交通拥堵，化工企业数量增多带来的空气污染、水污染等。网络外部性的其他分类方式还包括直接网络外部性或间接网络外部性、单边网络外部性或双边网络外部性等。此外，当个体只受到网络中一部分用户的影响时，网络外部性还可以被定义为一种局部网络影响，例如社交网络影响^[7]。

近年来,移动通信技术的飞速发展、移动设备的普及、网络规模的不断扩大、以及移动社交应用的盛行,使得一些移动网络问题中的网络外部性现象愈发凸显出来。而在对这些问题的分析建模过程中考虑网络外部性的影响则具有十分重要的意义。例如在网络服务定价问题中,作为一个服务提供商,如果其掌握了移动用户的社交关联信息,那么其可以在考虑社交影响带来的正网络外部性的基础上,进行定价策略的优化。在这种情况下,使用无线数据服务给用户带来的价值可以被分成两部分,一部分是用户自身使用服务获得的效用,另一部分是与其有社交关联的用户同时使用服务所带来的额外效用。因此,如果提供商在优化定价策略时仅考虑前者而忽略了后者则可能使得到的收益偏离实际可达到的最优收益。相反如果提供商适当降低服务价格以吸引更多用户的参与,则用户在正网络外部性影响下可获得更多的效用,进而使用更多的数据服务,给服务提供商带来额外的收益。

1.1.1.2 理性行为模型

在移动网络中,通常假设通信或数据资源的持有者和使用者为独立的个体,他们了解自己可以选择的决策,对于所得到的不同的结果有明确的偏好。这些独立个体执行最大化个人效用的行为则被称之为理性(Rational)行为。而个体信息的不完整以及不确定性,甚至个体对自身或他人策略的非客观性评估,会使得实际中个体行为偏离理性行为,其被称之为有限理性(Bounded-rational)行为。行为经济学(Behavioral Economics)对于个体的非完全理性行为有着广泛且深入的研究,其中就包括获得2002年诺贝尔奖经济学奖的展望理论(Prospect Theory)^[8]。在具有不确定性的环境中,相比于通常用于求解最优策略所使用的期望效用理论(Expected Utility Theory),展望理论提供了对于决策制定在行为心理学上更加准确的描述,从相关实验研究的结果上看其更加贴近真实中的情况。在移动网络的一些问题场景中,展望理论有着较大的应用价值。在移动网络中的机制设计中,充分的考虑不同用户行为模型上的异质性是至关重要的。

1.1.2 移动网络性能优化机制设计

借助于网络经济学的理论工具,人们可以通过对移动网络运作机制的巧妙设计实现对于复杂网络系统建立更加实际的模型并进行求解。下面我们对本文所涉及的三个移动网络机制设计问题进行简单的介绍:

- **分布式频谱接入机制:**移动通信网络中所使用的的频谱是一种典型的稀缺资源,当空间上临近的两个通信链路同时使用同一频段时会互相产生干扰,影响通信的质量。在这种情况下,有限的频谱带宽中又有大部分被划分为只有“主用户”可以使用的专用

频段。动态频谱共享技术的出现大大改善了频谱的使用效率,使得无频谱使用执照的移动设备可以以“次级用户”的身份机会性地在“主用户”未使用其频段时接入频段,被认为是解决频谱利用问题的有效解决方案。然而在规模较大的移动网络场景中,由于个体用户普遍具有自利属性,如何为大量次级用户设计高效的分布式频谱共享接入机制以优化系统的整体性能仍然面临着较大的挑战。较为常见的一类解决方案是将次级用户之间的交互建模成非合作博弈^[9,10]。

- **数据服务定价机制:** 一个移动通信网络是由网络运营商(数据服务提供商)和众多移动用户(数据服务使用者)所组成的。运营商制定数据服务的价格,而用户基于观察到的价格决定自己的数据使用需求量。对于数据服务定价机制的研究需要将对于用户行为的分析与对于运营商价格策略的优化有效地结合起来。价格策略是运营商追求收益优化的重要杠杆。较高的价格在得到更大边际收益的同时可能会抑制用户的需求,而较低的价格有助于扩大其用户市场,而会造成一定的收益损失。在对用户行为的建模中,当假设其决策不考虑自身数据使用行为对于价格的潜在影响时,这些用户被称为价格接受者(price-taker)。相反,当假设用户的决策考虑了网络中其他用户的行为及其影响时,这些用户被称为价格预期者(price-anticipator),此时对于用户的行为策略的建模和分析需借助博弈论的理论工具。价格预期者类型的用户、多个运营商之间的竞争以及服务市场供需两侧的信息不完整都会给数据服务定价机制的设计带来不小的挑战。
- **群智感知激励机制:** 群智感知基于众包的思想,将感知任务指派给移动设备来完成,并支付给移动用户一定奖励以补偿用户的资源消耗。与频谱选择和数据服务消费场景所不同,群智感知中的感知、计算资源属于移动用户,系统则需要通过有效的激励机制向用户提供激励,鼓励用户参与并贡献其感知资源。在一些场景中,为了对用户资源进行协调调度,系统需向用户获取一些有关用户资源的信息(例如移动用户的感知成本、数据隐私偏好等)。而对于激励机制设计的一个主要挑战即是如何促使用户诚实地提供所需的个人相关信息。常见的用于群智感知激励机制设计包括基于反向拍卖模型的机制^[11],具体包括确定拍卖赢家(Winner-determination)和确定相应的奖励金额(Price-determination)两步。此外,如何消除用户对于贡献个人数据所产生的隐私顾虑也已成为相关研究关注的重点。

1.2 研究现状

1.2.1 移动网络中的网络外部性效应

随着越来越多的移动用户通过在线社交网络（例如 Facebook^[12], Twitter^[13]）进行联络，用户的影响力和信息传播速度已经达到了前所未有的速度^[14]。作为一种典型的局部网络外部性效应，移动网络的社交影响引起了服务提供商以及平台开发人员的广泛关注。David 等^[15]将用户之间的社交效应建模为一种正网络外部性效应。Chen 等^[16]采用了类似的想法来刻画众包系统中不断增长的社交用户数量所带来的内在收益的增长，及其对于平台外在奖励开支的削减。为了减少蜂窝网络峰值负载，Malandrino 等^[17]提出了一系列算法，根据用户在社交网络中的地位将数据内容主动地推送给一些特定用户。一些研究工作已经在解决网络设计和优化问题中对于个体间的社交影响进行充分的考量。Chen 等^[18]利用社交信任和互惠互利因素，通过将问题转化为联合博弈来改进 D2D 合作通信质量。Li 等^[19]针对认知无线网络中个体的社交行为进行了社交网络分析。Ashraf 等^[20]使用用户之间的社交距离确定用户关联，基于此实现了具有底层 D2D 通信的小型蜂窝网络系统性能上的提升。Yang 等^[21]提出了一种移动群智感知系统设计，利用移动用户之间的社交联系来激励他们的参与和合作，以获取更高的回报。Chen 等^[22]提出了一个社交群体效用最大化（SGUM）框架，其中每个用户以自己的个人效用与社交朋友的效用所组成的“群体效用”为优化目标。

除了社交效应所导致的正网络外部性效应，负网络外部性现象也存在于很多移动网络问题场景中。例如，在通信网络中，当用户数量增加使得流量负载超出基础架构容量时，就会发生拥塞现象。这种影响在许多数据通信速率较高的移动网络系统中尤为显著，目前已有相关工作对其进行了深入的研究^[23-27]。其中 Yang 等^[26]使用随机博弈模型对无线接入网络选择问题进行建模，并充分考虑了不同用户选择同一无线网络所导致的拥塞效应。移动网络中的另一种常见的负网络外部性现象是移动设备间的信号干扰。接入一个信道的用户越多，每个用户所可以获得的吞吐量越低。因而当移动设备在做信道接入决策时，除了考虑信道的通信质量，还需考虑其他设备的信道接入选择。Jiang 等^[28]在研究多信道感知接入的问题时就从网络外部性的角度将信号干扰作为影响次级用户顺序信道接入决策的主要因素并进行相关分析。

1.2.2 群智感知系统中的数据隐私保护

在群智感知系统中,用户在向感知平台提供数据的过程中往往会直接或者间接地泄露与用户相关的敏感信息。因次,参与用户在产生感知成本的同时也会付出一定隐私成本。近些年,研究者们开始对群智感知系统中的数据隐私保护给予更多的关注^[29-35]。其中大多数工作^[29-33]在建模中假定群智感知平台是值得信赖的,用户直接将原始感知数据发送给作为数据收集方的感知平台,将数据隐私保护控制权完全交给了感知平台。近期的工作^[34,36]更多考虑了感知平台为非可信的情况,并允许用户通过报告含有噪声的数据来对其隐私进行保护。本小节将介绍几种与本文相关的移动群智感知隐私保护设计,这些设计将基于差分隐私的数据加噪与激励机制设计相结合,把对于用户隐私成本的补偿考虑到激励机制的设计中。下文根据所使用的激励机制的类型对相关工作进行分类,包括基于拍卖模型的方法,基于博弈模型的方法和基于合约模型的方法。

基于拍卖模型的方法: 反向拍卖机制是移动群智感知系统常用的激励机制类型之一。具体来说,由平台充当拍卖商移动用户向平台报告其出价,反映其参与成本。该平台选择参与者并确定相应的付款,目的是在预算约束下使总付款最小化或使平台效用最大化,或使参与者的社会福利最大化^[37]。Ghosh 和 Roth 的工作^[31]首创性地提出了一种可用于保护用户数据隐私的拍卖机制,其中用户的出价反映了其单位隐私成本,并令用户单位隐私成本与差分隐私保护级别 ϵ 的乘积来刻画用户的隐私损失。文中所设计的拍卖机制满足激励机制设计的两个基本要求,即诚实性 (Truthfulness) 和个体合理性 (Individual Rationality):

- **诚实性:** 参与用户无法通过不诚实的出价行为获取收益上的提升。
- **个体合理性:** 每个参与用户收到的奖励不低于其隐私损失。

Ghosh 等^[31]从以下两个角度描述了数据收集者付给用户的总奖励额与数据聚合结果准确性之间的折衷:(1) 在给定准确性要求的情况下最小化总奖励额;(2) 在给定总奖励额预算情况下最大化数据聚合结果准确性。在此基础上,Jin 等^[32]开发了一个用于在移动群智感知系统中保护用户数据隐私的组合拍卖机制框架。除了在建模中将隐私成本作为用户感知成本的一部分,作者在解决用户选择问题中还考虑了感知用户可靠性对聚合结果准确性的影响。另一相关工作^[33]则考虑了移动用户行为受社交因素的影响。值得注意的是,以上工作在建模过程中都假设数据收集者为可信第三方。

基于博弈模型的方法: 使用基于博弈论模型的问题建模^[37-39]是网络经济学中研究激励机制的另一种典型方法。与基于拍卖的激励机制设计相似,基于博弈论模型的方法需要指定一种支付策略以激励用户的参与。所不同的是,在基于博弈的方法中,用户是否参与不由平台

选择确定，而是用户根据平台的奖励规则做出策略性的决策。Wang 等^[34]在一种特定背景下设计了一种博弈机制，其中数据收集者购得的用户私人数据为用户对于系统状态的认知。不同于文献 [31–33] 中所考虑的可信平台对聚合后数据进行中心式数据加噪，Wang 等^[34]使用了数据收集者不可信的假设。在这种前提下，每个参与用户策略性地对于其原始数据进行扰动，随后将带噪声的数据发送给数据收集者。在博弈模型中，用户为玩家其行动对应于其数据扰动策略。通过对于数据收集者定价策略的精心设计，该机制可以实现当博弈达到纳什均衡时，参与用户的隐私成本得到补偿且数据聚合结果满足一定的准确性要求。然而使用博弈论建模的方法可能会导致系统处于效率较低的均衡状态，使得数据聚合结果难以达到较高的准确性标准。

基于契约模型的方法：在基于契约的机制中，契约设计者将精心设计一组付出-报酬的对应选项，以激励具有不同类型的个体的参与，同时优化设计者自身的收益。基于契约的方法不要求实时的竞标信息，而是利用个体成本的统计信息来确定报酬契约，从而克服了信息不对称的问题并减少了通信和计算开销。Zhang 等^[40]提出了一种基于契约的移动群智感知隐私保护框架。具体来说，感知平台设计并公布其契约选项，每个选项都指定一种类型的差分隐私保护级别，以及用户在同意的契约选项后所可收到的相应报酬。此后，每个用户选择使自己效用最大化的契约选项之一。作者选取了适当的指标并得出了个人隐私保护级别与数据聚合准确性之间的定量关系。表1.1总结对上面所介绍的三类方法进行了对比。

表 1.1 针对现有移动群智感知数据保隐私方法类型的总结

文献	激励机制类型	平台可信	数据扰动机制	特征
[32]	拍卖	是	拉普拉斯机制	考虑用户可靠性
[33]	拍卖	是	拉普拉斯机制	考虑用户社交联系
[34]	博弈	否	随机回应	分析了用户的均衡行为
[40]	契约	否	拉普拉斯机制	解决信息不对称问题

1.2.3 频谱共享中的位置隐私保护

无线网络中的另一种常见隐私攻击是针对移动用户位置信息的攻击，其相关问题一直以来被众多学者所关注。这其中有较大一部分工作侧重于在网络应用层中对于位置隐私攻击与防护的研究。用于解决网络层位置隐私保护的方法包括位置混淆 (Location obfuscation)^[41]、用户匿名化 (Anonymization)^[42–44]、以及基于密码学的位置变换^[45,46]。这些方法分别适用于不同的应用场景，其中位置混淆通过在位置信息上添加扰动将真实位置与临近位置进行混淆，并可以进一步结合差分隐私的工具从数学上量化位置隐私保护的级别^[47]。匿

名化方法中则包括基于虚假名 (Pseudonym) 的方法^[42] 以及基于 k -匿名的方法^[44]。其中前者致力于将用户真实身份与其位置信息解耦, 后者的核心思想则是保证至少 k 个用户的位置是难以区分的。基于密码学的位置变换方法则通过对位置信息的加密提供对于敏感位置信息的保护。

然而针对于无线网络物理层面中的位置隐私攻击, 以上这些隐私保护方案效果则十分有限。在网络物理层的位置隐私攻击中, 攻击者主要利用信号的物理信息来推测用户的位置。在这种情况下, 对传输信号的物理信息进行模糊化成为更为有效的防御手段。在 [48] 和 [49] 所设计的防御方案中, 移动设备通过策略性地降低其传输功率, 可以有效减少可参与完成 RSS 定位的攻击者数量, 或降低攻击者 RSS 定位的准确性。Wang 等^[50] 则聚焦于定向天线的设计, 以应对物理层位置隐私攻击的问题。Gao 等^[51] 所应用的位置隐私保护措施与本文中所使用的较为接近。然而不同于本文所考虑的基于 RSS 的定位攻击, 文献 [51] 中考虑的是通过推断目标用户所使用的信道来判断其位置。因而目标用户可以通过选择最有利的信道来缓解隐私攻击的威胁。

1.2.4 移动网络中的非完全理性行为

近些年, 人们在解决一些实际的无线网络中个体的决策问题时, 采用了展望理论 (Prospect Theory)^[8] 对决策过程进行建模。例如, Li 等^[52] 研究了一种无线环境下的随机接入博弈, 其中用户考虑了展望理论中的概率失真效应作用, 策略性地确定其在冲突信道上的传输概率。Yu 等^[53] 研究了一种数据市场模型, 模型中用户需要选择成为数据卖方还是数据买方, 并确定交易的数据量。他们考虑了展望理论中的概率失真效应和效用框架效应对用户决策行为的影响, 并将该问题表述为非凸优化问题。

1.3 本文研究内容

近年来, 研究者们在不同应用场景中对网络性能优化的研究取得了很多进展, 然而现有工作仍然存在以下三方面的不足: (1) 在解决网络性能优化的问题时缺乏从网络外部性的角度的分析与讨论; (2) 结合网络性能优化与用户隐私保护的研究分析还较少, 尤其缺乏针对性能提升-隐私保护之间权衡的刻画与考量; (3) 现有激励机制设计中对于用户个体在交互中的策略性行为假设较为理想, 与实际情况存在差距。以上这些研究不足一定程度上限制了网络性能优化的提升空间, 为本文提供了充分的研究动机。

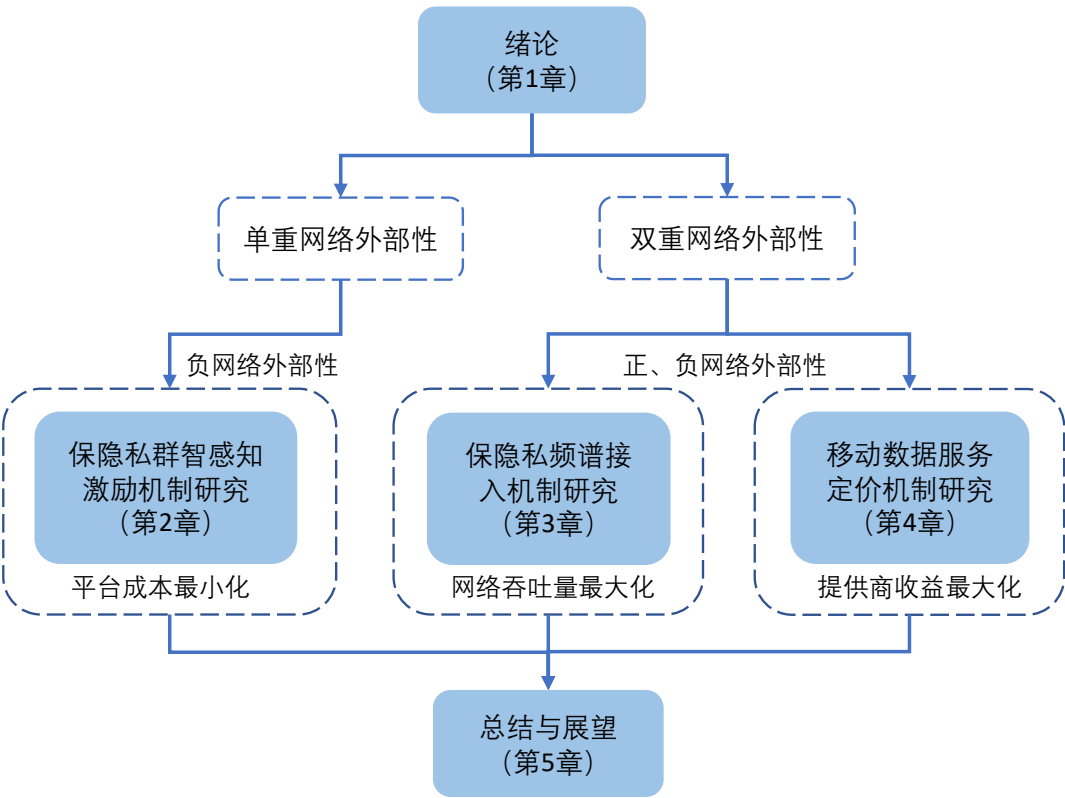


图 1.1 全文组织结构图

1.3.1 研究思路

基于对移动通信网络中网络外部性现象的认识，本文从网络外部性的视角，对不同场景中的移动网络资源分配与优化问题进行研究。借助网络经济学的相关原理与工具，对问题进行分析，提出相应的机制设计和协议算法，以达到提升网络系统性能的目的。全文的思路和基本组织架构如图 (1.1) 所示。第 1 章绪论介绍网络外部性的概念以及隐私保护、群智感知激励机制等相关研究背景和国内外研究现状，第 2-4 章为文章的主体部分，第 5 章对全文进行总结和展望。主题内容可分为三大部分，对应于三种场景下不同网络性能目标的优化，其中第一个场景中移动网络受单重网络外部性的影响，后两个场景中网络则受到正网络外部性和负网络外部性的双重影响。具体来看，第一部分以群智感知平台成本最小化为目标，研究了数据隐私保护下考虑了负网络外部性效应的数据聚合激励机制设计，对应的章节为第 2 章。第二部分研究了信号干扰（负网络外部性）和社交效应（正网络外部性）共同影响下以吞吐量最大化为优化目标的频谱接入机制设计，对应于本文的第 3 章。第三部分研究了社交效应（正网络外部性）拥塞效应（负网络外部性）共存的移动数据服务市场中，服务提供商的定价机制收益最大化问题，对应的章节为第 5 章。

1.3.2 研究内容

本文的具体研究内容如下：

第二章考虑了数据隐私保护下群智感知系统平台成本最小化问题，提出了一种用于移动群智感知中隐私数据聚合的拍卖框架。由于移动用户的感知能力和提供数据的隐私成本皆有所差异，充当拍卖者角色的感知平台的主要挑战在于选择合适的参与用户，并针对性地为他们设计用于隐私保护的数据噪声分布，使得数据聚合结果达到准确性指标，同时用户的隐私得到保护并获取足够的奖励。本文提出了一种允许用户进行本地数据加噪的方案。其中用户所允许添加的噪声分布由感知平台决定，其数据隐私保护程度可以使用差分隐私的量化指标进行衡量。本文揭示了用户间所存在的负网络外部性效应，并根据用户对于隐私保护级别的偏好分成“消极隐私保护”和“积极隐私保护”两种场景进行问题的建模与求解。在“消极隐私保护”场景中当平台可以通过支付奖励充分补偿用户的隐私损失时，用户即愿意参与并提供感知数据。而在更具一般性的“积极隐私保护”场景中，参与用户对其数据隐私保护级别存在固有要求，仅当要求满足时才同意参与任务。基于问题隐藏的单调性特性，本文分别针对两种场景设计了具有诚实性、个体理性，计算效率高的激励机制，以近似地最小化感知平台用于购买用户数据的成本，同时满足对于聚合结果准确性的要求。我们通过理论分析结合充分的仿真实验验证了所提出的方案。

第三章考虑了位置隐私保护下具有社交意识的网络吞吐量最大化问题。在数据库辅助频谱共享的场景中，由于便携式移动设备与用户的强关联性，对移动设备的定位攻击给用户带来了位置隐私保护方面的担忧。本文中移动用户对信号传输功率水平添加随机扰动，以削弱基于 RSS 的潜在位置隐私攻击的威胁。另一方面，虽然用户之间的物理信号干扰（负网络外部性）会给网络整体性能带来负面影响，但用户之间社交关联引入的社交效应（正网络外部性）给系统效用带来了一定的提升空间。本文中，每个次级用户在进行频谱接入决策时，把包含其社交好友效用的“社交群体效用”作为自己的优化目标。进一步，本文将这种隐私保护下的具有社交意识的频谱共享问题建模成一个随机信道选择博弈。博弈中次级用户作为策略性的玩家动态调整其策略，以最大化其社交群体效用。我们针对博弈模型设计了一个基于无悔规则的双时间尺度分布式学习算法，并证明其几乎可以肯定收敛至博弈的相关均衡集合。数值结果证实，隐私保护级别越高，网络吞吐量的下降就越显著。

第四章考虑了服务提供商收益最大化问题。在竞争性数据服务市场中多个服务提供商通过定价策略的制定以最大化自身收益。市场中移动用户的数据消费行为同时受到两方面因素的影响：社交效应（正网络外部性）和拥塞效应（负网络外部性）。为了分析移动用户和服务提供商之间的策略互动，本文设计了一个两阶段的斯塔伯格博弈，分别由第一阶段

的提供商博弈和第二阶段的用户博弈组成。针对用户博弈，本文刻画了均衡解的特征并建立了它的唯一性。对于提供商博弈，分析表明，对于提供商行为理性的场景以及提供商行为有限理性的场景，混合策略均衡解均是有保证的。进一步，本文提出了一种分布式学习算法，用于寻找提供商博弈的混合策略均衡解。最后，数值仿真结果对于正网络外部性和负网络外部性如何影响系统性能的提供了见解，并验证了提供商有限理性行为对其收益所产生的负面影响。

最后，第六章对全文进行了总结，并提出了未来可能的研究方向。

第二章 单重网络外部性下群智感知系统平台成本最小化研究

本章摘要：本章提出了一种用于移动群智感知保隐私数据聚合的拍卖框架。该框架中，为了保护个人隐私，移动用户将带有噪声的数据提交给作为拍卖商的感知平台。为确保数据聚合结果的准确性，感知平台只能通过有限的市场力量，即根据用户的隐私偏好和感知能力选择合适的感知用户群体，以此控制聚合数据中的噪声水平。这种由用户本地完成数据加噪的方式给群智感知系统引入了负网络外部性的影响因素：每个用户的隐私保护程度取决于聚合结果中的总噪声量，而总噪声量又取决于选择哪些移动用户以及这些用户所添加的噪声。本章研究了在这种单重负网络外部性作用下的拍卖激励机制设计。具体而言，本章第3节首先考虑一种“消极隐私保护”的场景，即一旦平台可以通过奖励充分补偿用户的隐私损失，用户即愿意参与感知任务并提供感知结果数据。本文通过解析表达式明确地描述了问题的负网络外部性因素与隐藏的单调性特性，并基于此设计出一个具有诚实性、个体理性，计算效率高的激励机制。本章第4节将讨论扩展到“积极隐私保护”的场景，即参与用户对其可获得的数据隐私保护级别有固有的要求。针对两种场景，本文提出的激励机制所确定的用户子集及相应奖励可以近似地最小化感知平台购买用户隐私数据的成本，同时满足对于数据聚合结果准确性的要求。本章通过理论分析结合充分的仿真实验对于提出的方案进行了验证。

关键词：群智感知；数据隐私保护；拍卖理论；差分隐私

2.1 引言

近些年来，移动群智感知的兴起引发了人们的关注。作为一种颇具发展前景的无线传感网络应用，移动群智感知利用人们便携移动设备上的传感器来执行各种感知任务，其应用场景包括医疗保健，环境监测，室内定位和智能交通等^[54]。通过将感知任务外包给公众，移动群智感知系统可以有效地收集细粒度的感知任务数据。然而另一方面，参与感知任务的任何个体不可避免地需要授予任务发布者一定权限以访问其感知数据，因而当感知数据本身具有敏感性且任务发布者不可信第三方时，用户的隐私泄漏隐患便会暴露出来。这种隐私安全隐患已然成为除设备资源消耗（例如电池和计算能力）问题外，阻碍群智感知

用户增长的主要因素。因此，移动群智感知的成功与否很大程度上取决于与隐私保护措施的激励机制设计与运用。

大部分早期的移动群智感知系统激励机制设计^[11,35,38,55-64]仅考虑了参与用户的感知成本，而直到近些年才开始有更多研究工作将参与用户的隐私成本考虑进来。这其中大部分设计基于感知平台为可信第三方的理想假设，允许感知平台收集得到用户的原始数据后在数据聚合结果上进行加噪处理^[32,33]。该方式可以一定程度上解决公开聚合结果所导致的用户数据隐私泄露问题，然而参与用户自身缺乏对其数据隐私保护级别。尤其当感知平台可信度较低时，用户的参与度将大大降低。另有一些设计将平台与用户的交互建模为博弈问题^[34,36]，然而对于博弈均衡点质量控制上的挑战使得数据聚合结果的准确性难以得到保证。解决这些不足的关键在于为移动群智感知开发新颖的数据聚合框架，允许参与用户向不可信的第三方（包括感知平台在内）报告他们在本地加噪后的感知数据（以保护其数据隐私）。用户的感知结果可靠性因而同时取决于用户的加噪处理及其移动设备自身的感知能力^[32]。此外，在保隐私数据聚合框架设计中，至关重要的一环是如何通过激励机制的设计在用户的数据隐私保护和数据聚合准确性之间获得良好的权衡。由于基于博弈论模型方案会导致系统处于质量较低的纳什均衡状态，本章选用基于拍卖机制的激励机制，其设计过程中需要解决以下四个挑战：

- **行为策略性** 由于感知数据的加噪处理由移动用户在本地完成，策略性用户会寻求向原始数据中添加尽量大的噪声以提高数据隐私保护级别。用户的行为策略性还体现在他们为了最大化自身的效用可以向平台提交偏离真实值的出价，导致感知平台需要付出更大成本以获得足够可靠的感知数据。因此，激励机制的设计需要具备诚实性的特性，并赋予感知平台对于用户数据加噪一定的控制能力。
- **网络外部性** 在相关工作^[32]中，噪声由感知平台添加到用户的感知数据中，因而用户的数据隐私完全取决于平台所添加的噪声大小。相比而言，本章中每个用户的数据隐私取决于被选择完成感知任务的用户集合以及被选用户所添加到数据中的噪声大小（请参见第2.2.3节），由此引入了负网络外部性的影响因素，使得本章中的激励机制设计更具挑战性。
- **隐私保护偏好** 在群智感知模型中，用户旨在最大化其从感知平台获取的报酬与其数据隐私成本的差值。传统情况下，只要获得的报酬可以完全弥补提供数据所产生的隐私损失，用户就会选择参与感知系统。这在本章中被称作为“消极隐私保护”情形。然而，在某些情况下用户的隐私保护行为可能会更加积极，表现在他们会对其所能获得的数据隐私保护级别有一定的要求。在这种“积极隐私保护”情形中，若感知平台

所指定的噪声水平低于某个特定阈值,则用户无论所获奖励多少都将拒绝参与感知任务。由此,我们需要针对具有不同隐私保护偏好的用户设计新颖的激励机制。

- **计算复杂度** 为了以经济且高效的方式得到具有理想精度水平的数据聚合结果,平台需要以最小的成本找到最优的用户子集来完成感知任务。由于用户数据隐私价值评估的差异以及在单重负网络外部性影响下用户间数据隐私级别所呈现的相关性,寻找最优用户子集同时达到理想的准确性是一个有约束的组合优化问题。由此,我们在问题求解中需要高效的算法设计。

为了应对这些挑战,本文提出了一种新颖的用于移动群智感知的拍卖框架,在该框架中,用户可以通过基于数据聚合方案所确定的噪声分布添加噪声来保护其数据隐私。具体的,我们考虑采用节俭机制(frugal mechanism)的设计^[65,66],以最小化平台征召用户所需的总支付为目标,同时使聚合数据满足需要的准确性。但是我们注意到,由于单重负网络外部性的影响,基于阈值的节俭机制^[65,67]无法直接应用于我们所考虑的问题,这使得机制设计更具挑战性。此外,尽管通过本地数据加噪,用户可以避免直接将原始数据暴露给不可信感知平台,然而用户所添加噪声的分布仍然是由感知平台所指定的。感知平台可以通过指定较小的噪声分布同时给予用户大量的奖励以收集到接近真实数据的用户加噪数据。为了使用户可以更大程度地控制自己的数据隐私保护级别,本章将问题的讨论范围进一步扩展到一种积极隐私保护的情况。在这种情况下,用户可以限制其最低可接受噪声级别的情况。针对这种情况本文设计了一种有效的具有诚实性属性的激励机制,其中用户的出价有两个维度,包括了他们对单位隐私成本的出价以及他们对绝对隐私级别的固有要求。在算法的开始阶段,该机制需要对用户进行额外的预筛选,用于后续对于参与用户的选择。对于积极隐私保护场景的考虑将我们提出的机制设计与移动群智感知中现有的隐私数据聚合机制^[32,33,60]区分开来。

本章的主要贡献概述如下:

- **差分隐私数据聚合** 我们基于当前学术界流行的差分隐私概念提出了隐私保护下的数据聚合方案,其主要思想是利用拉普拉斯分布的可分性质针为每个用户指定一个噪声分布。每个用户根据相应的噪声分布进行加噪后将结果报告给平台。通过使用此方案,用户对其数据隐私进行得到相应的保护平台可以在不知道用户真实感知数据的情况下,对聚合数据的噪声水平进行一定的控制。
- **单重负网络外部性** 由于我们提出的差分隐私数据聚合方案针对不同的参与用户设计的噪声分布不同,因此当感知平台选择的参与用户集合变化时,每个用户的隐私保护

级别都将发生变化,形成一种网络外部性效应。在本章的分析中我们明确刻画了用户之间的单重负网络外部性(即单一用户的隐私保护级别随参与用户增加而降低),并在激励机制设计中充分考虑到了这种联系。

- **隐私—准确性权衡** 为了保证聚合结果的准确性,如果用户汇报的感知数据具有更高的准确性(即添加的噪声较少),则平台将给予用户更多奖励。显然,在隐私保护和聚合结果准确性之间存在着一个权衡。本章使用用户添加噪声所导致的聚合结果失真来描述聚合结果的准确性,并基于差分隐私的概念刻画了用户数据隐私与聚合结果准确性之间的权衡。
- **差分隐私数据拍卖** 基于所提出的差分隐私数据聚合方案,激励机制的设计归结为解决一个将感知任务分配给一组用户并通过支付奖励换取用户敏感数据的反向拍卖问题。该拍卖以最小化用户总报酬为目标,以数据聚合结果的准确性限制为约束。本章证明了该问题的 NP 难属性。通过探索问题的结构,本章挖掘出了该问题隐藏单调性的属性,并确定了用户的临界出价。基于这些发现,本章针对问题的组合性质提出了一种计算有效的差分隐私数据拍卖方案。此外,本章证明了所提出的差分隐私数据拍卖方案具备诚实性、个体合理性,并可以得出近似最优解。通过充分的仿真实验,本章评估了所提出方案的性能表现。
- **固有隐私要求** 针对系统里存在“积极隐私保护”类型用户的情况,本章对基本的差分隐私数据拍卖方案进行了扩展。具体来说,每个用户将向平台报告其最低可接受的数据隐私级别以及其单位隐私成本,激励机制将两部分信息作为一个二维的竞价输入,并基于此确定参与用户的集合以及相应的奖励(参见第2.4节)。

本文的其余部分安排如下。第2.2节描述了用于移动群智感应系统的隐私保护数据聚合框架。第2.3节提出了激励机制,并分析了它在用户消极隐私保护情形下的特性。在2.4节中,我们将研究扩展到积极隐私保护的场景,其中用户对数据隐私级别提出了固有要求。在2.5中,我们评估了所提出的激励机制的性能。节2.6对本章进行总结。

2.2 数据隐私保护下的移动群智感知系统

2.2.1 系统概况

我们考虑一个移动群智感知系统,如图2.1所示,该系统由一个集中式平台 \mathcal{A} , 一个任务代理 \mathcal{T} 和一组参与用户 $\mathcal{N} \triangleq \{1, \dots, N\}$ 组成。该任务要求用户向平台报告其对某特定

对象或现象的本地感测数据，例如光谱感测和环境监控。由于不同用户的感测数据的可靠性可能由于传感器质量的不同而有所不同^[32]，为了提高结果的可靠性，该平台将对所有参与用户的感测数据进行聚合。与现有的基于拍卖的移动群智感知工作不同^[11,32,33,35,38,55-64]，本文允许每个用户报告其经过噪声处理后的数据，以保护其自身的数据隐私^[34]。

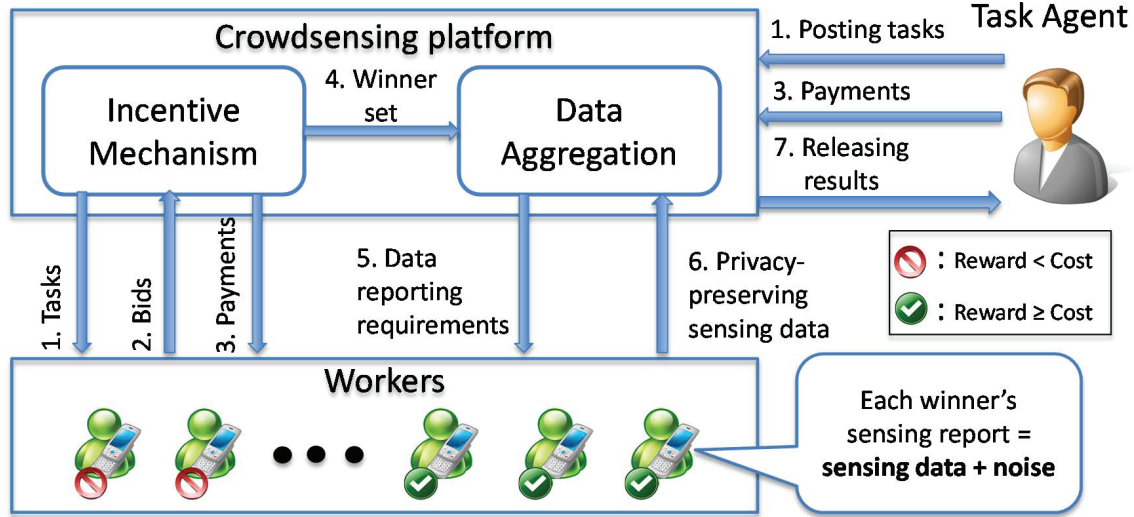


图 2.1 基于拍卖模型框架的保隐私数据聚合

具体而言，我们所提出的保隐私数据聚合流程如下（参见图2.1）：

- 首先，任务代理在群智感知平台上发布任务，然后将该任务向用户集合 \mathcal{N} 中所有 N 个用户宣布该任务（步骤 1）。
- **激励机制** 然后，平台进行拍卖以征召用户。用户首先将他们的出价提交到平台（步骤 2）。在该平台上，出价反映了用户的个人信息，例如对隐私损失的评估以及其最低可接受的数据隐私保护级别（参见2.2.2）。基于收集到的用户出价，平台确定中标者（即参与完成任务的用户）以及对参与用户的对应支付（步骤 3 和 4）。
- **数据聚合** 接下来，平台将数据加噪要求告知参与用户，并允许用户报告其感知数据的隐私保护版本（步骤 5 和 6）。
- 最后，平台将聚合结果发布给任务代理（步骤 7）。

2.2.2 群智感知拍卖模型

在群智感知系统中，平台扮演着拍卖师的角色征召移动用户完成感知任务并聚合传感数据。作为竞标者，用户将其敏感数据提供给平台，并从平台获取奖励以补偿其隐私损失。接下来，我们介绍隐私成本模型，用户模型和平台模型以及机制设计的目标。

2.2.2.1 平台模型

在拍卖开始阶段, 作为拍卖者的平台将从用户处征集出价 (见节2.2.2.2中定义)。通过运行巧妙设计的赢家选定流程和奖励确定流程, 平台输出一个任务分配结果 (\mathbf{x}, \mathbf{p}) , 其中 $\mathbf{x} = (x_1, \dots, x_N)$ 代表参与用户的集合, 而 $\mathbf{p} = (p_1, \dots, p_N)$ 表示平台向参与用户给予的奖励数额。具体来说, $x_i \in \{0, 1\}$ 表示用户 i 是否被选择参与感知任务: $x_i = 1$ 表示用户 i 被选择 (即 i 为赢家), 反之 $x_i = 0$ 表示用户 i 未被选择。据此, 我们将 \mathcal{S} 定义为由 S 个用户组成的赢家集合。对于每个用户 $i \in \mathcal{N}$, 平台将给予金额为 $p_i \geq 0$ 的奖励以收集其隐私数据, 并利用差分隐私的工具进行数据聚合 (参见节2.2.3)。平台消耗的总奖励额可以表示为 $\sum_{i \in \mathcal{N}} p_i$ 。我们将感知任务的数据聚合精度要求表示为 Δ , 其定义将在节2.3中给出。

2.2.2.2 用户模型

接下来, 我们介绍用户的隐私成本模型, 出价模型和效用函数模型。

隐私成本 在我们考虑的模型中, 用户在向平台提供其敏感感知数据时会产生隐私成本。我们使用差分隐私^[68]的理论工具来量化这种隐私成本的大小。我们令 $v_i > 0$ 表示用户 i 对单位隐私成本的估价。直观上, v_i 的值越大, 表明用户 i 在提供其感知数据时会产生更大的隐私损失。我们假设每个用户的这种单位隐私成本是不被平台或其他用户所了解的。我们令 ϵ_i 表示用户 i 的数据隐私级别 (请参见节2.2.3中的定义), 该级别由感知平台指定, 与数据扰动的噪声大小紧密相关。具体而言, ϵ_i 的值越小, 用户 i 所被允许添加到其数据上的噪声水平越高, 因而数据隐私保护级别越高。用户 i 的隐私成本 c_i 由下式给出

$$c_i = v_i \epsilon_i(\mathbf{x}). \quad (2.1)$$

该形式的隐私成本函数已在许多现有工作中被使用^[30–33]。而本文中用户隐私 ϵ_i 是 \mathbf{x} 的函数, 其不仅取决于用户自己增加的噪声, 还取决于数据聚合结果中的总噪声, 因而引入了网络外部性的因素 (参见2.2.3节)。这是本工作与移动群智感知其他工作, 例如^[32]之间的主要区别。在^[32]中, 用户的隐私成本完全取决于其自身的参与情况。

竞价模型 我们假设每个用户的单位隐私成本独立于其个人数据, 因此在竞价过程中不会泄露用户个人隐私。然而, 为了获取更大收益, 用户可能不会报告其单位隐私成本的真实价值。由于在消极隐私保护情形和积极隐私保护情形下用户在确定其数据隐私级别时的行为不同, 因此我们针对两种情形使用差异化的出价模型。在消极隐私保护的情况下, 每个用户 $i \in \mathcal{N}$ 只需将其单位隐私成本作为出价 b_i 报告给平台 (其值可能与真实值 v_i 不同)。我们令 $\mathbf{b} = (b_1, \dots, b_N)$ 表示所有用户的出价向量, \mathbf{b}_{-i} 表示除去用户 i 后的出价向量。平

台运行拍卖算法，其输出结果指定了每个用户 i 所可获得的数据隐私保护级别 ϵ_i 。用户 i 则被动地接受数据隐私保护级别并相应地进行本地噪声注入（请参见第2.2.3节）。

在积极隐私保护的情况下，我们假设每个用户 $i \in \mathcal{N}$ 对其数据隐私级别具有固有要求，一旦平台分配的隐私保护级别 ϵ_i 大于其自定义阈值 E_i ，她将选择不参与感知任务。为了实现这样的限制约束，用户 i 将报告一个对应于其单位隐私成本 v_i 和数据隐私保护级别 E_i 的出价元组 (b_i, g_i) 。

用户效用 在我们的群智感知框架中，每个用户将有噪声的数据报告给平台，同时得到报酬 p_i 以补偿其隐私费用 c_i 。我们假设用户在最大化自身收益方面是利己且具有策略性的。基于隐私成本的表达式 (2.1)，消极隐私保护用户的 i 的效用 u_i 可以被表示为：

$$u_i(b_i, \mathbf{b}_{-i}) = p_i(b_i, \mathbf{b}_{-i}) - c_i = p_i(b_i, \mathbf{b}_{-i}) - v_i \epsilon_i(\mathbf{x}), \quad (2.2)$$

对于积极隐私保护者，其效用为

$$u_i(b_i, g_i, \mathbf{b}_{-i}, \mathbf{d}_{-i}) = \begin{cases} p_i(b_i, g_i, \mathbf{b}_{-i}, \mathbf{g}_{-i}) - v_i \epsilon_i(\mathbf{x}), & \text{if } \epsilon_i(\mathbf{x}) \leq g_i, \\ -\infty, & \text{其他情况.} \end{cases} \quad (2.3)$$

其中，给定 ϵ_i 和 \mathbf{x} ， u_i 和 p_i 是出价向量的函数。在这里，非参与用户 $i \in \mathcal{N}$ （即有 $x_i = \epsilon_i = p_i = 0$ ）的效用为零。请注意，为了简化形式，我们没有显式地将执行任务的感知成本包括在效用函数中 (2.2)。而我们在本章中的结果可以很容易地通过类似文献 [38,69] 中所使用的方式扩展到包含感知成本的情况。例如，类似于 [38]，让 s_i 表示用户 i 的感知成本，我们可以将用户 i 的个体效用修改为 $u_i = p_i - s_i - \epsilon_i v_i$ ，并且定义 $p'_i = p_i - s_i$ 将感知成本引入到奖励中。

2.2.2.3 设计目标

我们旨在通过设计具备以下属性的激励机制，提出一种基于拍卖的分配机制，以使对用户的总补偿量最小，并获得令人满意的数据聚合准确性：

- **诚实性**：每个用户 i 可以通过诚实地对其隐私评估来最大化其效用，即 $u_i(v_i, \mathbf{b}_{-i}) \geq u_i(b_i, \mathbf{b}_{-i}), \forall \mathbf{b}$ 。
- **个体理性**：每个用户 $i \in \mathcal{N}$ 的效用保证为非负。根据式 (2.2) 和 (2.3)，这意味着算法所确定的补偿 p_i 和隐私级别 $\epsilon_i(\mathbf{x})$ 满足 $u_i = p_i - c_i \geq 0$ 。此外，对于积极隐私保护用户 i ，额外的约束条件 $\epsilon_i(\mathbf{x}) \leq g_i$ 需要进一步被满足。

- **成本最小化**：所设计的激励机制以最大程度地减少支付给用户的费用为优化目标。
- **计算效率**：拍卖算法可以在多项式时间内得到解 (\mathbf{x}, \mathbf{p}) 。

2.2.3 差分隐私下的数据聚合

在消极隐私保护和积极隐私保护两种情况下，为了保护数据隐私，每个拍卖的获胜者 i 都会通过添加随机噪声 n_i 到原始数据 d_i 上后报告其隐私保护版本 \hat{d}_i 。在不失一般性的前提下，我们假设所有感知数据 d_i 都是归一化在 $[0, 1]$ 范围内的值。在本文中，我们考虑对用户数据使用加权聚合运算 f 来计算得到聚合结果 r 。令 \mathbf{d} 为代表用户感知数据的向量。聚合结果 r 可以写为

$$r = f(\mathbf{d}) = \sum_{i \in \mathcal{N}} w_i (d_i + n_i) x_i = \sum_{i \in \mathcal{S}} w_i (d_i + n_i), \quad (2.4)$$

其中 $w_i > 0$ 是用户 i 的归一化权重，满足 $\sum_{i \in \mathcal{N}} w_i = 1$ 。类似于已有的一些工作^[32,70,71]，加权聚合是考虑到用户不同技能水平对聚合结果的影响。直觉上，较高的权重将分配给感知结果更可靠的用户提供的数据，这使得聚合结果更接近于真实的结果^[32,70,71]。权重的确定可以基于平台和用户已知的用户技能水平^[32]。

在本文中，我们基于著名的差分隐私^[68]概念对数据聚合中的隐私损失进行量化，并提出了以下差分隐私数据聚合定义。

定义 2.2.1 (差分隐私数据聚合). 如果对于一个聚集运算 $f: [0, 1]^S \rightarrow \mathbb{R}$ ，任何一对相邻向量 \mathbf{d} 和 $\mathbf{d}_{(i)}$ (两个向量仅在用户 i 的数据上存在差异)，以及任何聚合结果的集合 $O \subseteq \text{Range}(f)$ ，以下不等式成立：

$$\Pr[f(\mathbf{d}) \in O] \leq \exp(\epsilon_i) \Pr[f(\mathbf{d}_{(i)}) \in O], \quad (2.5)$$

则聚集运算 f 对于用户 i 是 ϵ_i -差分隐私的。其中 ϵ_i 是一个正参数，用于量化工作者 i 的数据隐私保护级别。

值得注意的是，此定义与^[68]中的定义稍有不同，在^[68]中， ϵ -差分隐私的描述是基于最坏情况下的隐私保护级别，即 $\epsilon = \sup_i \epsilon_i$ 。

一种众所周知的提供差分隐私保护的方法是将基于拉普拉斯分布生成的随机噪声添加到聚合函数 f 的计算结果上^[68]。由于在这里我们允许每个用户自己添加噪声，因此我们需要巧妙地设计每个用户的噪声分布，以使噪声的总和等价于服从拉普拉斯分布的随机噪声，即使得聚合噪声 $n = \sum_{i \in \mathcal{S}} w_i n_i$ 遵循拉普拉斯分布。

命题 2.2.2. 针对式(2.4)中的聚合函数 f , 我们定义 $s_i(f) = \max_{\mathbf{d}, \mathbf{d}_{(i)} \in [0,1]^S} |f(\mathbf{d}) - f(\mathbf{d}_{(i)})|$ 为函数 f 针对用户 i 的数据 d_i 的敏感度, σ 为拉普拉斯分布的参数。我们进而定义 $\epsilon_i = s_i(f)/\sigma$ 。我们说用户 i 在聚合运算 f 下是受到差分隐私保护的, 如果对于每一个用户 $i \in \mathcal{S}$, 在其数据上添加独立的噪声 $n_i = G_1(S, \sigma/w_i) - G_2(S, \sigma/w_i)$ 。其中 $G_1(S, \sigma/w_i)$ 和 $G_2(S, \sigma/w_i)$ 为服从伽玛分布的 *i.i.d.* 随机变量, 概率密度函数为 $g(x; S, \sigma/w_i) = \frac{1}{\Gamma(1/S)} (\frac{w_i}{\sigma})^{\frac{1}{S}} x^{\frac{1}{S}-1} e^{-\frac{w_i x}{\sigma}}$ 。

证明. 证明命题2.2.2的成立只需证明聚合后的噪声服从拉普拉斯分布。基于拉普拉斯分布^[72]的可分性, 拉普拉斯分布可以被构造为一系列 *i.i.d.* 伽玛分布的加和。根据伽玛分布的缩放定律, $w_i n_i = G_1(S, \sigma) - G_2(S, \sigma)$ 。因此, 我们有

$$\sum_{i \in \mathcal{S}} w_i n_i = \sum_{i \in \mathcal{S}} (G_1(S, \sigma) - G_2(S, \sigma)) = L(\sigma), \quad (2.6)$$

其中第二个等式来自拉普拉斯分布^[72]的可分性, 从而得出了证明结论。□

根据命题2.2.2, 如果我们针对每个用户巧妙地设计其噪声分布, 则 (2.4) 中的聚合计算 f 可以满足对于用户 i 的 ϵ_i -差分隐私保证。因此, 我们在算法1中提出了满足差分隐私保证的数据聚合机制。其中, 平台需要告知用户参数 S 和 σ/w_i 的值, 每个用户基于这两个参数产生随机噪声, 加入到原始感知数据上, 将 \hat{d}_i 报告给感知平台。具体来说, σ/w_i 的值表征了用户 i 的数据隐私保护级别 (请参见2.2.4节中的命题2.2.4)。

Algorithm 1: Differentially Private Data Aggregation

- 1: **Input:** 参与用户集合 \mathcal{S} , 每个参与用户的加权系数 $w_i, \forall i \in \mathcal{S}$, 拉普拉斯分布参数 σ .
 - 2: **Output:** 聚合结果 r .
 - 3: 对于每一个用户 $i \in \mathcal{S}$, 平台会告知其参数 $S = |\mathcal{S}|$ 和 σ/w_i 的值。
 - 4: 每个用户基于 $G_1(S, \sigma/w_i) - G_2(S, \sigma/w_i)$ 的分布生成随机噪声 n_i , 然后报告加噪后的数据 $\hat{d}_i = d_i + n_i$ 给平台。
 - 5: 平台基于式 (2.4) 对用户的数据进行聚合, 将聚合后的结果返回给任务代理。
-

备注:

- 在消极隐私保护的情况下, 用户将直接按照平台告知的参数化数据隐私保护级别生成随机噪声。相反, 在积极隐私保护的情况下, 用户对数据隐私保护级别有自定义的要求, 因而平台告知用户的噪声参数需要满足该固有要求 (请参见第2.4节中的详细讨论)。
- 在提出的数据聚合算法中, 平台不知道用户数据的真实值, 而是仅知道用户汇报的数据中所含噪声所服从的分布信息。通过这样的操作, 平台除了对用户的数据隐私提供

保护之外，还可以防止用户向他们的感知数据中添加任意大的噪声，导致聚合结果变得毫无用处。为了应对所谓的“道德风险 (Moral hazard)”问题，平台则可以对于每个用户是否遵循指定的噪声分布进行加噪处理进行监测，甚至应用一些信誉管理技术来识别不诚实的用户^[73]。另外，我们还可以通过客户端 APP 的设计强制用户按照平台指定的噪声分布完成本数据加噪。

- 对于不同的参与用户集合，平台所指定的噪声分布也有所差异。换句话说，每个参与用户的隐私保护级别一定程度上取决于参与用户集合的选择，这就引入了网络外部性的概念。这也正是本文中的激励机制设计与现有的基于拍卖机制的移动群智感知系统设计的不同之处。

2.2.4 隐私与准确性

由于系统允许用户报告加噪处理过的数据，添加到汇总结果中的噪声将不可避免地降低结果的准确性。从命题2.2.2中，我们观察到 ϵ_i 取决于 σ 的值。 σ 的值越高， ϵ_i 值越小，隐私保护效果越好。但是， σ 值越大，聚合结果的准确性越差。**很明显，用户的数据隐私保护与平台的数据聚合结果准确性之间存在自然的折衷。**为了描述准确性，我们引入失真度的概念，刻画两个聚合结果之间的差异。这其中一个聚合结果为未加噪声的基准结果，另一个为带有噪声的用户提交数据对应的聚合结果（由式 (2.4) 计算得到）。

定义 2.2.3 (失真度). 给定向量 \mathbf{x} ，我们定义失真度 $\delta(\mathbf{x})$ 为

$$\delta(\mathbf{x}) = \max_{\mathbf{d} \in [0,1]^N} \mathbb{E}[(\sum_{i \in \mathcal{N}} w_i d_i - \sum_{i \in \mathcal{N}} w_i (d_i + n_i) x_i)^2]. \quad (2.7)$$

在定义2.2.3中，失真度定义为对于任意的真实用户感知数据 \mathbf{d} ，用户报告的感知数据与真实结果的期望的最大偏差值。显然，失真度取决于参与任务的用户数量以及加入到数据中的噪声。它们之间的依赖性通过以下命题来量化。

命题 2.2.4 (隐私-失真度). 对于所有用户，给定 x_i 和 w_i 和聚合函数 (2.4)，每个用户的隐私和聚合结果的失真可以表示为

$$\epsilon_i = \frac{w_i x_i}{\sigma}, \forall i \in \mathcal{N} \quad (2.8)$$

$$\delta(\mathbf{x}) = (\sum_{i \in \mathcal{N}} w_i (1 - x_i))^2 + 2\sigma^2. \quad (2.9)$$

证明. 对于所有用户, 给定 x_i 和 w_i 和聚合函数 (2.4), 我们有

$$s_i(f) = \max_{\mathbf{d}, \mathbf{d}'_{(i)} \in [0,1]^S} |w_i(d_i - d'_i)x_i| = w_i x_i$$

. 因此, 我们有 $\epsilon_i = \frac{s_i(f)}{\sigma} = \frac{w_i x_i}{\sigma}$ 。针对于失真度, 我们有

$$\begin{aligned} \delta(\mathbf{x}) &= \max_{\mathbf{d} \in [0,1]^N} \mathbb{E}[(\sum_{i \in \mathcal{N}} w_i d_i - \sum_{i \in \mathcal{N}} w_i (d_i + n_i) x_i)^2] \\ &\stackrel{(a)}{=} \max_{\mathbf{d} \in [0,1]^N} \mathbb{E}[(\sum_{i \in \mathcal{N}} w_i d_i (1 - x_i) - \sum_{i \in \mathcal{S}} w_i n_i)^2] \\ &\stackrel{(b)}{=} \max_{\mathbf{d} \in [0,1]^N} (\sum_{i \in \mathcal{N}} w_i d_i (1 - x_i))^2 + 2\sigma^2 \\ &= (\sum_{i \in \mathcal{N}} w_i (1 - x_i))^2 + 2\sigma^2, \end{aligned}$$

其中等号 (a) 从 (2.4) 中的关系式 $\sum_{i \in \mathcal{N}} w_i n_i x_i = \sum_{i \in \mathcal{S}} w_i n_i$ 得到, 而等号 (b) 从命题 2.2.2 得到, 即 $\sum_{i \in \mathcal{S}} w_i n_i$ 是一个均值为零, 方差为 $2\sigma^2$ 的拉普拉斯随机变量。□

从命题 2.2.4 可以看出, 给定 σ , 完成任务的用户数量越多, 失真就越小; 当参与用户集合 \mathcal{S} 给定时, σ 值越高, ϵ_i 值越小 (即更好的隐私保护), 同时失真度越高。类似于文献^[30]中的处理, 我们允许用户添加具有以下参数形式的拉普拉斯噪声,

$$\sigma = \sigma(\mathbf{x}) = \sum_{i \in \mathcal{N}} w_i (1 - x_i). \quad (2.10)$$

基于 (2.10), 每个用户的隐私和聚合结果的失真度可以表示为

$$\epsilon_i(\mathbf{x}) = \frac{w_i x_i}{\sum_{i \in \mathcal{N}} w_i (1 - x_i)}, \forall i \in \mathcal{N} \quad (2.11)$$

$$\delta(\mathbf{x}) = 3(\sum_{i \in \mathcal{N}} w_i (1 - x_i))^2. \quad (2.12)$$

等式 (2.11) 和 (2.12) 中引入了负网络外部性, 用户 i 的数据隐私取决于其他用户的参与。具体而言, 参与者越多, 聚合结果失真越小, 而隐私保护越差 (即 ϵ_i 越大)。此外, 我们需要谨慎选择用户, 因为他们所具有的不同技能水平 (即 w_i), 将对失真度产生不同的贡献。此外, 由于不同用户的隐私偏好存在差异, 征召他们的成本也有所不同。因此, 寻找合适的用户来完成群智感知任务是一项具有挑战的任务。

2.3 消极隐私保护下的激励机制

在本节中, 我们研究当用户处于消极隐私保护情况下 (即对数据隐私保护级别没有内在固有要求), 数据众筹的激励机制设计。在这种假设情形下, 一旦用户的隐私损失完全被平台给予的奖励所补偿, 他们就会参与并完成感知任务。

2.3.1 数学模型

群智感知平台的目标是最大程度地减少所需向用户支付的总奖励，以使聚合结果的准确性高于某个预定阈值（即失真低于阈值参数 Δ ）。具体来说，这个问题可以表述为

$$\begin{aligned}
 & \text{minimize} && \sum_{i \in \mathcal{N}} p_i \\
 & \text{subject to} && p_i \geq b_i \epsilon_i(\mathbf{x}), \forall i \in \mathcal{N}, \text{ (个体理性约束)} \\
 & && \delta(\mathbf{x}) \leq \Delta, \text{ (准确性约束)} \\
 & && x_i \in \{0, 1\}, \forall i \in \mathcal{N}.
 \end{aligned} \tag{2.13}$$

在问题 (2.13) 中，决策变量为 $\{x_i\}_{i \in \mathcal{N}}$ 和 $\{p_i\}_{i \in \mathcal{N}}$ ，个体理性约束确保每个用户都能获得非负的效用。关于准确性约束，阈值通常将影响奖励总额和对于用户数据的隐私保护级别。在低阈值（高精度）时，平台将向用户支付更多费用以获得噪声水平较低的数据。不同于多数群智感知的现有工作，问题 (2.13) 涉及到了用户之间存在的负网络外部性影响，其直接导致用户的数据隐私保护级别之间彼此依赖，这已在节 2.2.3 和节 2.2.4 中讨论过。由于单重负网络外部性的影响，设计一种激励机制来解决问题 (2.13) 具有一定的挑战性。下面的定理 2.1 表明问题 (2.13) 是一个 NP 难问题。

定理 2.1. 群智感知拍卖问题 (2.13) 是 NP 难问题。

为了证明定理 2.1，我们首先建立问题 (2.13) 与以下问题之间的等价关系：

$$\begin{aligned}
 & \text{minimize} && \sum_{i \in \mathcal{N}} b_i \epsilon_i(\mathbf{x}) \\
 & \text{subject to} && \sum_{i \in \mathcal{N}} w_i x_i \geq W, \\
 & && x_i \in \{0, 1\}, \forall i \in \mathcal{N},
 \end{aligned} \tag{2.14}$$

其中 $W = \sum_{i \in \mathcal{N}} w_i - (\Delta/3)^{1/2}$ 。

引理 2.3.1. 问题 (2.13) 的最优解 \mathbf{x}^* 同时为问题 (2.14) 的解。

证明. 注意到当问题 (2.13) 被最小化时， p_i 应当始终等于 $b_i \epsilon_i(\mathbf{x}^*)$ 。因此，关于个体理性的约束是紧的。换句话说，最小化 $\sum_{i \in \mathcal{N}} p_i$ 等价于最小化 $\sum_{i \in \mathcal{N}} b_i \epsilon_i(\mathbf{x})$ 。接着，我们可以将约束 $\delta(\mathbf{x}) \leq \Delta$ 通过一些数学变换重写为 $\sum_{i \in \mathcal{N}} w_i x_i \geq W$ ，即可得到需要证明的结论。 \square

很容易证明问题 (2.14) 可归结为一个 NP 难的反向二进制背包问题。基于引理 2.3.1，可得到定理 2.1。

2.3.2 机制设计

根据定理2.1, 当用户集合 \mathcal{N} 较大时, 问题 (2.13) 具有较高的计算复杂度。为了解决这个问题, 我们提出了一种计算上有效的机制差分隐私数据拍卖机制 (DPDA) (见算法2和3)。该算法具有诚实性和个体理性的性质, 并且可以针对问题 (2.13) 找到一个近似最优解 \mathbf{x}^* 的参与用户集合。我们将在节2.3.3做详细讨论。算法2中的主要思路是首先找到对应于问题 (2.14) 的如下分数松弛问题的解 C ,

$$\begin{aligned} & \text{minimize} && \sum_{i \in \mathcal{N}} b_i \epsilon_i(\mathbf{x}) \\ & \text{subject to} && \sum_{i \in \mathcal{N}} w_i x_i \geq W, \\ & && 0 \leq x_i \leq 1, \forall i \in \mathcal{N}, \end{aligned} \quad (2.15)$$

我们将问题的解 C 作为目标成本, 并根据 C 通过选择总成本大于或等于 C 的最小用户集合来确定参与的用户。因为问题 (2.15) 的约束比问题 (2.14) 的约束要松弛, 因此 C 是问题 (2.14) 解的下限。为了找到最小的一组用户, 我们探索了问题2.15的解的结构。基于问题 (2.15) 和问题 (2.14) 之间的关系, 我们发现了问题的单调性属性 (参见附录中定理2.4的证明)。进而基于这种单调性属性, 我们通过逐步将用户添加到参与用户集合中直到总成本大于等于目标成本 (参见算法2中的第 6-10 行的主循环部分)。本质上, 我们希望找到最小的 k , 使得 $\sum_{i \leq k} b_i w_i / (\sum_{i \geq k+1} w_i) \geq C$, 即 $k = \min\{j : \sum_{i \leq j} b_i w_i / (\sum_{i \geq j+1} w_i) \geq C, \forall j \in \mathcal{N}\}$, 继而所有下标 $i \leq k$ 的用户属于参与用户集合中。值得注意的是, 由于负网络外部性的影响, 这种单调性属性是隐藏于问题 (2.14) 中的, 这使我们的问题比现有的移动群智感知拍卖工作更具技术难度。

在算法3中, 我们应用了拍卖理论^[67] 中的临界值方法。其思想是确定关键竞标价 b_c , 进而只选择竞标价小于 b_c 的用户作为拍卖的胜出者。具体实现时, 我们首先从用户集合 \mathcal{N} 中移除用户 i , 找出将导致该用户输掉拍卖的最小出价 (算法3中的第 5 行)。这里我们将用户的出价按升序排列。关键竞标价 b_c 即被设为所有这些投标的最高价 (算法3中的第 6 行)。使用此关键竞标价, 我们根据每个获奖者的权重确定每个获奖者的付款 (算法3中的第 8 行)。通过节2.3.3中对 DPDA 的分析, 我们可以看到算法2和3给出的解是可行的, 并且为问题 (2.13) 的近似解。

求解目标成本 C 的问题 (2.15) 为一个线性分数规划问题。为了在计算上有效地求解 C , 我们可以根据以下引理将问题 (2.15) 转换为线性规划问题。

引理 2.3.2. 问题 (2.15) 等价于以下线性规划问题：

$$\begin{aligned}
& \text{minimize} && \sum_{i \in \mathcal{N}} b_i w_i y_i \\
& \text{subject to} && \sum_{i \in \mathcal{N}} w_i y_i \geq Wz, \\
& && 0 \leq y_i \leq z, \forall i \in \mathcal{N}, \\
& && \sum_{i \in \mathcal{N}} w_i z - \sum_{i \in \mathcal{N}} w_i y_i = 1.
\end{aligned} \tag{2.16}$$

证明. 为了证明等价性，我们将证明问题 (2.15) 的任何可行解对于问题 (2.16) 也是可行的，且具有相同的函数值，同时逆命题也成立。我们注意到，如果 \mathbf{x} 为问题 (2.15) 的可行解，则 $y_i = \frac{x_i}{\sum_{i \in \mathcal{N}} w_i (1-x_i)}$, $\forall i \in \mathcal{N}$ 和 $z = \frac{1}{\sum_{i \in \mathcal{N}} w_i (1-x_i)}$ 是问题 (2.16) 的可行解，且可得到相同的目标函数值 $\sum_{i \in \mathcal{N}} b_i w_i y_i = \sum_{i \in \mathcal{N}} b_i \epsilon_i(\mathbf{x})$ 。因此，问题 (2.15) 的最优值大于或等于问题 (2.16) 的最优值。对于逆命题，首先注意到问题 (2.16) 中有 $z > 0$ 。如果 y_i 和 z 为问题 (2.16) 的可行解，则 $x_i = y_i/z$ 是问题 (2.15) 的可行解，且具有相同的目标函数值 $\sum_{i \in \mathcal{N}} b_i \epsilon_i(\mathbf{x}) = \sum_{i \in \mathcal{N}} b_i w_i y_i$ 。因此，问题 (2.15) 的最优值小于或等于问题 (2.16) 的最优值。因此，问题 (2.15) 等价于问题 (2.16)。□

基于引理2.3.2，我们可以通过求解线性规划问题 (2.16) 来求解得到 C 。而算法2的计算成本有两部分主要来源：求解线性规划 (2.16) (第 3 行) 和确定拍卖获胜者集合 (第 6-10 行)。为了有效地求解 (2.16)，我们可以对线性规划使用现有的求解器，例如 CPLEX^[74]，它可以在多项式时间内求解线性规划问题 (2.16)^[75]。确定获胜者集合则在最坏的情况下具有 $O(N)$ 的时间复杂度。因此，算法3可以在多项式时间内确定问题 (2.13) 的参与用户集合。对于每个拍卖获胜者，算法3需要运行一次算法2，即最坏情况不超过 N 次，因此也为多项式时间内可解。

2.3.3 DPDA 性能分析

在本节中，我们将证明 DPDA 是诚实的，个体理性的，并且其结果对于最优成本而言，是 α -近似的。首先，我们分析 DPDA 的诚实性。

定理 2.2. DPDA 是诚实的。

证明. 要证明 DPDA 是诚实的，只需证明用户无法通过报出偏离其真实隐私成本估值的竞价来提高其效用。在 DPDA 中，获胜者根据其出价在集合 \mathcal{N} 中的排序确定，排序越高，被选中的机会就越小。此外，由算法3所确定的关键出价并不取决于获胜者的出价。在下面的内容中，我们将讨论用户 i 使用不诚实的出价 \tilde{b}_i 的情况。

Algorithm 2: DPDA-确定参与用户集合

-
- 1: **Input:** 总用户集合 \mathcal{N} , 每个用户的权值 $w_i, \forall i \in \mathcal{N}$, 每个用户的竞价 $b_i, \forall i \in \mathcal{N}$ 。
 - 2: **Output:** 获胜者（参与用户）集合 \mathcal{S}
 - 3: 按照 $w_i b_i$ 数值的递增顺序对用户进行排序。
 - 4: 通过求解问题 (2.16) 得到目标成本 C 。
 - 5: 令 $k = 1, x_1 = 1$ 且 $x_i = 0, \forall i = 2, \dots, N$
 - 6: 令 $\mathcal{S} = \{1\}$, 计算 $C' = b_1 \epsilon_1(\mathbf{x})$ 。
 - 7: **while** $C' < C$ **do** \\\ 确定获胜者
 - 8: $k = k + 1$.
 - 9: 令 $x_k = 1$, 同时令 $\mathcal{S} = \mathcal{S} \cup \{k\}$.
 - 10: $C' = \sum_{i=1}^k b_i \epsilon_i(\mathbf{x})$.
 - 11: **end while**
 - 12: **return** \mathcal{S} .
-

Algorithm 3: DPDA-确定用户奖励

-
- 1: **Input:** 用户集合 \mathcal{N} , 用户的权值 $w_i, \forall i \in \mathcal{N}$, 每个用户的竞价 $b_i, \forall i \in \mathcal{N}$, 获胜者集合 \mathcal{S} 。
 - 2: **Output:** 用户奖励 \mathbf{p} 。
 - 3: 令 $\mathbf{p} = (0, \dots, 0)$, $b_c = b_{k+1}$, 其中 k 为集合 \mathcal{S} 中竞价最大的用户的下标。
 - 4: **for each** $i \in \mathcal{S}$ **do** \\\ 确定关键竞价
 - 5: 在集合 $\mathcal{N} \setminus \{i\}$ 上运行算法2, 得到获胜者集合 \mathcal{S}' 。令 k' 为集合 \mathcal{S}' 中竞价最高的用户的下标。
 - 6: $b_c = \min\{b_c, b_{k'+1}\}$.
 - 7: **end for**
 - 8: 对于每一个用户 $i \in \mathcal{S}$, 有奖励 $p_i = \frac{b_c w_i}{\sum_{i \in \mathcal{N} \setminus \mathcal{S}} w_i}$ 。
 - 9: **return** \mathbf{p} .
-

- 虚报高价 $\tilde{b}_i > v_i$ 。在这种情况下，用户 i 的排名可能会向后移动。首先假设用户本可以通过诚实地竞标 v_i 赢得拍卖。此时假设用户通过虚报高价仍然留在获胜者集合中，然而虚报高价并不会改变她的效用，因为算法3确定的关键出价 b_c 将保持不变；而如果由于虚报高价而被排除在参与用户集合外，则其效用即减小为零。我们再假设用户通过诚实的竞标无法赢得拍卖，那么她即使虚报高价仍然不会被选中为获胜者。因此在两种情况下，用户 i 都无法改善其效用。
- 虚报低价 $\tilde{b}_i < v_i$ 。在这种情况下，用户 i 的排名可能会在集合中向前移动。假设用户可以通过诚实地竞标 v_i 赢得拍卖，那么虚报低价的话她仍然会处于获胜者集合中，然而由于关键竞标价格保持不变，她的效用并不能提高。假设用户使用诚实的竞标会输掉了拍卖，而虚报低价可以使其被选为获胜者，则此时她的效用为 $u_i = \frac{(b_c - v_i)w_i}{\sum_{i \in N \setminus S} w_i}$ 。由于她最初不在获胜者集合中，因而有 $v_i \geq b_c$ ，而这将导致她的效用 $u_i \leq 0$ 。

因此，DPDA 是诚实的。 \square

接下来，我们分析 DPDA 的个体理性性质。

定理 2.3. DPDA 是个体理性的。

证明. 由于 $b_c \geq b_i, \forall i \in S$ ，对于获胜者集中的每个用户，我们都有

$$p_i = \frac{b_c w_i}{\sum_{i \in N \setminus S} w_i} \geq \frac{b_i w_i}{\sum_{i \in N \setminus S} w_i} = c_i,$$

对于所有输掉拍卖的用户，我们有 $p_i - c_i = 0$ 。因此，对于所有用户，我们有 $p_i - c_i \geq 0$ ，即 DPDA 具备个人理性的性质。 \square

接下来，我们分析算法 DPDA 的近似率。我们的思路是首先刻画问题 (2.15) 的最优解。其挑战主要来自问题本身所具有的单重网络外部性特征。针对这个挑战，我们剖析了问题 (2.15) 的结构，并在将问题 (2.15) 转换为一个等效问题后发现了问题隐藏的单调性属性。根据这一发现，我们证明 DPDA 满足问题 (2.13) 的结果准确性约束，并利用 DPDA 的输出与问题 (2.13) 最优解之间的关系推导出 DPDA 的近似比率。我们将结果归纳在以下定理中。

定理 2.4. DPDA 满足问题的准确性约束（即 $\delta(\mathbf{x}) \leq \Delta$ ），可以得到相对于最优成本的 α 近似解，其中 $\alpha = \frac{(b_k + C)w_k}{C \sum_{i \geq k} w_i - \sum_{i \leq k-1} b_i w_i} \geq 1$ 。

接下来，我们在“小竞标者 (Small bidder)”的假设下完善近似比率 α 。

假设 2.3.3. 在“小竞标者”的假设下，单一用户的竞价通常比求解问题 (2.16) 得到的目标成本 C 小得多，因此可以满足 $C > \beta b_{max}$ ，其中 $b_{max} = \max_i b_i$ ，而 $\beta > N$ 是一个较大的正常数。

推论 2.5. 在假设2.3.3下，DPDA 可以得到针对最优成本的 α' -近似解，其中 $\alpha' = \frac{1}{1-k/(\beta+1)} \geq 1$ 。

附录A.1中提供了定理2.4和推论2.5的证明。该结果展示了一个具体的方案，即“小竞标者”效应越显著， β 的值越大，因此我们的 DPDA 算法的性能越好。

2.4 积极隐私保护下的激励机制

在上一节所讨论的模型中，虽然用户可以在本地进行数据加噪，然而噪声级别是由平台指定的，因此用户对于其数据的隐私保护级别的控制非常有限。在本节中，我们将考虑一种积极隐私保护的场景：用户寻求一种积极主动的数据隐私保护，仅当平台所指定的隐私保护级别满足用户的固有要求时，用户才会参与并完成感知任务。我们首先介绍该场景下问题的建模，然后介绍在 DPDA 基础上所拓展得到的 EDPDA 拍卖机制，最后对其进行性能上的分析。

2.4.1 问题建模

遵循与节2.3相同的思路，我们旨在设计一种激励机制，在满足数据聚合结果准确性约束的前提下最小化平台用于征召用户的奖励总额。所设计的激励机制除具备真实性、个人理性和计算效率几个属性外，还应满足用户对于隐私保护级别的固有要求。我们重新定义优化问题 (2.13)，如下所示：

$$\begin{aligned}
 & \text{minimize} && \sum_{i \in \mathcal{N}} p_i \\
 & \text{subject to} && p_i \geq b_i \epsilon_i(\mathbf{x}), \forall i \in \mathcal{N}, \text{ (个体理性约束)} \\
 & && \delta(\mathbf{x}) \leq \Delta, \text{ (准确性约束)} \\
 & && \epsilon_i(\mathbf{x}) \leq g_i, \forall i \in \mathcal{N}, \text{ (隐私保护级别约束)} \\
 & && x_i \in \{0, 1\}, \forall i \in \mathcal{N}.
 \end{aligned} \tag{2.17}$$

在我们的讨论中，我们做以下的假设：

假设 2.4.1. 给定每个用户 $i \in \mathcal{N}$ 的出价 g_i 和权重 w_i ，平台将确定准确性约束 Δ ，以满足以下条件，

$$\Delta \geq 3(w_i/g_i)^2, i \in \mathcal{N}. \quad (2.18)$$

该假设意味着平台对于准确性的要求相对于比值 w_i/g_i 不应太小。其背后的解释是，同等条件下，在积极隐私保护场景中，由于有些用户会对隐私保护级别有较严格的要求，我们可能无法招募到一些具有高技能水平的员工（他们对于结果准确性有较大贡献），因而我们可能难以得到同被动隐私保护场景下一样高的聚合结果准确性。我们有以下引理。

引理 2.4.2. 成本最小化问题 (2.17) 在假设2.4.1下有可行解。

证明. 给定 (2.17) 中的聚合结果准确性约束，我们有 $\sum_{i \in \mathcal{N}} w_i x_i \geq \sum_{i \in \mathcal{N}} w_i - (\Delta/3)^{1/2}$ 。在隐私保护级别约束 (2.17) 的限制下，我们有 $\sum_{i \in \mathcal{N}} w_i x_i \leq \sum_{i \in \mathcal{N}} w_i - \frac{w_i x_i}{g_i}$ 。当 $\frac{g_i}{w_i} \geq \sqrt{3/\Delta}$ 满足时，易得到

$$\sum_{i \in \mathcal{N}} w_i - (\Delta/3)^{1/2} \leq \sum_{i \in \mathcal{N}} w_i - \frac{w_i}{g_i} \leq \sum_{i \in \mathcal{N}} w_i - \frac{w_i x_i}{g_i}$$

进而命题得以证明。 \square

2.4.2 机制设计

由于 (2.17) 中用户对于隐私保护级别的附加限制，节2.3中开发的激励机制无法直接应用在积极隐私保护的场景中。此外，由于在积极隐私保护场景下，用户的单位隐私成本和固有隐私级别要求都为仅用户自己知道的私人信息，因此每个用户需要提交一个二维的竞价。类似于消极隐私保护场景，由于用户的策略性行为，他们可能会使用偏离真实值的竞价。针对这种问题场景中的挑战，我们对于 DPDA 进行了扩展，得到了同样基于拍卖的激励机制 EDPDA。接下来，我们介绍问题的建模 (2.17)。我们将指出，该问题同样可以简化为反向二进制背包问题，并且基于下述引理2.4.3可以通过放松整数变量约束转换为可解的线性规划问题。

引理 2.4.3. 问题的分数松弛 (2.17) 可简化为以下线性规划问题：

$$\begin{aligned}
& \text{minimize} && \sum_{i \in \mathcal{N}} b_i w_i y_i \\
& \text{subject to} && \sum_{i \in \mathcal{N}} w_i y_i \geq Wz, \\
& && \sum_{j \in \mathcal{N}} w_j y_j + \frac{w_i}{g_i} y_i \leq \sum_{j \in \mathcal{N}} w_j z, \forall i \in \mathcal{N}, \\
& && 0 \leq y_i \leq z, \forall i \in \mathcal{N}, \\
& && \sum_{i \in \mathcal{N}} w_i z - \sum_{i \in \mathcal{N}} w_i y_i = 1,
\end{aligned} \tag{2.19}$$

其中 W 的定义与 (2.14) 中的相同。

引理2.4.3的证明参见附录A.2。

我们使用算法4中所示的贪婪算法来确定拍卖获胜者的集合。具体来说，我们首先筛选出一组隐私保护级别可以保证被满足用户（第 4-5 行）。然后，我们以问题 (2.19) 的解作为目标总成本，然后遵循算法2中所使用的相同程序，在不超出目标成本的前提下筛选出拍卖的获胜者。每个获奖者 $i \in \mathcal{S}$ 得到的奖励是通过节2.3中提出的算法3计算得到的。

Algorithm 4: EDPDA-确定参与用户集合

- 1: **Input:** 总用户集合 \mathcal{N} ，每个用户的权值 $w_i, \forall i \in \mathcal{N}$ ，每个用户的竞价 $\{b_i, g_i\}, \forall i \in \mathcal{N}$ 。
 - 2: **Output:** 获胜者（参与用户）集合 \mathcal{S} 。
 - 3: 按照 $\frac{w_i}{g_i}$ 数值的递增顺序对用户集合 \mathcal{N} 中的用户进行排序。
 - 4: 找出最大的整数 k 满足 $\frac{w_k}{g_k} \leq \sum_{i=k+1}^N w_i$ ，并定义获胜者集合 $\mathcal{S}' = \{1, \dots, k\}$ 。
 - 5: 对集合 \mathcal{S}' 中的用户按照 $b_i w_i$ 值的递增顺序进行排序。
 - 6: 通过求解问题 (2.17) 得到目标成本 C 。
 - 7: 令 $l = 1$ ， $x_1 = 1$ 且 $x_i = 0, \forall i = 2, \dots, N$
 - 8: 令 $\mathcal{S} = \{1\}$ ，计算 $C' = b_1 \epsilon_1(\mathbf{x})$ 。
 - 9: **while** $C' < C$ and $l \leq k$ **do** // 确定获胜者
 - 10: $l = l + 1$.
 - 11: 令 $x_l = 1$ ，同时令 $\mathcal{S} = \mathcal{S} \cup \{l\}$.
 - 12: $C' = \sum_{i=1}^l b_i \epsilon_i(\mathbf{x})$.
 - 13: **end while**
 - 14: **return** \mathcal{S} .
-

2.4.3 EDPDA 性能分析

我们接下来证明 EDPDA 是诚实的、个体理性的，同时满足所有参与用户对于隐私保护级别的固有要求。首先，我们分析 EDPDA 的诚实性。

定理 2.6. EDPDA 具有诚实性。

证明. 为了阐明 EDPDA 的诚实性，我们需要对单位隐私成本 v_i 和隐私约束 E_i 的不诚实出价行为进行分别讨论。对于单位隐私成本，定理2.2提供的证明足以表明用户使用不同于真实成本的出价并不会带来效用上的收益。因此在这里，我们集中讨论用户对于隐私约束的不诚实出价情况。

- 虚报高价 $\tilde{g}_i > E_i$ 。这种情况下，在算法4第4行执行完毕时用户 i 的排名可能会比诚实报价情况下向前移动。如果用户通过诚实报价 E_i 即可进入集合 \mathcal{S}' ，则排名前进不会改变其效用。而如果用户通过诚实报价 E_i 本无法进入集合 \mathcal{S}' ，依靠虚报高价虽然可能会帮助其进入集合 \mathcal{S}' ，而后续平台可能会指定一个较低的违背用户固有要求的隐私保护级别。
- 虚报低价 $\tilde{g}_i < E_i$ 。这种情况下，在算法4第4行执行完毕时用户 i 的排名可能会比诚实报价情况下向后移动。如果通过诚实报价 E_i 无法进入用户集合 \mathcal{S}' ，则排名后退后用户仍然会被排除在集合 \mathcal{S}' 外。如果用户通过诚实报价 E_i 可以进入用户集合 \mathcal{S}' ，而排名后退则可能使得其被排除在集合 \mathcal{S}' 外。

综上，可以总结得出 EDPDA 是具有诚实属性的。 \square

如果我们使用算法3确定获胜者的奖励，则 EDPDA 的个体理性属性可以使用与定理2.3相同的证明得到。接下来，我们证明 EDPDA 可以保证用户的隐私约束可以被满足。

定理 2.7. EDPDA 保证参与用户的隐私约束可以被满足。

证明. 在算法4（第3-5行）中，我们首先过滤选出了其固有隐私保护级别要求可以被满足的一组用户 \mathcal{S}' ，然后我们进一步确定获胜者集合 $\mathcal{S} \subseteq \mathcal{S}'$ 。算法在对集合 \mathcal{S}' 中的用户进行重新排序（第6行）及之后的处理中都不会违背用户的隐私保护级别要求。根据 (2.11)，对于每个获胜者 $i \in \mathcal{S}$ ，我们都有

$$\epsilon_i = \frac{w_i}{\sum_{j \in \mathcal{N} \setminus \mathcal{S}} w_j} \leq \frac{w_i}{\sum_{j \in \mathcal{N} \setminus \mathcal{S}'} w_j} \leq g_i.$$




图 2.2 不同准确性约束下的平台支付（消极隐私保护情况）

由于我们已经证明了诚实性，我们有 $\epsilon_i \leq E_i, \forall i \in \mathcal{S}$ ，即在 EDPDA 每个参与用户的隐私保护级别要求可以被满足。□

在将 DPDA 扩展至 EDPDA 后，激励机制的近似比率的推导变得更具挑战性。因此，我们将其留作我们的未来工作。

2.5 性能评估

2.5.1 仿真设置

在仿真中，我们随机生成用户的竞标价。具体的，我们从区间 $[1, 20]$ 均匀地生成用户 i 的单位隐私成本 v_i ；对于积极隐私保护场景，我们从区间 $[0.01, 0.2]$ 均匀地生成用户 i 的隐私保护级别固有要求 E_i 。我们从区间 $[1, 10]$ 均匀地随机生成每一个用户的权值，然后进行归一化处理。实验中的用户总数 N 的变化范围为 100 到 300。失真度通过预设的最大失真度 Δ_{\max} 进行归一化处理，保证 W 在不同失真度情况下总为正值。我们使用优化求解器 CPLEX^[74] 的二等分算法求解问题 (2.14) 和问题 (2.17) 的最优解。由于据我们所知，现有的群智感知激励机制研究工作尚未有考虑系统网络外部性的特征，因此在这里我们仅对 DPDA 算法和 EDPDA 算法进行评估实验。




图 2.3 数据隐私与准确性之间的关系




图 2.4 不同准确性约束下用户总量的影响（消极隐私保护情况）




图 2.5 积极隐私保护与消极隐私保护之间的结果对比（归一化失真度要求 = 0.2）

2.5.2 结果和讨论

奖励 vs. 准确性 在图2.2中，我们展现了平台总支付在不同结果准确性约束下的变化趋势。我们观察到，随着准确性约束放宽（归一化失真度要求变大），平台总支付会单调降低。其背后原因是 W 会随着 Δ 数值的增加而减少，即准确性要求放宽后平台不需要在“购买”较准确的用户隐私数据上产生过多成本。同时，我们发现对于相同水平的失真度要求，平台的总支付额随着用户总数的增加而增加。这是由于对于相同水平的失真， W 随着用户数量的增加而增加 (2.14)，使得平台必须征召更多的用户，从而导致总付款额的增加。

隐私 vs. 准确性 在图2.3中，我们阐明了数据隐私保护级别与结果准确性约束之间的关系。我们使用所有参与用户中最低的隐私保护级别（即 $\epsilon = \max_{i \in S} \epsilon_i$ ）来表示某一准确性约束（失真度要求）的系统隐私保护级别。正如我们所预期的，随着准确性约束放宽，数据隐私保护级别会有所升高（即 ϵ 越小，隐私保护级别越高），与节2.2.4中的分析相符合。实验结果同时清晰地表明积极隐私保护场景下的用户普遍会比消极隐私保护场景下的用户得到更高的隐私保护级别，而这正是由于积极隐私保护场景下的用户会对其隐私保护级别有固有的要求。

单重负网络外部性 在图2.4和图2.5中，我们阐明了单重负网络外部性的影响。如同节2.3.1中

所讨论的, 每个用户的数据隐私保护级别取决于其他用户的参与。当参与用户的数量改变时, 用户们的隐私保护级别也相应发生变化。当用户数量增加时, 平台需要征召的用户数量也随即增加以维持相同的结果准确性。因此, 我们可以从实验结果中观察到当用户总数增加时, 平台的总支付和参与的用户数量都有相应的增加。图2.4则清晰地说明了准确性要求越低(失真度水平越高), 平台总支付和参与的用户数量约少。在图2.5中, 我们进行了隐私消极保护场景和因司机及保护场景的对比。可以看到, 在给定归一化失真度和用户集大小的情况下, 两种场景下平台所需支付的总付款额几乎相同。这是由于积极隐私保护场景下参数 W 并不受用户 $i \in \mathcal{N}$ 的固有隐私级别要求 g_i 的影响。此外, 我们观察到, 积极隐私保护场景下的拍卖获胜者人数通常少于消极隐私保护场景下的获胜者人数。这是因为对隐私保护级别的固有要求使少数用户失去了参与感知任务的条件, 直接导致了用户人数的减少。因而在单重负外部性的影响下, 获胜者的数量减少了。

算法近似度 在表2.1中, 我们通过分别比较 DPDA 算法和 EDPDA 算法输出结果与相应最优值的差异来说明两个算法的性能。对于每个 N 的取值, 我们运行 100 次实验, 并且在每个实验中, 我们都会随机生成节2.5.1中提到的参数。在不同的实验设置下, 我们观察到两种算法得到的总付款都非常接近最优值, 两个算法的最大近似比约为 2。相比之下, DPDA 算法的近似率优于 EDPDA。这是因为在积极隐私保护的场景下, 平台除了要考虑成本最小化的目标外, 还须考虑用户的固有隐私保护级别要求。

表 2.1 DPDA 和 EDPDA 算法的近似率 (归一化失真度要求 = 0.2).

(a) DPDA 算法			
用户总数 N	100	200	300
平均近似率	1.88	1.85	1.85
最小近似率	1.45	1.68	1.70
最大近似率	2.21	2.23	2.08

(b) EDPDA 算法			
用户总数 N	100	200	300
平均近似率	1.98	1.89	1.86
最小近似率	1.63	1.67	1.70
最大近似率	2.75	2.27	2.08

计算复杂度 图2.6展示了算法 DPDA 的计算复杂度。对于 N 的每个取值, 我们运行 100 次实验来评估算法的平均运行时间。实验中参数按节2.5.1所述随机生成。我们实验所使用的 PC 配备有 2.7GHz Intel Core i7 处理器和 16GB RAM。在不同的设置 (即不同的失真度级

别，出价和用户权重)下，我们观察到提出的 DPDA 算法的计算时间很短，并且与问题大小近似成线性关系。




图 2.6 不同参数设置下 DPDA 的运算耗时。

2.6 本章小结

本章在拍卖机制的框架下研究了隐私保护下的移动群智感知数据聚合问题，其中群智感知平台作为拍卖者征召移动用户来完成感知任务。在此模型下，本章应用差分隐私的概念设计了一种新颖的移动群智感知系统。具体来说，本章第 2 节提出了一种允许每个用户报告带有噪声数据的数据聚合方案，其中用户所允许添加的噪声分布由感知平台决定，使得用户的数据隐私保护程度可以通过差分隐私的量化指标进行衡量。本章第 3 节进一步提出了一个具有诚实性、个体合理性，且计算效率高的激励机制 (DPDA)。该机制可以寻找一组用户，在聚合结果准确性约束下，近似地将征召移动用户所需的成本降至最低。进一步，本章第 4 节将第 3 节提出的消极隐私保护框架泛化到一种积极隐私保护的场景。在这种场景中，用户可以通过竞标最低可接受的隐私保护级别来更好地控制其数据隐私保护级别。通过理论分析和充分的数值仿真，本文验证了 DPDA 算法和 EDPDA 算法的性能。

第三章 双重网络外部性下频谱共享网络吞吐量最大化研究

本章摘要：在工业和商业场景中无线网络基础设施飞速发展的今天，无线频谱短缺问题日益凸显。而数据库辅助频谱共享则长期以来被视为解决频谱短缺问题颇有前景的解决方案之一。本章讨论了具有社交感知的数据库辅助频谱共享。其中移动用户在制定频谱共享决策时同时考虑了其与附近用户在地理位置上的耦合（负网络外部性）以及其与社交好友在社交关系上的耦合（正网络外部性）。另一方面，频谱共享网络在位置隐私保护方面的不足逐渐成为了移动用户在参与频谱共享时所关注的潜在隐患。为了应对基于 RSS（Received Signal Strength）的位置隐私攻击，本文采用了一种信号传输功率扰动的措施，允许每个次级用户巧妙地在传输功率水平上添加一个服从一定分布的负偏分量。进一步，本章第 3 节将隐私保护下的次级用户信道共享问题建模成一个随机信道选择博弈。博弈中次级用户作为策略性的玩家动态调整其策略，以最大化其社交群体效用。本章第 4 节针对提出的博弈模型设计了一个基于无悔学习规则（No-regret learning rule）的双时间尺度分布式学习算法，并证明其几乎可以肯定收敛至博弈的相关均衡集合。本章第 5 节的数值结果证实，隐私保护级别越高，网络吞吐量的下降就越显著。

关键词：频谱接入；隐私保护；分布式算法；博弈论

3.1 引言

在如今蜂窝网络频繁出现流量拥塞的现状下，如何解决爆炸性流量需求增长与有限网络资源间的冲突已经成为未来无线网络设计的主要挑战。针对这一挑战，世界各地的监管机构一直在积极研究动态频谱访问的政策法规使得频谱授权用户（主用户）和认知无线电设备（次级用户）可以实现互惠互利。在美国，联邦通信委员会（FCC）已经明确要求次级频谱用户需借助地理位置数据库来确定频谱的可用性^[76]。在这种数据库辅助的体系结构中，主用户将为数据库提供最新的频谱信息，从而无需次级用户对于未充分利用的频谱进行额外的检测^[77]。

然而可靠的数据库辅助频谱接入目前仍然面临着诸多挑战。比如，对于次级用户的频

谱接入选择至关重要的地理位置信息可以被直接或间接地关联到用户个人的敏感信息。因此如果这些信息无法得到适当的保护,将使次级用户的隐私受到严重的威胁。

学术界对于无线网络中用户位置隐私的保护已经进行了广泛的研究,其中大多数隐私保护的工作集中在网络应用层的层面^[78,79]。而针对网络物理层位置隐私攻击的相关研究仍然屈指可数。实际上,在物理层位置隐私攻击中,隐私攻击者可以在实际场景中从接收到的信号中轻松提取物理参数(例如,到达时间(TOA),到达时间差(TDOA),到达角度(AOA)和接收信号强度(RSS)^[80]),进而用来直接推断目标设备的位置。基于此观察,本章考虑一个攻击者模型,其中三个在目标用户周边不同位置的攻击者可以分别使用他们所接收到的信号的RSS观测值来估计其与目标用户之间的距离,进而应用三角定位技术(例如文献[81]中所使用的方法)完成对于目标用户的定位。

在应对物理层位置隐私攻击时,一种基本的策略是去混淆攻击者用以进行位置推断的相关信号物理参数^[48,49,82]。本章采用了一种随机功率扰动的方法来应对基于RSS观测值的定位攻击。为此,每个用户的发射功率电平会在原本给定的分量上添加一个根据特定分布采样得到的随机噪声分量。使用扰动后的功率电平发送的信号将导致攻击者在信号接收时得到不准确的RSS观测值,从而可有效降低其对于目标用户的定位精度。尽管这种功率扰动方法具有很强的实用性,但其不可避免地会导致网络性能的下降(例如,吞吐量的降低和延迟的增加)。因此,本文的主要目的是开发一种保隐私频谱共享价值,使其可以与功率扰动方法有效地结合起来使用。

除了隐私保护问题之外,实现有效的数据库辅助频谱接入时的另一个关键挑战是如何协调次级用户之间的频谱共享,从而减轻接入相同空闲信道的用户之间所产生的干扰^[83,84]。基于现实中移动设备与用户携带者相关联的事实,文献[85]的作者提出了一种名为“社交群体效用最大化”(SGUM)的博弈模型框架,用于求解具有社交关联的用户的网络效用最大化问题。在SGUM框架中,每个用户作为博弈的玩家会针对其他用户调整自己的策略以最大化包含其自身效用在内的“社交团体效用”。

本章将隐私保护下的频谱接入问题表述为一个SGUM博弈。其中,次级用户在选择信道时同时考虑了其在物理域和社交域内与其他用户之间的耦合。为了应对基于RSS的定位攻击,每个用户将使用随机噪声功率电平进行数据传输,以混淆隐私攻击者对其的定位结果。本文中通过分析博弈均衡解的特征来刻画博弈的动态特性。具体而言,本文使用了相关均衡(Correlated Equilibrium)的博弈均衡概念。相关均衡允许不同玩家的策略之间存在相关性,相比纳什均衡更具有一般性,并且有利于实际中的分布式实现^[86]。

为了在随机功率扰动影响下求解信道选择博弈的相关均衡(本文中简称为CE),本研究设计了一种双时间尺度的分布式学习算法。具体而言,在相对较大的时间尺度内,每个

移动用户根据带修正的无悔规则^[87]来对其信道选择策略进行迭代。而在相对较小的时间尺度上,用户通过一个效用学习的动态过程不断更新其对于社交群体效用的估计,以解决由功率扰动引入的群体效用所含的随机噪声,提高在较大时间尺度上策略学习的效果。我们的分析指出,当学习过程的时间尺度满足一定温和的条件时,用户的联合决策的经验概率分布可以收敛于CE的集合。仿真结果验证得出,在随机功率扰动下,我们的双时间尺度学习算法优于仅使用信道选择策略自适应的单时间尺度学习算法。同时,评估结果表明我们所提出的双时间尺度学习算法有助于实现系统吞吐量和位置隐私保护之间的权衡。

与大多数现有工作不同,本文的问题建模与求解过程中将频谱管理与用户位置隐私保护紧密地结合在一起。综上,我们的工作包含以下几点贡献:

- 我们从双重网络外部性的视角阐释了频谱共享网络中存在的物理信号干扰(负网络外部性)与社交效应(正网络外部性),并通过社交群体效用函数的定义对两种效应进行了刻画。
- 我们指出了在数据库辅助频谱接入系统中的基于RSS的位置隐私攻击隐患,并考虑了一种轻量级的功率扰动方法来降低隐私攻击者的定位精度。
- 我们通过一个隐私保护下信道选择博弈的建模来研究在动态频谱接入系统中进行位置隐私保护的问题。我们允许移动设备使用添加有扰动项的传输功率水平进行信号传输并策略性地做出信道选择决策以最大化其社交群体效用。
- 我们提出了一种基于无悔学习规则的双时间尺度学习算法。该算法弱收敛于相关均衡集合,并且在用户使用随机功率扰动的情况下可以获得优于单一时间尺度学习算法的系统吞吐量指标。

本章的其余部分安排如下。第3.2节首先介绍了隐私保护下具有社交意识的频谱共享的系统模型。第3.3节给出了用于频谱共享的SGUM博弈建模,并介绍了无悔学习规则(No-regret learning rule)。接下来,第3.4节提出了隐私保护下频谱共享的双度尺度无悔学习算法,并在第3.5节中对算法的表现进行了评估。最后,第3.6节对本章进行了总结。

3.2 位置隐私保护下的频谱共享系统模型

3.2.1 基本设置

根据FCC^[76]的规定,在数据库辅助频谱访问中,每个空白用户将首先向数据库发送频谱访问请求,然后数据库将向该用户显示在特定位置处空闲的TV信道。我们考虑这样




图 3.1 认知无线网络的社交域-地理域说明

的一个由主信道（例如电视频道）频谱集合 $\mathcal{A} = \{1, 2, \dots, M\}$ 组成的频谱接入网络。在这个网络中有一组次级用户 $\mathcal{V} = \{1, 2, \dots, N\}$ 会去尝试在信道未被主用户占用的情况下访问这些空闲的信道。具体来说，每个用户 $n \in \mathcal{V}$ 可以访问数据库公布的一个可用信道子集 $\mathcal{M}_n \subseteq \mathcal{A}$ 。显然，如果次级用户之间没有适当的协调，则可能会发生信道使用的冲突，且所产生的信道干扰会严重影响网络的性能。因此，在存在时变信道占用和干扰的环境中，数据库辅助频谱接入可以被归结为次级用户之间的动态信道分配。

参照文献^[85]，我们考虑一个具有社交意识的认知无线网络（如图3.1所示），其中每个次级用户在选择频道时都考虑了地理位置和社交关系所决定的双重网络外部性的影响。一方面，由于数据传输产生的信道干扰，次级用户在地理域中耦合，并希望通过减弱干扰来增加其传输效用。而接入同一信道的用户越多，单一用户的效用越差（负网络外部性）。另一方面，次级用户通过他们之间的社交联系在社交域中相互耦合。由于用户的大部分通信流量产生于同社交好友之间的互动，因此社交好友通信吞吐量的提升对于用户个人的效用带来非直接的正向影响（正网络外部性）。对于具有社交意识的次级用户，在进行通信时考虑与其有社交联系的其他次级用户的效用，将形成一种双赢的局面。

我们使用一个信道干扰模型来刻画设备之间的地理位置上的耦合。具体来说，我们令 $a_n \in \mathcal{M}_n$ 表示为用户 $n \in \mathcal{V}$ 所访问的信道，并将其通信链接上的信道增益表示为 $g_{nn}^{a_n}$ 。然后我们令 $g_{mn}^{a_n}$ 表示用户 $m \in \mathcal{V}$ 和用户 n 的通信链路之间在信道 a_n 上的干扰增益。我们用

N_{a_n} 表示用户 n 的链路在信道 a_n 上的噪声，对应的信噪比 (SINR) $\gamma_n(P_n)$ 可以表示为

$$\gamma_n(P_n) = \frac{P_n g_{nn}^{a_n}}{\sum_{m \in \mathcal{V}/\{n\}} P_m g_{mn}^{a_n} \mathbf{1}_{\{a_m=a_n\}} + N_{a_n}}, \quad (3.1)$$

其中 P_n 是用户 n 使用的传输功率；当用户 m 和用户 n 访问同一信道时，指示函数 $\mathbf{1}_{\{a_m=a_n\}}$ 等于 1，反之等于零。我们用 W 表示带宽，并将功率水平为 P_n 时的吞吐量定义为用户 n 的个体效用函数，即

$$U_n = W \log[1 + \gamma_n(P_n)]. \quad (3.2)$$

我们使用无向社交图 $G^S = \{\mathcal{V}, E\}$ 来对用户之间的社交耦合进行建模。其中每个顶点对应于集合 \mathcal{V} 中的一个用户，用图中无向的边表示用户之间的社交关系。特别的，我们对于联结任意两个用户 n 和 m 的边赋予一个权重 $e_{nm} \in [0, 1]$ 来量化两个用户之间社交关系的亲密程度。此外，我们所定义的权重具有以下特性： $e_{nm} = e_{mn}, e_{nn} = 1, \forall n, m \in \mathcal{V}$ 。我们使用社交群体效用模型来刻画存在社交联系的设备之间潜在的社交耦合，在这里，我们定义用户 n 的社交群体效用函数为

$$S_n = U_n + \sum_{m \in \mathcal{V}/\{n\}} e_{nm} U_m. \quad (3.3)$$

该定义中用户的个体效用刻画了用户间的负网络外部性影响，而对于社交好友个体效用的加权求和则刻画了用户之间的正网络外部性效应。

3.2.2 针对基于 RSS 的位置隐私攻击的随机功率扰动

3.2.2.1 基于 RSS 的位置隐私攻击

在这项研究中，我们考虑了一个物理层攻击者模型，该模型采用基于接收信号强度 (RSS) 的定位技术来获取目标用户的位置隐私。基于 RSS 的定位可以捕获传输的信号，并可以根据信号传播模型^[48,49] 建立距离与 RSS 之间的映射。每个攻击者可以采集一系列目标用户发射信号的 RSS 电平¹，并使用通过最大似然估计^[89] 获得距离的估计。然后，攻击者可以通过使用一组距离估计结合其自身地理位置使用三角测量的方法近似地确定目标用户的位置。

¹例如，通过采集信号 RSS 并结合 RF 指纹技术^[88]，信号接收者可以通过分析信号模拟分量中的瑕疵来识别无线网卡。

3.2.2.2 传输功率随机扰动

为了对抗基于 RSS 的位置隐私攻击，我们采用了一种本地传输功率随机扰动的方法，旨在增加攻击者定位结果的不确定性^[49]。为此，每个用户可以动态地随机改变其传输功率水平。攻击者收集到的带有噪声的 RSS 测量值会有效地扩大目标用户定位的不确定性区域，从而降低定位精度。

为了避免对主用户的额外干扰，我们限制随机功率扰动分量为负偏值。具体来说，用户 n 扰动后的传输功率可表示为 $P_n = p + \Delta p_n$ ，即常规传输功率电平 $p > 0$ 和扰动项 Δp_n 的加和。扰动项可被表示为一个服从单边截断指数分布的随机变量，其概率密度函数的表达式为

$$f(\Delta p_n | b, \bar{p}) = \frac{\frac{1}{b} \exp(\Delta p_n / b)}{1 - \exp(\bar{p} / b)}, \Delta p_n \in (-\bar{p}, 0], \quad (3.4)$$

其中 \bar{p} 表示最大扰动量。当扰动超出该范围时，将导致 SINR 过小而不满足正常数据传输的要求。参数 $b > 0$ 则刻画了用户指定的一个“平均”功率扰动水平，我们将在节 3.5 中对其做进一步讨论。

3.3 隐私保护下带有社交意识的频谱共享

在本节中，我们将频谱共享问题转换为社会团体效用最大化 (SGUM) 博弈，并介绍了无悔学习规则，该规则可以以分布式方式计算非合作博弈的相关均衡。

3.3.1 频谱共享中的社交群体效用最大化 (SGUM) 博弈

在我们的研究中，我们将系统中的每一对接收发射端视为一个用户，他们之间存在持续的策略性的交互，旨在从长远来看最大化他们各自的社交群体效用。为此，我们将隐私保护下的频谱共享问题建模为一个社交群体效用最大化 (SGUM) 博弈，每一个用户对应于博弈中的一个玩家²。每个玩家 $n \in \mathcal{V}$ 的行为空间在这里被定义为用户 n 可以接入的可用信道集合 \mathcal{M}_n 。我们令 $\mathbf{a} = (a_1, a_2, \dots, a_N) \in \mathcal{M}$ 表示所有用户的联合频谱接入选择方案，其中 $\mathcal{M} \triangleq \prod_{n=1}^N \mathcal{M}_n$ 。为了便于评估每个用户的长期社交群组效用期望，我们令 $\Delta \mathcal{M}_n$ 表示用户 n 的混合策略空间，并令 $\pi_n = (\pi(a_{n,1}), \pi(a_{n,2}), \dots, \pi(a_{n,|\mathcal{M}_n|})) \in \Delta \mathcal{M}_n$ 表示用户 n 的混合策略。其本质上可看作为是定义在 \mathcal{M}_n 上的一个概率分布，其中 $q(a_{n,i})$ 代表用户选择信道 $a_{n,i}$ 的概率。因此，所有玩家的联合混合策略可以被表示为 $\pi = (\pi_1, \pi_2, \dots, \pi_N) \in \Delta \mathcal{M} \triangleq \prod_{n=1}^N \Delta \mathcal{M}_n$ ，而按照管理除用户 n 外的其他玩家的联合策略可以表示为 $\pi_{-n} =$

²是本章中，术语上“用户”和“玩家”可以互换。

$(\pi_1, \dots, \pi_{n-1}, \pi_{n+1}, \dots, \pi_N)$ 。我们进一步令 $\pi(\mathbf{a})$ 表示联合决策 $\mathbf{a} \in \mathcal{M}$ 在博弈中出现的概率。

基于以上模型，我们将隐私保护下的频谱共享问题视为一个非合作信道选择博弈，用一个三元组 $\Gamma = (\mathcal{V}, \Delta\mathcal{M}, \{S_n\}_{n=1}^N)$ 来表示，博弈中每个玩家旨在最大化自身的期望社交群体效用。我们研究中考考虑的均衡标准是相关均衡 (Correlated Equilibrium)。由于相关均衡允许不同玩家的之间的策略存在相关性，因此可被看做是纳什均衡 (Nash Equilibrium) 的一个泛化。数学上来看，一个相关均衡对应一个凸多面体，凸面体的极值点对应于纳什均衡。因此，通常系统可以在达到相关均衡时比达到纳什均衡时获得更好的总体性能。我们在下面给出相关均衡的正式定义。

定义 3.3.1 (相关均衡). 我们称定义在 $\Delta\mathcal{M}$ 上的概率分布 π^* 为信道选择博弈 Γ 的一个相关均衡 (CE)，如果 $\forall n \in \mathcal{V}, \forall a_{n,i}, a_{n,j} \in \mathcal{M}_n$ ，社交群体效用 S_n 满足以下不等式，

$$\sum_{\mathbf{a} \in \mathcal{M}: a_n = a_{n,i}} \pi^*(\mathbf{a}) [S_n(a_{n,j}, \mathbf{a}_{-n}) - S_n(\mathbf{a})] \leq 0. \quad (3.5)$$

备注 为了获得对相关均衡更具体理解，我们可以将 π^* 看作频谱数据库提供的一个信道接入策略推荐。则对于每个用户而言，假设其他用户都遵循频谱数据库所推荐的相应均衡策略，则同样遵循频谱数据库所推荐的策略会对于该用户最有利的选择。换句话说，用户不能依靠单方面背离 CE 推荐的策略获得期望社交群体效用的提升。

定理 3.1. (CE 的存在性) 信道选择博弈 Γ 至少存在一个相关均衡 (CE)。

由于我们的信道选择博弈 Γ 中的玩家集合和策略集合都为有限集，因此属于有限博弈的范畴，继而保证存在一个非空的相关均衡集合^[86]。

3.3.2 无悔学习规则 (No-regret learning rule)

在本节中，我们简要介绍无悔学习规则，该规则是为以分布式的方式搜索非合作博弈的相关均衡而提出的^[90]。通过此规则，可以使用“遗憾度量”来量化玩家的策略调整所带来的性能收益或损失。该规则的核心思想是让每个用户从每个特定策略的遗憾中学习，目的是最小化长期的平均遗憾度量。

具体来说，对于每个用户 $n \in \mathcal{V}$ ，给定其对手的策略 \mathbf{a}_{-n} ，则截止到 t 时刻，其在当前

策略 $a_n^t = a_{n,i}$ 与某一其他策略 $a_{n,j} \neq a_{n,i}$ 下的平均群体效用之差为

$$D_n^t(a_{n,j}, a_{n,i}) = \frac{\sum_{l \leq t} S_n(a_{n,j}, \mathbf{a}_{-n}^l) \mathbb{1}_{\{a_n^l = a_{n,i}\}}}{t} - \frac{\sum_{l \leq t} S_n(\mathbf{a}^l) \mathbb{1}_{\{a_n^l = a_{n,i}\}}}{t}, \quad (3.6)$$

其中第二项量化了用户 n 在策略 $a_{n,i}$ 下截止到时间 t 时刻的平均群组效用，而第一项表明了如果用户如果在之前每次选择策略 $a_{n,i}$ 时都换为使用策略 $a_{n,j}$ 所能获得的平均群组效用。直观地来说，用户 n 会产生“遗憾”如果一个替代的策略可以带来更高的效用。在这里，我们就用 $R_n^t(a_{n,j}, a_{n,i}) = \max \{D_n^t(a_{n,j}, a_{n,i}), 0\}$ 来表示用户因未使用 $a_{n,j}$ 替代 $a_{n,i}$ 所产生的“遗憾”。

根据时间 t 时刻的遗憾度量，用户 n 将根据以下概率调整其策略，

$$\begin{cases} q_n^{t+1}(a_{n,j}) = \frac{1}{\mu} R_n^t(a_{n,j}, a_{n,i}), & \forall a_{n,j} \in \mathcal{M}_n / \{a_{n,i}\}, \\ q_n^{t+1}(a_{n,i}) = 1 - \sum_{a_{n,j} \neq a_{n,i}} q_n^{t+1}(a_{n,j}). \end{cases} \quad (3.7)$$

这里，选择某一替代策略 $a_{n,j} \in \mathcal{M}_n / \{a_{n,i}\}$ 的概率正比于相应的遗憾度量 $R_n^t(a_{n,j}, a_{n,i})$ 。我们设定参数 μ 为一个较大的值，以确保用户始终会以一定非负的概率维持当前所选择的信道。较大的 μ 值会降低切换到其他可选信道的概率，因此 μ 可以被视为一个“惯性”参数。类似的，在算法进行过程中用户不断地更新自己的遗憾度量。我们令 $f^t(\mathbf{a}) \in \Delta \mathcal{M}$ 表示联合决策 $\mathbf{a} \in \mathcal{M}$ 截止到 t 时刻的经验分布，表示为

$$f^t(\mathbf{a}) = \frac{1}{t} \sum_{l \leq t} \mathbb{1}_{\{\mathbf{a}^l = \mathbf{a}\}}. \quad (3.8)$$

根据已有结果我们知道，对于一个非合作博弈，如果玩家遵循无悔学习规则来更新其策略，则当 $t \rightarrow \infty$ 时，经验分布 f^t 会以概率 1 收敛到相关均衡的集合^[90]。

当我们尝试直接使用无悔学习规则来求解我们的随机信道选择博弈问题时会遇到了两个主要挑战。首先，由于使用了随机功率扰动程序用以保护隐私，每个用户的群体效用会因随机噪声的引入而遭到损坏，这不可避免地导致了遗憾度量的不准确，并可能导致得到的 CE 实际表现较差。

此外，根据 (3.6) 的定义，在计算未使用信道 $a_{n,j}$ 所产生的遗憾时，用户 n 需要评估先前每次使用策略 $a_{n,i}$ 时，若使用替代信道 $a_{n,j}$ 所可以获得的社交群体效用 $S_n(a_{n,j}, \mathbf{a}_{-n}^l)$ 。而这在实际中是不可行的，因为用户并不掌握其他用户的信道选择策略 \mathbf{a}_{-n} ，以及他们的群体效用函数这些系统全局信息。

为了解决这两个挑战，在下一部分中，我们将设计一种双时间尺度的学习算法，通过该算法，用户可以在相对较小的时间尺度上学习其夹带有噪声的社交群体效用，同时在相对较大的时间尺度上通过一种经过修正的无悔规则来调整其信道选择策略。

3.4 用于隐私保护下频谱共享的分布式无悔学习算法

在本节中，我们将提出一个双时间尺度的用于寻找信道选择博弈的 CE 的分布式算法，并对算法在温和条件下的长期弱收敛性进行理论上的分析。

3.4.1 双时间尺度无悔学习算法

如算法5中所述，我们设计的学习算法包括一个在相对较小和一个相对较大的学习过程。具体地，在较小的时间尺度上，每个用户会持续地在每个时间步长内基于观察到的带有噪声的效用不断更新对应于每个可用信道的群体效用期望。以这些长期更新的期望团体效用为参照，每个用户同时在相对较大的时间尺度上使用无悔学习规则来调整其策略。接下来，我们分别详细介绍两个时间尺度上的学习过程。

3.4.1.1 较小时间尺度上的效用学习

在较小的时间尺度上，用户 n 持续更新一个向量 $\mathbf{s}_n^t = (\hat{S}_n^t(a_{n,1}), \hat{S}_n^t(a_{n,2}), \dots, \hat{S}_n^t(a_{n,|\mathcal{M}_n|}))$ ，其中每个元素 $\hat{S}_n^t(a_{n,i})$ 表示在 t 时刻对于信道 $a_{n,i}$ 所对应的群体效用的估计。随着算法的推进，群体效用的估计更新如下式所示

$$\hat{S}_n^t(a_{n,i}) = (1 - \lambda^t) \hat{S}_n^{t-1}(a_{n,i}) + \lambda^t \mathbf{1}_{\{a_n^t = a_{n,i}\}} S_n^t(a_n^t), \quad (3.9)$$

其中 $0 < \lambda^t < 1$ 表示学习率。具体地，为了得到 $S_n^t(a_n^t)$ ，每个用户 n 首先观测自己受到的干扰并计算个体效用 $U_n^t(a_n^t)$ ，并查询每个用户 $m \in \mathcal{N}_n$ 所获得的效用 $U_m^t(a_n^t)$ ³，然后根据式 (3.3) 进行求和。在每次迭代 t 中，向量 \mathbf{s}_n^t 中只有元素 $\hat{S}_n^t(a_{n,i})$ 会被更新。通过这种效用学习过程，用户 n 可以渐近地形成对期望群体效用的准确评估，从而确保在较大的时间尺度所进行的策略学习最终可以收敛到 CE 的集合中。

³两个有社交关系的用户之间的信息交换可以通过一个公共控制信道来完成。

Algorithm 5: 双时间尺度分布式学习算法

-
- 1: **initialization:** 对于每个用户 n ,
 - 2: 初始化 \mathbf{s}_n^0 和遗憾度量 $R_n^0(a_{n,j}, a_{n,i}), \forall a_{n,i}, a_{n,j} \in \mathcal{M}_n$.
 - 3: 每个用户 i 以概率 $q_n^0(a_{n,i}) = \frac{1}{|\mathcal{M}_n|}$ 随机选择一个信道 $a_{n,i} \in \mathbf{a}_n$.
 - 4: 初始化学习率 λ^0 和 ϵ^0 ; 初始化参数 γ .
 - 5: **end initialization**
 - 6: **for** $n \in \mathcal{V}$ **do**
 - 7: 效用学习 (较小时间尺度):
 - 8: 观测受到的干扰并计算个体效用 $U_n^t(a_n^t)$ by (3.2).
 - 9: 查询社交邻居的个体效用并根据式 (3.3) 计算即时社交群体效用 $S_n^t(a_n^t)$
 - 10: 基于式 (3.9) 更新对于期望群体效用 $\hat{S}_n^t(a_n^t)$ 的估计
 - 11: 策略学习 (较大时间尺度):
 - 12: 基于式 (3.11) 计算即时遗憾 $Q_n^t(a_{n,j}, a_{n,i})$, 基于式 (3.10) 计算遗憾度量 $D_n^t(a_{n,j}, a_{n,i})$.
 - 13: 根据 (3.12) 更新信道选择策略 $\{q_n^t(a_n)\}$, 并基于 $\{q_n^t(a_n)\}$ 随机选择下一时刻的信道 a_n^{t+1}
 - 14: $t \leftarrow t + 1$.
 - 15: **end for**
-

3.4.1.2 较大时间尺度上的策略学习

我们对于节3.3.2中所介绍的标准无悔规则进行修正以用于较大时间尺度上的策略学习。

特别的, 每个用户 n 更新其在当前决策 $a_n^t = a_{n,i}$ 与某一其他决策 $a_{n,j} \neq a_{n,i}$ 下的平均群体效用之差如下

$$D_n^t(a_{n,j}, a_{n,i}) = (1 - \epsilon^t) D_n^{t-1}(a_{n,j}, a_{n,i}) + \epsilon^t Q_n^t(a_{n,j}, a_{n,i}), \quad (3.10)$$

其中 $Q_n^t(a_{n,j}, a_{n,i}) \triangleq [S_n(a_{n,j}, \mathbf{a}_{-n}^t) - S_n(\mathbf{a}^t)] \mathbb{1}_{\{a_n^t = a_{n,i}\}}$ 定义了时刻 t 使用了决策 $a_{n,i}$ 而不是 $a_{n,j}$ 所产生的即时遗憾。学习率 $0 < \epsilon^t < 1$ 的取值决定了无悔策略学习的时间尺度, 且应当在设置时与 λ^t 的值相对应以保证算法收敛到博弈的 CE, 这一点将在下文进一步讨论。值得注意的是, 式 (3.10) 是对式 (3.6) 的推广, 并且当学习率 $\epsilon^t = 1/t$ 时可以约简为式 (3.6)。

如上一节所提到的, 时刻 t 时, 在不知道其他用户的决策 \mathbf{a}_{-n}^t 以及他们的个体效用函数的情况下, 计算某一替代决策 $a_{n,j} \neq a_{n,i}$ 所对应的效用是非常困难的。因此, 我们使用

一种经过修正的无悔学习规则^[87]，并用估计项 $\frac{q_n^t(a_{n,i})}{q_n^t(a_{n,j})} \mathbb{1}_{\{a_n^t=a_{n,j}\}} S_n(\mathbf{a}^t)$ 来代替所需的明确群体效用，其中 $q_n^t(a_{n,j})$ 和 $q_n^t(a_{n,i})$ 分别为选择对应两个决策的概率。特别的，用户 n 将根据下式计算时刻 t 的瞬时遗憾度量：

$$Q_n^t(a_{n,j}, a_{n,i}) \triangleq \left[\frac{q_n^t(a_{n,i})}{q_n^t(a_{n,j})} \mathbb{1}_{\{a_n^t=a_{n,j}\}} - \mathbb{1}_{\{a_n^t=a_{n,i}\}} \right] \hat{S}_n^t(a_{n,i}). \quad (3.11)$$

这里我们依旧定义用户因未使用 $a_{n,j}$ 替代 $a_{n,i}$ 所产生的“遗憾”度量为 $R_n^t(a_{n,j}, a_{n,i}) = \max\{D_n^t(a_{n,j}, a_{n,i}), 0\}$ 。简单说来，遗憾度量表征了平均群体效用在决策 $a_{n,j}$ 和决策 $a_{n,i}$ 下的差异。而权值 $\frac{q_n^t(a_{n,i})}{q_n^t(a_{n,j})}$ 的作用则是对即时群体效用进行归一化，以使得式 (3.11) 中的两项具有可比性。

基于遗憾度量 $R_n^t(a_{n,j}, a_{n,i})$ ，每个用户按照下式对其策略进行更新：

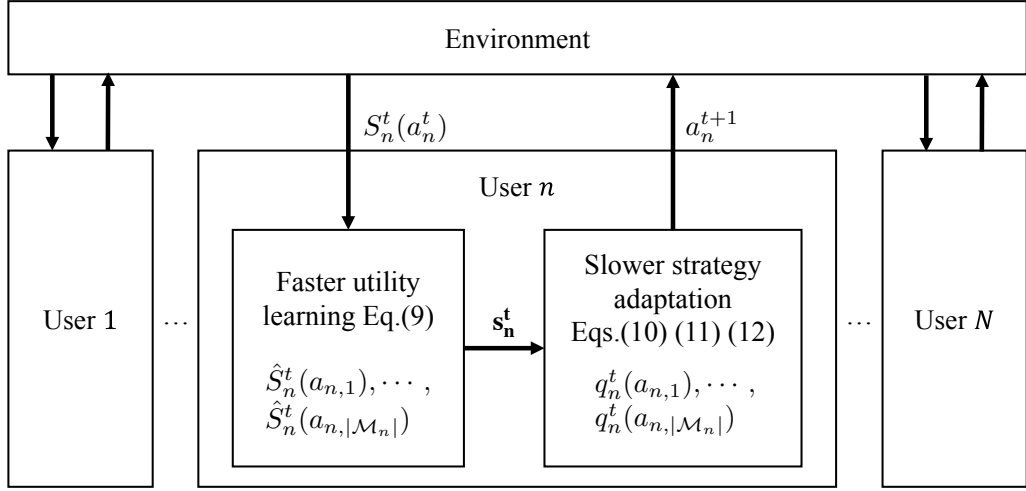
$$\begin{cases} q_n^t(a_{n,j}) = (1 - \delta^t) \min \left\{ \frac{R_n^t(a_{n,j}, a_{n,i})}{\mu}, \frac{1}{|\mathcal{M}_n|-1} \right\} + \frac{\delta^t}{|\mathcal{M}_n|}, \\ \quad \forall a_{n,j} \neq a_{n,i}, \\ q_n^t(a_{n,i}) = 1 - \sum_{a_{n,j} \neq a_{n,i}} q_n^t(a_{n,j}), \end{cases} \quad (3.12)$$

其中 $\mu > 2S_{\max}(|\mathcal{M}| - 1)$ ， S_{\max} 表示用户群组效用的上限。由于 $\frac{q_n^t(a_{n,i})}{q_n^t(a_{n,j})}$ 的数值可以无限大，为保证 $q_n^t(a_{n,i}) \geq 0$ ，我们采用加权遗憾项和 $\frac{1}{|\mathcal{M}_n|-1}$ 中的较小的一个。每个用户基于这周策略更新的规则调整其信道选择，并在下一个时间步长内继续更新其遗憾度量。

通过引入参数 δ ，我们的策略更新规则 (3.12) 实现了探索与利用 (Exploration and Exploitation) 之间的权衡。一方面，导致更大“遗憾”的替代行动将有更大的概率被选择，这可以被视为对于更好策略的充分利用。另一方面，每个替代决策都会以至少 $\frac{\delta^t}{|\mathcal{M}_n|}$ 的概率被选择，实现对于策略空间的充分探索。因此，每个决策可以被尝试足够多的次数，这是使策略学习和效用学习收敛所需要的。这里为保证策略学习的收敛性能，我们将权重参数设置为数值上递减的形式 $\delta^t = 1/t^\rho$ with $\rho < 1/4$ 。我们使用图4.1来进一步说明在任意时间步长 t 内效用学习与策略学习之间的耦合。简而言之，在提出的基于遗憾度量的双时间尺度学习算法中，用户在对其长期社交群体效用进行学习的同时，同步地进行策略上的迭代以调整到具有较高“遗憾”度量的信道选择上。在每次迭代中，每个用户都使用其维护的平均遗憾矩阵来计算瞬时遗憾度量（计算复杂度为 $O(|\mathcal{M}_n|)$ ）。接下来，我们对于所提出的学习算法的收敛性能进行评估。

3.4.2 收敛性分析

在本节中，我们分析算法5的收敛性能。我们算法的核心思想是令效用学习和基于无悔学习的策略调整在不同的时间尺度上平行地进行，从而使在较大时间尺度上运行的策略学

图 3.2 t 时刻时效用学习与策略学习之间耦合关系的示意图

习可以视为在较小时间尺度上运行的效用学习为准静态。我们将采用标准随机逼近理论在双时间尺度上的拓展来证明博弈 Γ 对于相关均衡集合的弱收敛性。以下定理给出了我们的主要结果。

假设 3.4.1. 对于每一个用户 $n \in \mathcal{V}$, 满足以下条件 **C1-C3**,

$$\mathbf{C1} : \lim_{t \rightarrow \infty} \sum_{t \geq 0} \lambda_n^t = +\infty, \quad \lim_{t \rightarrow \infty} \sum_{t \geq 0} (\lambda_n^t)^2 < +\infty. \quad (3.13)$$

$$\mathbf{C2} : \lim_{t \rightarrow \infty} \sum_{t \geq 0} \epsilon_n^t = +\infty, \quad \lim_{t \rightarrow \infty} \sum_{t \geq 0} (\epsilon_n^t)^2 < +\infty. \quad (3.14)$$

$$\mathbf{C3} : \lim_{t \rightarrow \infty} \frac{\epsilon_n^t}{\lambda_n^t} = 0. \quad (3.15)$$

定理 3.2. (算法5的收敛性) 令 $f^t \in \Delta \mathcal{M}$ 为式 (3.8) 中定义的经验分布。在满足假设3.4.1且式 (3.10) 中 $\epsilon^t = 1/t$ 的条件下, 算法5收敛到博弈 Γ 的相关均衡 (CE) 的集合 $\{\pi^*\}$, 其中 $\pi^* = (\pi_1^*, \pi_2^*, \dots, \pi_N^*) \in \Delta \mathcal{M}$ 。特别的, 我们有

$$\lim_{t \rightarrow \infty} \hat{S}_n^t(a_{n,i}) = \bar{S}_n(a_{n,i}, \pi_{-n}^*), \quad \forall n \in \mathcal{V}, \quad \forall i = 1, \dots, |\mathcal{M}_n|, \quad (3.16)$$

$$\text{and } f^t \xrightarrow{a.s.} \{\pi^*\} \text{ as } t \rightarrow \infty. \quad (3.17)$$

其中 $\bar{S}_n(a_{n,i}, \pi_{-n}^*)$ 是当用户 n 选择决策 $a_{n,i}$, 其他用户联合策略为 π_{-n}^* 时的期望社交群体效用。

定理证明的主要思想是首先引入离散学习过程 (3.9) 和 (3.10) 的连续时间插值过程。首先, 每个学习过程在数学上分别对应于一个微分包含 (differential inclusion)^[91]。而其连

续时间差值过程可被证明为对应的微分包含的半流渐近伪轨迹 (asymptotic pseudotrajectory of the semiflow)。因而, 我们可以通过微分包含来研究序列 $\{S_n(\mathbf{a})\}$ 和 $\{\pi(\mathbf{a})\}$ 的极限行为。在满足假设3.4.1的前提下, 通过结合异步随机逼近框架^[92], 我们可以获得两个并行的学习过程的渐近弱收敛结果。由于篇幅所限, 我们在线附录B.1部分提供详细的证明。

3.5 性能评估

在本节中, 我们评估了用于隐私保护下频谱共享的双时间尺度分布式学习算法的性能。

3.5.1 仿真设置

我们考虑一个数据库辅助的频谱接入网络, 该网络由 $N = 80$ 个次级用户组成, 我们假设这些用户随机分布在 $1\text{km} \times 1\text{km}$ 的正方形地理区域中。每个用户 n 对应于一个有数据发送需求的移动设备, 其默认传输功率为 $P_n = 100 \text{ mW}$ ^[76]。我们假设每个用户的可用信道集合即为总的可用信道集合, 即 $\mathcal{M}_n = \mathcal{A}$, 并设置默认的信道总数为 $M = 5$ 。我们考虑瑞利信道衰落模型, 其中用户 n 和 m 之间的信道增益反比于他们之间的物理距离 (路径损耗因子 $\alpha = 4$)。我们令 N_{a_n} 表示用户 n 使用信道 a_n 时的背景干扰功率, 并假设其数值服从区间 $[-100, -90] \text{ dBm}$ 上的均匀分布。我们假设所有的用户被随机分到两个社交群体中, 每个群体中用户 n 的权重因子 e_n 从均匀分布 $\mathcal{U}(e_{\min}, 1)$ 采样获得, 并且设置 e_{\min} 的默认值为 0.5。如节3.2.2中所述, 我们的设计中每个用户通过对其传输功率进行随机扰动以对抗基于 RSS 的定位攻击。功率扰动程度越大, 对于攻击者定位准确性的影响越显著, 继而对于位置隐私的保护作用越好。在实验中, 我们使用功率扰动的期望值 $E(\Delta p_n)$ 来量化隐私保护程度的大小。根据式 (3.4), 我们可以得出功率扰动项的期望值的表达式为 $E(\Delta p_n) = b \left[\frac{1 - (k+1)\exp(-k)}{1 - \exp(-k)} \right]$, 其中 $k = \bar{p}/b > 0$ 。我们固定 $\bar{p} = 15 \text{ mW}$ 并默认设置 $b = 12$, 以使平均功率扰动水平约为 -6mW 。对于前文提出的双时间尺度学习算法5, 我们分别设置学习率为 $\lambda^t = t^{-0.5}$ 和 $\epsilon^t = t^{-0.2}$ 。在满足条件 **C1-C3** 的前提下, 我们通过网格搜索确定超参数的取值。对于参数 ρ , 我们使用与文献^[87]中同样的设置, 即 $\rho = 1/8$ 。

3.5.2 结果与讨论

3.5.2.1 收敛表现

我们首先检查算法的收敛性能。在默认设置 $E(\Delta p_n) = -6 \text{ mW}$, $e_{\min} = 0.5$ 的条件下, 我们针对不同数量的可用信道集合进行实验, 即 $M = 4, 5, 6$ 。我们使用网络吞吐量




图 3.3 网络吞吐量的收敛表现




图 3.4 用户 #10 的策略收敛表现 (M=4)

$T = \frac{1}{N} \sum_{n \in \mathcal{V}} T_n$ 作为性能指标, 其中 T_n 表示用户 n 的平均吞吐量。从图3.3中我们观察到算法在 1500 次迭代内可以收敛, 而通道总数的增加会导致收敛时间的增长。同时可以看出, 系统可实现的最大网络吞吐量大约占网络吞吐量最优值的 90%, 且并不会受到信道集合大小变化的影响。图3.4则分别展示了任意选择的一个用户 (#10) 所对应的每一个信道的策略的收敛性表现。

3.5.2.2 关于吞吐量-隐私权衡的比较性实验

我们接下来研究在不同功率扰动水平下网络吞吐量与位置隐私之间的权衡。我们使用默认设置 $M = 5$, $e_{min} = 0.5$, 并在不同功率扰动级别下运行实验。具体来说, 我们通过

更改参数 b 的值,使得扰动功率的平均值在 0mW 至 -9mW 之间变化。为了进行比较研究,我们考虑了两个基准:(a) 单一时间尺度学习算法,该算法仅使用3.4.1.2节中所介绍的修正后的无悔学习规则进行策略上的调整而不引入对于效用的学习;(b) 双时间尺度学习算法,其中包括在较小时间尺度上对于效用的学习以及在较大时间尺度上使用随机虚拟对弈 (Stochastic Fictitious Play)^[93] 进行策略调整。

如图3.5所示,正如所预期的,系统吞吐量会随平均功率扰动水平的增加而降低。同时,很明显,使用单一时间尺度的学习算法在隐私保护级别升高时,网络吞吐量较其他两种算法相比下降得更快。这表明引入平行的效用学习来校准带有噪声的效用观测值的有效性。这也有助于我们可以在位置隐私保护与保证网络性能(即系统吞吐量)之间取得权衡。

从图3.5中还可以看出,我们所提出的基于无悔学习的双时间尺度算法所获得的平均吞吐量比使用^[93]中提出的双时间尺度学习方法所获得的平均吞吐量平均要高5%。这样的结果可以由两种方案中所使用的不同均衡标准来解释。文献^[93]中提出的算法针对的是纳什均衡。根据定义,纳什均衡假设博弈参与者的策略之间是相互独立的,而本研究中所考虑的相关均衡则允许参与者的策略之间存在相关性,因此相比纳什均衡更具一般性。由于相关平衡的集合在数学上等价于一个凸多胞形,并且凸多胞形的每一个极值点即对应于一个纳什均衡点,因此一般而言以相关均衡为考虑对象可以使得结果展现出更好的性能。




图 3.5 几种学习算法在不同功率扰动水平下的性能比较




图 3.6 社交联系强度对吞吐量的影响

3.5.2.3 网络外部性对于系统吞吐量的影响

我们最后对网络外部性对系统性能的影响进行评估。实验中我们分别针对三种网络规模（即 $N = 80, 100, 120$ ）在将社交关联强度参数 e_{min} 取值从 0.5 增加到 0.9 的过程中对系统的吞吐量进行了考察。如图3.6所示，随着系统规模的扩大，网络吞吐量呈逐步增长的趋势。另外，可以看出，系统吞吐量会随着社交关联强度的增加而单调增加。具体的，对于 $N = 80, 100, 120$ 的三种情况，当 e_{min} 从 0.5 增加到 0.9 时，系统性能分别可以获得大约 14.5%、15% 和 16.4% 的提升。这说明正向的网络外部性影响有助于提升系统的表明。

3.6 本章小节

本章关注了认知无线网络中的数据库辅助频谱共享技术，其中次级用户在双重网络外部性的作用下分别在社交域和物理域中都存在相互耦合。针对潜在的基于 RSS 的位置隐私攻击，次级用户使用随机功率扰动的方法来降低攻击者的定位精度。本文将隐私保护下具有社会意识的频谱共享建模为次级用户之间的随机信道选择博弈。基于无悔学习的规则，本文设计了一种双时间尺度的分布式学习算法。算法中，每个用户持续对自己带有噪声的期望社交团体效用进行估计，并根据降低遗憾度量的目标调整其信道选择策略。本文所提出的算法具有针对相关均衡集合的弱收敛性。数值结果证实较高的隐私保护级别将导致更严重的网络吞吐量下降。

第四章 双重网络外部性下移动数据服务提供商收益最大化研究

本章摘要：移动社交网络极大地增强了人们的在线社交互动，产生了海量的移动数据流量，为无线服务提供商带来了可观的收入。然而，潜在的收入增长正面临着通信基础设施网络容量的限制，以及服务提供商之间竞争的影响。本章研究了竞争性数据服务市场中多个服务提供商的定价策略，其中移动用户的数据消费行为受到两方面因素的影响：社交效应（正网络外部性）和拥塞效应（负网络外部性）。为了分析移动用户和服务提供商之间的策略互动，我们设计了一个两阶段的斯塔克伯格博弈，分别由第一阶段的提供商博弈和第二阶段的用户博弈组成。针对用户博弈，本章刻画了均衡解的特征并建立了它的唯一存在性。对于提供商博弈，本章的分析表明，在提供商行为理性的场景以及提供商行为有限理性的场景下，混合策略均衡解的存在性都是有所保证的。进一步，本章提出了一种分布式学习算法，用于寻找混合策略均衡解决方案。本章第 6 节的数值仿真结果对于社交效应和拥塞效应如何影响系统性能提出了见解，并验证了提供商有限理性行为为其收益带来的损失。

关键词：移动社交网络；网络定价；网络外部性；博弈论；展望理论

4.1 引言

在过去的十年中，人们对于移动智能设备的使用量经历了巨大的增长。对于不同背景和年龄的人群，移动智能设备如今已然成为他们日常生活中不可或缺的一部分。近年来，智能设备的普及也同时给在线社交网络（例如 Facebook^[12]，Twitter^[13]）带来了巨大成功，极大地促进了人们的在线社交互动。统计数据显示，由于智能设备和在线社交网络的激增，全球移动社交用户数量早在 2017 年 1 月就已超过 25 亿，占社交媒体用户总数的 91%^[94]。

移动社交用户的激增不仅为社交网络平台带来了丰厚的利润，而且还为无线服务提供商带来了可观的收入。直观上，如今市场上众多经过精心设计的移动社交应用程序，使得人们可以随时随地与他们现有的朋友或未曾相似的用户进行在线互动（通过互发信息，多媒体共享和在线游戏等方式）。在这种正网络外部性作用^[15]下，用户间社交关系的增强与

扩展会反过来激发更多数据流量消费。例如,市场调研结果表明,如果某个手机游戏在一个用户的社交好友圈中非常受欢迎,那么该用户通常也会更喜欢玩该游戏。心理学上对这种潜在影响的分析为:个体通常希望自己可以被视为同伴中的一部分。这种正网络外部性可以在整个移动社交网络中广泛传播,从而导致数据使用量整体激增,为无线提供商带来可观的潜在收入。然而与此同时,无线通信网络的有限容量已逐渐成为正网络外部性下流量增长的主要制约。以在线手机游戏平台为例,由于无线通信带宽有限,在每天高峰时间段,活跃用户数量的增加以及所产生的累积数据流量时常导致数据传输的拥塞与服务的延迟。这种负网络外部性效应下用户体验上的影响将降低那些对延迟较为敏感的用户活跃度,给服务提供商带来收入上的损失。

使用合理的定价机制是一种重要的网络流量调控手段。传统通信网络中的定价问题已经在文献^[95-99]中得到了较好的解决。对于移动无线通信网络中的定价问题,一些研究工作也已经将用户数据使用行为所受到的正网络外部性影响考虑进来^[100-102]。近期,Gong等^[103]对单一服务提供商的无线数据服务市场中移动用户在网络效应和拥塞效应下数据消费行为进行了研究。然而在一些现实场景中,移动用户已经不再局限于单个服务提供商,而是可以选择从多个无线服务提供商购买服务¹。另一方面,实际中的一些迹象表明个体决策通常会偏离期望效用理论(Expected Utility Theory)框架^[105]所预期的理性决策。在行为经济学领域进行的一些现有研究工作^[106]指出,个体的非理性行为时常归因于以下事实:当面对竞争和不确定性时,不同的个体会对他们的风险和收益进行不同且主观的评估。基于以上的观察与发现,本章考虑了多个服务提供商策略性争夺无线服务市场份额的问题场景,研究了在双重网络外部性效应下服务提供商以最大化其业务收益为目标的定价机制设计问题,并在建模中对于提供商的一些非完全理性行为进行了充分的考量。

简而言之,本章研究了一个具有多个服务提供商的竞争型无线数据服务市场,其中移动用户在确定其数据使用量时同时考虑两方面因素的影响,即对应于正网络外部性的社交效应以及对应于负网络外部性的拥塞效应。本文使用斯塔克伯格(Stackelberg)博弈^[2]的模型将提供商定价问题与用户数据使用问题结合起来进行建模。当博弈中服务提供商和个人用户的策略行为达到均衡状态时,任何独立的个体无法通过改变其策略获得更好的自身效用。对于刻画用户博弈均衡时的一个挑战在于每个用户的策略空间为多维空间(每个用户可以同时选用多个服务提供商的数据服务)。为了应对这一挑战,本文将连接任一用户和任一提供商的链接视为一个“虚拟用户”,并相应地对于每个“虚拟用户”的数据使用量进行考量。具体来说,在博弈的第一阶段,提供商会审慎地对其数据服务的单价进行设置以最

¹例如,在美国,移动用户可以通过订阅例如 Google 的 Project Fi^[104] 这样的虚拟网络运营商来使用 T-mobile 和 Sprint 的数据服务。

大程度提高其潜在收益。在博弈的第二阶段中, 给定每个提供商的单位数据服务价格, 每个“虚拟用户”会策略性地确定其数据使用量, 以优化其自身所获得的效用。在满足一定条件时, “虚拟用户”之间博弈均衡解的存在性以及唯一性可以被证明。在此基础上, 可以进一步证明提供商定价博弈中 ϵ -混合策略价格均衡的存在性。

为了描述有限理性提供者的定价决策行为, 本章第 5 节应用展望理论^[8]对第一阶段提供商之间的定价博弈作了进一步分析研究。作为诺贝尔经济学奖获奖理论, 展望理论被用以模拟和解释存在风险和不确定性下的个人决策^[52,53], 并已被应用于一些实际问题场景中。本文主要考虑了展望理论所涉及的两个主要现象: 概率失真效应和效用框架效应。本章的分析表明, 在这两种效应影响下, 给定一定条件, ϵ -混合策略定价均衡仍然存在。由于这种情况下服务提供商的收益函数不再被假设为已知信息, 本文诉诸于分布式学习算法, 使得服务提供商通过观察到的部分信息可以学习得到 ϵ -混合策略的定价均衡。数值结果表明, 提供商的有限理性行为最终会导致其期望收入的下降。

本章的剩余部分组织如下。第4.2节描述了无线服务提供商和移动用户之间的两阶段斯塔克伯格博弈的基本建模。第4.3节研究了针对用户之间流量使用的用户博弈, 并描述了博弈的联边需求均衡解。第4.4节对提供商之间的定价博弈进行讨论和分析。最后, 第4.5节从展望理论的角度重新审视了服务提供商之间的定价博弈问题。相关的数值仿真结果在第4.6节中给出, 第4.7节对本章进行了总结。

4.2 社交关系影响下移动数据的价格竞争

在本节中, 我们首先提出了无线数据服务的寡头市场模型, 在该模型中, 互相之间具有社交关系的移动用户可以从一组服务提供商那里购买和使用数据服务。我们使用两阶段的斯塔克伯格博弈对提供商和用户之间的交互进行建模。我们接下来对建模进行具体介绍。

4.2.1 系统模型

我们考虑一组移动用户 $\mathcal{N} \triangleq \{1, \dots, N\}$ 从一组无线服务提供商 $\mathcal{K} \triangleq \{1, 2, \dots, K\}$ 那里购买使用具有可替代性的无线数据服务²。每个用户可以从一个以上的服务提供商那里购买服务, 其中用户 i 从服务提供商 k 消费的数据量 (由 x_i^k 表示)。我们令 $\mathbf{X} \in \mathbb{R}^{N \times K}$ 表示所有用户的使用情况, 用 \mathbf{X}_{-i} 表示排除用户 i 后剩余用户的使用情况。

²此处可替代性意味着使用来自不同服务提供商的等量数据对于用户来讲具有相同价值。

我们假定移动用户之间存在社交关联，并使用社交联系量 $g_{ij} \in [0, 1]$ 来量化用户 j 对用户 i 的社交影响。而社交影响所引发的正网络外部性使得移动用户随着其社交朋友数据使用量的增加获得更多的效用。另一方面，随着用户整体数据消耗的增加，拥塞效应（例如，服务延迟现象）作为一种负网络外部性效应将变得尤为显著。由此，本章在建模时所需要明确地将每个移动用户的个人效用分成四部分：固有效用，数据使用成本，社交效应和拥塞效应。具体来说，给定每个提供商收取的单位服务价格，用户 i 的单个效用可以写为

$$\begin{aligned}
 u_i(\mathbf{x}_i, \mathbf{X}_{-i}, \mathbf{p}) = & \underbrace{a_i \sum_{k \in \mathcal{K}} x_i^k}_{\text{固有效用}} - \underbrace{\frac{1}{2} b_i (\sum_{k \in \mathcal{K}} x_i^k)^2}_{\text{数据使用成本}} - \underbrace{\sum_{k \in \mathcal{K}} p_k x_i^k}_{\text{数据使用成本}} \\
 & + \underbrace{\sum_{k \in \mathcal{K}} x_i^k \sum_{j \in \mathcal{N}} g_{ij} \sum_{m \in \mathcal{K}} x_j^m}_{\text{社交效应 (正网络外部性)}} - \underbrace{\frac{c}{2} \sum_{k \in \mathcal{K}, x_i^k > 0} (\sum_{j \in \mathcal{N}} x_j^k)^2}_{\text{拥塞效应 (负网络外部性)}}, \quad (4.1)
 \end{aligned}$$

其中 $\mathbf{x}_i = (x_i^1, x_i^2, \dots, x_i^K)$ 表示用户 i 的使用情况，而 $\mathbf{p} = (p_1, \dots, p_K)$ 表示所有服务提供商的定价策略，其中 p_k 表示来自提供商 $k \in \mathcal{K}$ 的数据服务单价。同工作^[103]和工作^[101]相同，我们采用了二次函数形式的内在效用函数，其对类型广泛的一些凹函数来说是很好的二阶近似。具体来说， $a_i > 0$ 和 $b_i > 0$ 是两个内在系数，用于表征使用数据服务对于用户 i 的固有效用。双重网络外部性中的社交效应被建模为来自用户 i 的总数据需求量的线性函数，因而其边际效用取决于其社交好友的总数据使用量乘以对应社会联系的加权总和（即 $\sum_{j \in \mathcal{N}} g_{ij} \sum_{m \in \mathcal{K}} x_j^m$ ）。而对于双重网络外部性中的拥塞效应，本文建模中假设用户从单个服务提供商处所受到的拥塞影响与该服务提供商的总数据流量的平方成正比，其中参数 $c > 0$ 用以刻画物理通信介质的状况。用户受到的总拥塞影响是其受到各服务提供商拥塞影响的总和。

对于每个服务提供商 $k \in \mathcal{K}$ ，我们令 q_k 表示其单位服务成本，并将其收入 v_k 表示为其收到的总付款减去她产生的总服务成本，

$$v_k = p_k \sum_{j \in \mathcal{N}} x_j^k - q_k \sum_{j \in \mathcal{N}} x_j^k, \quad \forall k \in \mathcal{K}, \quad (4.2)$$

其中 p_k 由提供商 k 通过从包含 M_k 个不同价格水平的离散价格空间 $\mathcal{P}_k \triangleq \{p_k^1, p_k^2, \dots, p_k^{M_k}\}$ 中选择一个值来确定。所有服务提供商的联合价格空间定义为 $\mathcal{P} \triangleq \prod_{k \in \mathcal{K}} \mathcal{P}_k$ 。图4.1展示了系统模型以及服务提供商和移动用户之间的交互关系。简单来说，服务提供商通过策略性地制定服务价格来争夺数据需求大的移动用户。而在给定提供商的服务定价后，自利的移动用户需要在社交效应和拥塞效应的影响下决定其数据使用情况。在下一部分中，我们将介绍问题的博弈论表述。




图 4.1 系统模型以及服务提供商和移动用户之间的交互关系示意图。

4.2.2 斯塔克伯格博弈建模

在本节中，我们将提供商定价-用户数据使用的问题建模为一个两阶段的斯塔克伯格博弈。服务提供商通过阶段 I 中的非合作博弈来确定其服务定价，而其定价策略是基于第二阶段子博弈中用户之间的子博弈所确定的。与文献 [103] 中考虑的垄断市场不同，在我们的案例中，每个移动用户的战略空间都是多维的，这给刻画用户博弈的均衡解增添了挑战。针对这一挑战，我们把联结一个移动用户和一个服务提供商的链接视为一个虚拟玩家，并将用户之间的数据使用问题视为虚拟玩家（链接）间的非合作博弈。我们令 $\mathcal{L} \triangleq \{(i, k)\}_{i \in \mathcal{N}, k \in \mathcal{K}}$ 表示 $L = N \times K$ 个链接的集合。虚拟玩家 (i, k) 的纯策略是指流经链接 (i, k) 的数据量 x_i^k ，而玩家 (i, k) 的收益对应于 u_i （即始于同一用户的虚拟玩家具有相同的收益）。进而链接 (i', k') 对链接 (i, k) 的社交效应可以通过用户 i 和 i' 之间的社交联系量 $g_{ii'}$ 来表征。我们令 $\mathbf{x} = (\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_K)$ 表示所有链接上的数据使用量，并用 $\mathbf{x}_{-(i, k)}$ 表示排除联结 (i, k) 后其他链接上的数据使用量。两阶段博弈的定义如下：

定义 4.2.1 (两阶段提供商定价-用户数据使用博弈).

- 阶段 I (提供商定价博弈 $\mathcal{G}_P \triangleq \{\mathcal{K}, \mathcal{P}, \{v_k\}_{k \in \mathcal{K}}\}$):

在用户（链接）数据使用量为 \mathbf{x} 的情况下，给定其他提供商的定价策略 \mathbf{p}_{-k} ，每个提

供应商 $k \in \mathcal{K}$ 选择 p_k 来最大化其收入 v_k 。定价博弈的均衡解可表示为一个联合定价策略 $\mathbf{p}^* = (p_1^*, \dots, p_K^*)$ 满足下式

$$p_k^* = \arg \max_{p_k \in \mathcal{P}_k} v_k(p_k, \mathbf{p}_{-k}^*, \mathbf{x}), \forall k \in \mathcal{K}. \quad (4.3)$$

- 阶段 II(用户数据使用博弈 $\mathcal{G}_U \triangleq \{\mathcal{L}, \mathbb{R}_+^L, \{u_i\}_{i \in \mathcal{N}}\}$):

给定提供商的定价策略 \mathbf{p} 和其他链接的数据使用量 $\mathbf{x}_{-(i,k)}$, 每个链接 $(i, k) \in \mathcal{L}$ 选择从服务商 k 处使用量为 x_i^k 的服务以最大化其收益 u_i 。用户数据使用博弈的均衡解可表示为 $\mathbf{x}^* = (\mathbf{x}_1^*, \mathbf{x}_2^*, \dots, \mathbf{x}_K^*)$, 这种情况下任何用户都无法通过单方面更改其使用量来增加其个人收益:

$$x_i^{k*} = \arg \max_{x_i^k \in \mathbb{R}_+} u_i(x_i^k, \mathbf{x}_{-(i,k)}^*, \mathbf{p}), \forall i \in \mathcal{N}. \quad (4.4)$$

当博弈问题处于均衡解时任何参与博弈的玩家单方面偏离其均衡策略的行为都将导致其自身的收益降低。按照惯例, 我们采用反向归纳法^[2] 来分析斯塔克伯格博弈。我们首先来研究阶段 II 中的数据使用博弈。

4.3 用户数据使用博弈中的联结需求均衡

在本节中, 我们将在给定服务提供商定价策略的情况下研究提供商-用户链接的数据使用需求。根据公式 (4.1) 和一阶条件 $\frac{\partial u_i}{\partial x_i^k} = 0$, 我们获得了链接 (i, k) 的最佳响应函数为

$$\mathbf{B}_i^k(\mathbf{x}_{-(i,k)}) = \max \left\{ 0, \frac{a_i - p_k}{b_i + c} - \frac{b_i \sum_{k' \neq k} x_i^{k'}}{b_i + c} + \frac{\sum_{j \neq i} g_{ij} \sum_{m \neq k} x_j^m}{b_i + c} + \frac{\sum_{j \neq i} (g_{ij} - c) x_j^k}{b_i + c} \right\}. \quad (4.5)$$

根据 (4.5), 每个链接的最佳响应包括两部分: 独立于其他链接的内在需求 $\frac{a_i - p_k}{b_i + c}$, 和取决于其他链接的外部需求 $-\frac{b_i \sum_{k' \neq k} x_i^{k'}}{b_i + c} + \frac{\sum_{j \neq i} g_{ij} \sum_{m \neq k} x_j^m}{b_i + c} + \frac{\sum_{j \neq i} (g_{ij} - c) x_j^k}{b_i + c}$ 。具体来说, 对于外部需求, 第一项 $-\frac{b_i \sum_{k' \neq k} x_i^{k'}}{b_i + c}$ 表征了其他同样始于用户 i 的链接对链接 (i, k) 的负面影响, 这体现了使用除去提供商 k 以外的其他提供商的数据服务将削弱对于服务提供商 k 的数据使用。第二项 $\frac{\sum_{j \neq i} g_{ij} \sum_{m \in \mathcal{K}} x_j^m}{b_i + c}$ 刻画了联结除用户 i 和提供商 k 的其他链接对于 (i, k) 所产生的正面网络外部性影响。第三项中的系数 $\frac{g_{ij} - c}{b_i + c}$ 则刻画了与提供商 k 连接的其他链接对链接 (i, k) 上需求的边际影响。显然, 如果社会效应主导了拥挤效应 (即 $g_{ij} \geq c$), 则边际影响是正面的; 而如果拥塞效应占主导地位 (即 $g_{ij} < c$), 则边际影响为负面的。




图 4.2 包含三个服务提供商和四个移动用户的系统示意图，系统中存在 9 条链接。

4.3.1 联结需求均衡的存在性与唯一性

我们首先讨论用户博弈中链接需求均衡的存在性。在不失一般性的前提下，我们仅关注数据使用量大于零的链接，而那些具有零使用量的链接在策略求解中是冗余的。令 \mathcal{L}^+ 表示具有正数据使用量的链接集合，即 $x_i^k > 0, \forall (i, k) \in \mathcal{L}^+$ 。我们定义 $\tau: \mathcal{L}^+ \rightarrow (1, 2, \dots, L^+)$ 为一个映射使得 $\tau(i, k)$ 使用索引 $l \in \{1, \dots, L^+\}^3$ 对链接 $(i, k) \in \mathcal{L}^+$ 进行标记。为了方便起见，我们令 $\mathbf{u}^+ = (u_1^+, \dots, u_{L^+}^+)$ 表示效用向量，其中 $u_{\tau(i,k)}^+ = u_i$ ， $\mathbf{x}^+ = (x_1^+, \dots, x_{L^+}^+)$ 表示使用向量，其中 $x_{\tau(i,k)}^+ = x_i^k$ ， $\mathbf{p}^+ = (p_1^+, \dots, p_{L^+}^+)$ 表示价格向量，其中 $p_{\tau(i,k)}^+ = p_k$ 表示链接 (i, k) 和 $\mathbf{a}^+ = (a_1^+, \dots, a_{L^+}^+)$ 表示系数向量，其中 $a_{\tau(i,k)}^+ = a_i$ 表示链接 (i, k) 的固有系数。我们通过图 4.2 中的示例说明了注释规则，其中系统由三个服务提供商和四个移动用户组成。因此，我们有 $L^+ = |\mathcal{L}| = 9$ ， $\mathbf{a}^+ = (a_1, a_1, a_1, a_2, a_2, a_3, a_3, a_3, a_4)$ ，和 $\mathbf{p}^+ = (p_1, p_1, p_1, p_2, p_2, p_3, p_3, p_3, p_4)$ 。

接下来，我们通过引理 4.3.1 证明用户数据使用博弈 $\mathcal{G}_U^+ \triangleq (\mathcal{L}^+, \mathbb{R}_+^L, \{u_i\}_{i \in \mathcal{N}})$ 的链接需求均衡解是最佳响应函数 (4.5) 所对应的以下线性互补问题 (LCP)^[107] 的解。

³ $\forall i, i' \in \mathcal{N}$ ，如果 $i < i'$ 则 $\tau(i, k) < \tau(i', k)$ ； $\forall k, k' \in \mathcal{K}$ ，如果 $k < k'$ ，则 $\tau(i, k) < \tau(i, k')$ 。

引理 4.3.1. 给定价格向量 \mathbf{p}^+ , 联合数据使用量 $\mathbf{x}^{+*} \in \mathbb{R}_+^{L^+}$ 是博弈 \mathcal{G}_U^+ 的一个链接需求均衡当且仅当 \mathbf{x}^{+*} 是如下定义的线性互补性问题 $LCP(W, \mathbf{x}^+)$ 的解:

$$\begin{cases} \mathbf{x}^+ > 0 \\ \mathbf{a}^+ - \mathbf{p}^+ - W\mathbf{x}^+ \leq 0 \\ (\mathbf{x}^+)^T(\mathbf{a}^+ - \mathbf{p}^+ - W\mathbf{x}^+) = 0 \end{cases}, \quad (4.6)$$

其中 W 是 $L^+ \times L^+$ 维的加权邻接矩阵, 其中位于 $\tau(i, k)$ 行 $\tau(i', k')$ 列中的元素定义为如下:

$$w_{\tau(i, k), \tau(i', k')} = \begin{cases} b_i + c, & \text{if } i = i', k = k'; \\ b_i, & \text{if } i = i', k \neq k'; \\ c - g_{ii'}, & \text{if } i \neq i', k = k'; \\ -g_{ii'}, & \text{if } i \neq i', k \neq k'. \end{cases} \quad (4.7)$$

首先, 我们声明用户数据使用博弈存在一个链接需求均衡解。

定理 4.1. 对于用户数据使用博弈 \mathcal{G}_U^+ 存在至少一个链接需求平衡 \mathbf{x}^{+*} 。

上述定理的证明并不复杂。由于一组链接的最佳响应定义了一个从凸紧致欧氏子空间到自身的映射, 因此我们可以使用 **Brouwer** 不动点定理证明链接需求均衡的存在。

接下来, 基于引理4.3.1, 我们来证明在以下条件下链路需求均衡的唯一性。

定理 4.2. 矩阵 W 在满足对角优势条件情况下, 即 $\forall (i, k) \in \mathcal{L}$,

$$\begin{cases} w_{\tau(i, k), \tau(i, k)} \geq \sum_{(i', k') \in \mathcal{L}/(i, k)} |w_{\tau(i, k), \tau(i', k')}|, \\ w_{\tau(i, k), \tau(i, k)} \geq \sum_{(i', k') \in \mathcal{L}/(i, k)} |w_{\tau(i', k'), \tau(i, k)}|, \end{cases} \quad (4.8)$$

用户数据使用博弈 \mathcal{G}_U^+ 存在以下唯一的链接需求均衡,

$$\mathbf{x}^{+*} = W^{-1}(\mathbf{a}^+ - \mathbf{p}^+). \quad (4.9)$$

证明. 为了证明链接需求均衡的唯一性, 我们证明用户数据使用博弈 \mathcal{G}_U^+ 在满足条件 (4.8)

的情况下属于凹博弈。收益函数 $\mathbf{u}^+(\mathbf{x})$ 的雅克比矩阵 $\nabla \mathbf{u}^+(\mathbf{x})$ 如下所示,

$$\begin{aligned} \mathbf{X} &= \begin{bmatrix} \frac{\partial^2 u_1^+(\mathbf{x}^+)}{\partial x_1^{+2}} & \frac{\partial^2 u_1^+(\mathbf{x}^+)}{\partial x_1^+ \partial x_2^+} & \cdots & \frac{\partial^2 u_1^+(\mathbf{x}^+)}{\partial x_1^+ \partial x_{L^+}^+} \\ \frac{\partial^2 u_2^+(\mathbf{x}^+)}{\partial x_2^+ \partial x_1^+} & \frac{\partial^2 u_2^+(\mathbf{x}^+)}{\partial x_2^{+2}} & \cdots & \frac{\partial^2 u_2^+(\mathbf{x}^+)}{\partial x_2^+ \partial x_{L^+}^+} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 u_{L^+}^+(\mathbf{x}^+)}{\partial x_{L^+}^+ \partial x_1^+} & \frac{\partial^2 u_{L^+}^+(\mathbf{x}^+)}{\partial x_{L^+}^+ \partial x_2^+} & \cdots & \frac{\partial^2 u_{L^+}^+(\mathbf{x}^+)}{\partial x_{L^+}^{+2}} \end{bmatrix} \\ &= -W \end{aligned} \quad (4.10)$$

在条件 (4.8) 的情况下, 矩阵 W 即满足行对角占优同时也满足列对角占优, 同时其转置 W^T 也是对角占优的。于是我们有

$$\nabla \mathbf{u}^+(\mathbf{x}) + \nabla \mathbf{u}^+(\mathbf{x})^T = -W - W^T \quad (4.11)$$

是严格对角占优且对称的。根据文献^[108]中的现有结论, 当一个严格对角占优对称矩阵的对角元素为非负实数时, 该矩阵为正定的。因此在这里, 我们有 $\nabla \mathbf{u}^+(\mathbf{x}) + \nabla \mathbf{u}^+(\mathbf{x})^T$ 是负正定的矩阵。依据文献^[109]中的定理, 我们可以得到 $\nabla \mathbf{u}^+(\mathbf{x})$ 是严格对角凹的。因此, 利用文献^[109]中定理 2 的结果, 我们可以得到博弈 \mathcal{G}_U^+ 存在唯一的链接需求均衡。□

定理 4.2 的证明基于以下事实: 在条件 4.8 下, 式 (4.6) 所定义的线性互补问题 $LCP(W, \mathbf{x}^+)$ 对应于一个凹博弈 (Concave game), 因此解 \mathbf{x}^{+*} 是唯一的。基于引理 4.3.1 所述的, 即问题 $LCP(W, \mathbf{x}^+)$ 的解与博弈 \mathcal{G}_U^+ 的均衡点对应, 我们可据此确定链接需求均衡点在特定条件下的唯一性。详细的证据参见附录 A。正如 (9) 所示, 我们可以显式地将链接需求均衡点表述为 \mathbf{a}^+ 和 \mathbf{p}^+ 的线性组合。因此, 当达到链接需求均衡点时每名用户 $i \in \mathcal{N}$ 的使用消耗量 $\sum_{k \in \mathcal{K}} x_{\tau(i,k)}^{+*}$ 应是 $\mathbf{a} = (a_1, \dots, a_N)$ 和 $\mathbf{p} = (p_1, \dots, p_K)$ 的线性函数。

4.4 理性服务提供商之间的定价博弈

在上一节中, 我们已经说明了阶段 II 数据使用博弈存在链接需求均衡点并且均衡点具有唯一性。接下来, 我们来说明第一阶段无线提供商服务价格的确定。从理论上讲, 每个服务提供商都可以在一个连续的价格变量上优化其收入。实际上, 服务提供商宣布的价格通常落在离散样本空间内, 并在一组离散价格水平上服从指定概率分布。为了刻画这个特征, 在我们所关注的定价博弈中, 服务提供商针对其他用户的策略通过选择概率定价策略来最大化其期望收入。在本节中, 我们考虑传统的情况, 即理性的服务提供商客观地评估自己的收入和其他用户的策略。我们确定了博弈混合策略定价均衡点的存在性。

4.4.1 混合策略定价均衡点的存在性

我们将提供商 k 的混合策略定义为 $\pi_k = (\pi_k(p_k^1), \pi_k(p_k^2), \dots, \pi_k(p_k^{M_k})) \in \Delta\mathcal{P}_k$, 其中 $\pi_k(p_k^m) \in [0, 1]$ 是提供者 k 选择价格 $p_k^m \in \mathcal{P}_k$ 的概率。既而我们有 $\sum_{m=1}^{M_k} \pi_k(p_k^m) = 1$ 。我们定义一个联合的混合策略定价策略 $\pi = (\pi_1, \dots, \pi_K)$ 为一个笛卡尔积 $\Delta\mathcal{P} \triangleq \prod_{k \in \mathcal{K}} \Delta\mathcal{P}_k$ 。遵循冯·诺依曼·摩根斯坦恩的期望效用理论 (EUT)^[105], 在混合策略下, 提供商 $k \in \mathcal{K}$ 的收入 z_k^{EUT} 可以表示为

$$z_k^{EUT}(\pi_k, \pi_{-k}) = \sum_{\mathbf{p} \in \mathcal{P}} \left(\prod_{k \in \mathcal{K}} \pi_k(p_k) \right) v_k, \quad (4.12)$$

其中 $\pi_{-k} \in \prod_{k' \in \mathcal{K}, k' \neq k} \Delta\mathcal{P}_{k'}$ 表示除提供商 k 外的所有其他提供商的混合策略。这里, v_k 可以根据 (4.2) 计算得到, 其中总数据使用量从阶段 II 的链路需求均衡 \mathbf{x}^{+*} 获得 (如上节 4.3 所述)。

我们根据期望效用理论将定价博弈重新定义为 $\mathcal{G}_P^{EUT} \triangleq (\mathcal{K}, \Delta\mathcal{P}, \{z_k^{EUT}\}_{k \in \mathcal{K}})$ 。定价博弈的混合策略纳什均衡定义如下。

定义 4.4.1 (混合价格策略均衡). 我们认为如果对于每个服务提供商 $k \in \mathcal{K}$, 以下条件满足

$$z_k(\pi_k^*, \pi_{-k}^*) \geq z_k(\pi_k, \pi_{-k}^*), \quad \forall \pi_k \neq \pi_k^*. \quad (4.13)$$

则混合定价策略 $\pi^* = (\pi_1^*, \dots, \pi_K^*) \in \Delta\mathcal{P}$ 是一个混合策略价格均衡。

在下面的定理中, 我们说明了博弈 \mathcal{G}_P^{EUT} 中存在混合策略定价均衡。

定理 4.3. 定价博弈 \mathcal{G}_P^{EUT} 至少存在一个混合策略的定价均衡 $\pi^* \in \Delta\mathcal{P}$ 。

证明. 根据我们的模型, 每个无线服务提供商 $k \in \mathcal{K}$ 会从 M_k 个价格中选择并进行定价。由于服务提供商的数量和每个服务提供商的定价策略空间都是有限的, 因此定价游戏 \mathcal{G}_P^{EUT} 属于有限博弈。而混合策略定价均衡 π^* 是最佳响应对应 (Best response correspondence) 的固定点。根据 Kakutani 不动点定理, 价格博弈 \mathcal{G}_P^{EUT} 至少存在一个混合策略的纳什均衡^[2]。□

在实际中, 为了避免收敛时间慢和寻找平衡点所需的不必要开销, 我们可以考虑落在混合策略纳什平衡点附近足够小邻域内的近似平衡点。我们因此定义以下 ϵ 价格均衡:

定义 4.4.2 (ϵ -价格均衡). 如果对于每个服务提供商 $k \in \mathcal{K}$, 我们有

$$z_k(\pi_k^*, \pi_{-k}^*) \geq z_k(\pi_k, \pi_{-k}^*) + \epsilon, \quad \forall \pi_k \neq \pi_k^*. \quad (4.14)$$

则混合策略定价均衡 $\pi^* = (\pi_1^*, \dots, \pi_K^*) \in \Delta\mathcal{P}$ 是一个 ϵ 定价均衡。

由定理4.3, 我们可以直接得出 ϵ 定价平衡的存在性。为了明确地寻找一个 ϵ 定价均衡, 我们可以诉诸于论文^[110] 中第五节中提出的集中式算法。

4.5 有限理性服务提供商之间的定价博弈

在第五节中, 服务提供商的收入是基于期望效用理论建模的, 其前提假设是完全理性的提供商在价格竞争中采取客观的行为。但是我们观察到, 卖方在实践中的行为通常偏离经典的期望效用理论^[8] 所预测的理性行为路径。具体来说, 服务提供商可能会对其对手的概率定价策略以及自己的收益函数进行主观评估。我们使用展望理论 (PT) 来捕捉定价博弈中的行为因素。

4.5.1 前景理论下的提供商收入期望

我们考虑前景理论的两个主要特征。第一个是概率失真效应, 指现实中决策者倾向于看重小概率事件, 但是看轻中等和大概率事件。具体而言, 这种特性可以通过将客观概率 p 映射到主观概率的概率失真函数 $w(p)$ 来刻画。使用较为广泛的概率失真函数有 **Prelec** 函数^[111]:

$$w(p) = \exp(-(-\ln p)^\alpha), 0 < \alpha \leq 1, \quad (4.15)$$

其中 p 是事件的真实概率, α 是概率失真参数, $w(p)$ 是对应的主观概率。图4.3阐明了具有不同参数的概率失真函数 (4.15)。我们可以看到所有曲线在点 $1/e$ 相交。此外, 当 $0 \leq p < 1/e$ 时, 函数是凸的, $w(p) < p$ (即低估客观概率); 而当 $1/e \leq p < 1$ 时, 函数是凹的, 我们有 $w(p) \geq p$ (即高估客观规律)。失真参数 α 的值越小, 则概率失真效应越明显。当 α 设置为 1 时, 该函数即变为客观概率。在这里我们考虑同类服务提供商, 其主观评估可以通过 (4.15) 中给出的具有相同 α 取值的失真函数来表征。同时, 我们假设服务提供商能够客观地评估自身的策略。因而在前景理论下, 用户 k 对联合定价策略 $\mathbf{p} \in \Delta\mathcal{P}$ 的评估可以表示为 $\pi_k(p_k)w(\prod_{k' \in \mathcal{K}, k' \neq k} \pi_{k'}(p_{k'}))$ 。

我们考虑的前景理论的另一个特征是效用框架效应。此效应反映了每个服务提供商对自己的收益进行主观评估的实际情况。实际中, 仅当其收入超过参照点 R (R 无需等于零) 时, 每名用户才会将其视为收益增益, 否则将视为收益损失。同样, 在给定参考点 R 的情况下, S 型单调框架函数 $f(\cdot)$ 会进一步调整客观收入, 其中函数在 $v > R$ 侧为凹函数, 而




图 4.3 失真参数 α 不同取值下的概率失真函数。




图 4.4 不同效用规避参数 β 和损失惩罚参数 λ 下的框架函数。

在 $v < R$ 一侧是凸函数。此外，在 R 附近，收益损失比收益增益增长得更快，表明收益损失的边际效用大于收益增益的边际效用。在本文中，我们使用的框架函数基于^[8]提出的框架函数，

$$f(x; R) = \begin{cases} (v - R)^\beta, & v \geq R \\ -\lambda(R - v)^\beta, & v < R \end{cases} \quad (4.16)$$

其中参数 $0 < \beta \leq 1$ 和 $\lambda \geq 1$ 分别用于刻画风险规避和损失规避的因素。图4.4展示了不同参数取值下的框架函数。特别地，当博弈参与者收入远离参照点时， β 值越大，表示风险规避程度较小； λ 值的增大则刻画了博弈参与者在客观上经历等同的收益的损失和增益时，所主观上体验到的损失要大于所体验到的增益。容易看出，当 $\beta = \lambda = 1$ 时，主观收益曲线与原始的客观收益曲线一致。我们假设每个服务提供商 k 基于式 (4.16) 来评估其收入。则在前景理论模型下，服务提供商 $k \in \mathcal{K}$ 的预期收入 z_k^{PT} 可写为

$$z_k^{PT}(\pi_k, \pi_{-k}) = \sum_{\mathbf{p} \in \mathcal{P}} \pi_k(p_k) w \left(\prod_{k' \in \mathcal{K}, k' \neq k} \pi_{k'}(p_{k'}) \right) f_k(v_k). \quad (4.17)$$

我们将前景理论讨论下的定价博弈表示为 $\mathcal{G}_P^{PT}(\mathcal{K}, \Delta\mathcal{P}, \{z_k^{PT}(R_k)\}_{k \in \mathcal{K}})$ ，然后在下一节中重新讨论价格博弈的均衡解的存在。

4.5.2 混合策略定价均衡点的存在性

在节4.4.1中建立混合策略纳什均衡的存在性时，概率上期望收入 (4.12) 的线性性起着关键作用。然而正如前一节所述，在前景理论中参与者对通过非线性失真函数建模的信念进行主观加权。因此，我们需要重新评估游戏定价均衡的存在。我们首先对前景理论下的混合策略纳什均衡给出以下定义。

定义 4.5.1 (前景理论 (PT) 下的混合策略价格均衡). 如果对于每个服务提供商 $k \in \mathcal{K}$ 有，

$$z_k^{PT}(\pi_k^*, \pi_{-k}^*) \geq z_k^{PT}(\pi_k, \pi_{-k}^*), \quad \forall \pi_k \neq \pi_k^*. \quad (4.18)$$

则我们称该混合价格策略 $\pi^* = (\pi_1^*, \dots, \pi_K^*) \in \Delta\mathcal{P}$ 为前景理论下的混合策略定价均衡。

我们在以下定理中证明，当每个服务提供商的参考点固定时，我们的定价博弈 \mathcal{G}_P^{PT} 存在混合纳什均衡。

定理 4.4. 如果服务提供商的参考点 $\{R_k\}_{k \in \mathcal{K}}$ 都是固定的, 则定价博弈 \mathcal{G}_P^{PT} 存在至少一个混合策略均衡点 $\pi^* \in \Delta\mathcal{P}$ 。

证明. 对于每个 $k \in \mathcal{K}$, 给定任意 $R_k \in \mathbb{R}$ 和 $\pi_{-k} \in \Delta\mathcal{P}_{-k}$, 对于每个价格 $p_k \in \mathcal{P}_k$, 期望收入 $z_k^{PT}(\pi_k, \pi_{-k})$ 是 $\pi_k(p_k)$ 的线性函数。由于 $\Delta\mathcal{P}_k$ 是紧致集合, 因此最佳响应策略集 $\mathbf{B}_k(\pi_{-k}) \triangleq \{\pi'_k \in \Delta\mathcal{P} : z_k^{PT}(\pi'_k, \pi_{-k}) \geq z_k^{PT}(\pi_k, \pi_{-k})\}$ 是非空的, 紧致的且凸的。注意到 π_{-k} 是通过 $w(\cdot)$ 以 $\pi_{-k}(p_{-k}) = \prod_{k' \in \mathcal{K}, k' \neq k} \pi_{k'}(p_{k'})$ 的形式引入到 $z_k^{PT}(\cdot)$ 。由于式 (4.15) 中给出的概率失真函数 $w(p)$ 是 p 的连续函数, 因此 $z_k^{PT}(\pi_k, \pi_{-k})$ 对于每个 $\pi_{-k} \in \Delta\mathcal{P}_{-k}$ 是连续的。根据 Berge 最大值定理, 最佳响应对应 $B_k(\pi_{-k})$ 是上半连续的。根据 Kakutani 固定点定理, 存在 $\pi^* \in \Delta\mathcal{P}$, 使得对于所有 $k \in \mathcal{K}$, $\pi_k \in B_k(\pi_{-k})$ 成立。因此, 定理4.4中的论述成立。 \square

备注: 我们关于展望理论混合策略定价均衡点是否存在的讨论针对较为普遍的情况, 即服务提供商收益参考点为固定值, 且由服务商自行确定。然而当参照点不固定时, 很容易发现, 即使在仅有两个博弈玩家且每人只有两个纯策略的情况下, 混合策略定价均衡点也不一定存在。而如果服务提供商 k 参照点的取值同时取决于其他人的参照点, 则均衡点的分析会变得更为复杂。

4.5.3 混合策略定价均衡的分布式学习算法

在本节中, 我们为有限理性的服务提供商设计寻找混合策略定价均衡的算法, 而其中的挑战主要来自前景理论模型的效用框架效应。具体来说, 参数 β_k 和 R_k 都是仅服务提供商 k 自己所掌握的私有信息。因而没有一个集中式的个体知道所有服务提供商的效用函数, 而这恰恰是对于计算 ϵ -混合策略纳什均衡所需的。

为了应对这一挑战, 我们采用了基于虚拟对弈的分布式学习算法。通过该算法, 博弈参与者可以通过观察对手的动作学习得到均衡策略。基于纳什均衡和最佳响应之间的直接联系, 如果在算法结束时信念成功收敛, 则可以达到纳什均衡。但是, 这种标准的虚拟对弈算法并不总是能很好地发挥作用, 因为在某些博弈中这些信念无法收敛。在某些其他情况中, 虽然信念收敛, 但是混合策略或收入无法收敛。在其他一些情况下, 尽管信念会聚, 但混合策略或收益不会收敛。在一些标准虚拟对弈中策略和收益不收敛的原因是由于博弈策略不是信念的连续函数。因此, 我们采用了随机虚拟对弈算法 (标准虚拟对弈的一个修改版本); 其中, 每个博弈参与者所做出的策略都是平滑的最佳响应, 而不是标准的最佳响应。

定义 4.5.2 (平滑最佳响应). 对于收益为 $z_k^{PT}(\pi_k, \pi_{-k})$ 的博弈参与者 $k \in \mathcal{K}$, 给定其对手的联合混合策略 π_{-k} , 平滑最佳响应 $\mathbf{b}_k(\pi_{-k}; \eta) \in \Delta \mathcal{P}_k$ 对应于以下定义的混合策略:

$$\mathbf{b}_k(\pi_{-k}; \eta) = \arg \max_{\pi_k \in \Delta \mathcal{P}_k} \left\{ z_k^{PT}(\pi_k, \pi_{-k}) + \frac{1}{\eta} E(\pi_k) \right\}, \quad (4.19)$$

其中 $\eta > 0$ 是温度参数, $E(\pi_k) : \Delta \mathcal{P}_k \rightarrow \mathbb{R}$ 是严格可微的凹函数, 导致当 π_k 趋近于 $\Delta \mathcal{P}_k$ 的边界时, $E(\pi_k)$ 具有无限大的斜率。

由于平滑最佳响应在 π_{-k} 中是连续的, 因此信念的收敛意味着混合策略的收敛。我们采用常用的熵形式的平滑函数 $E(\pi_k) = -\sum_{m=1}^{M_k} \pi_k(p_k^m) \ln \pi_k(p_k^m)$ 。这种情况下当 $\eta \rightarrow \infty$ 时, 平滑最佳响应 $\mathbf{b}_k(\pi_{-k}; \eta)$ 恰好可化为标准的最佳响应。另一方面, 当 $\eta \rightarrow 0$ 时, 熵部分被最大化, 从而导致定价策略下的可用价格服从均匀分布。可以进一步证明, 每个价格水平 $p_k^m \in \mathcal{P}_k$ 对应的平滑最佳响应服从一个 Gibbs-Boltzmann 规则的形式:

$$\mathbf{b}_k(\pi_{-k}; \eta)(p_k^m) = \frac{\exp[\eta z_k^{PT}(p_k^m, \pi_{-k})]}{\sum_{p_k^n \in \mathcal{P}_k} \exp[\eta z_k^{PT}(p_k^n, \pi_{-k})]}. \quad (4.20)$$

接下来, 我们详细描述学习算法 (如算法6中所述)。在初始化阶段, 每个服务提供商 $k \in \mathcal{K}$ 根据其初始混合定价策略 $\pi_k^{(0)} \in \mathcal{P}_k$ 设置其初始价格水平。初始化后, 每个提供者只有在等待一个随机退避时间后才能获得更新策略的机会。这个随机退避时间是由参数为 τ 的指数分布中采样得到的。因而, 策略的更新过程为一个异步过程⁴。在阶段 t , 每个服务提供商 $k \in \mathcal{K}$ 观察其对手 $l \in \mathcal{K}$ 的当前行为并基于下式更新其对于对手 l 的信念:

$$\begin{aligned} \pi_l^{(t)}(p_l^m) &= \pi_l^{(t-1)}(p_l^m) + \frac{1}{t} \left\{ \mathbf{1}_{\{p_l^{(t)}=p_l^m\}} - \pi_l^{(t-1)}(p_l^m) \right\}, \\ \forall p_l^m &\in \mathcal{P}_l. \end{aligned} \quad (4.21)$$

每次当服务提供商 k 更新价格时, 其首先基于其对于对手策略的当前信念计算其在使用不同价格水平时所可以获得的期望收益 (即 $z_k^{PT(t)}(p_k^m, \pi_{-k}^{(t)}), \forall p_k^m \in \mathcal{P}_k$)。然后, 她基于分布 $\mathbf{b}_k(\pi_{-k}^{(t)}; \eta) = (\mathbf{b}_k(\pi_{-k}^{(t)}; \eta)(p_k^1), \dots, \mathbf{b}_k(\pi_{-k}^{(t)}; \eta)(p_k^{M_k}))$ (4.20) 做出平滑最优响应。最后, 提供商依据下式推进其对于混合策略的学习演化:

$$\pi_k^{(t)} = (1 - \theta^t) \pi_k^{(t-1)} + \theta^t \mathbf{b}_k(\pi_{-k}^{(t)}; \eta). \quad (4.22)$$

其中 $\theta^t > 0$ 表示学习率。

⁴根据指数分布的属性, 有多于一个提供商同时更新其策略的概率为零。

Algorithm 6: 分布式学习算法1: **initalization:**2: **for all** $k \in \mathcal{K}$ **do**3: 初始化策略空间 \mathcal{P}_k 上的均匀分布 $\pi_k^{(0)}$ 。

4: 初始化

$$\mathbf{z}_k^{PT(0)} = \left(z_k^{PT(0)}(p_k^1, \pi_{-k}^{(0)}), \dots, z_k^{PT(0)}(p_k^{M_k}, \pi_{-k}^{(0)}) \right).$$

5: **end initialization**6: **loop** 并行地对于每个服务提供商 $k \in \mathcal{K}$:7: 设置一个计时器, 该计时器从均值等于 $\frac{1}{\tau}$ 的指数分布中采样。

8: 倒数直到计时器归零。

9: $t \leftarrow t + 1$

10: 根据 (4.21) 更新其他服务提供商的信念。

11: **if** 服务提供商 k 的计时器到期 **then**12: 根据 (4.20) 计算平滑的最佳响应 $\mathbf{b}_k(\pi_{-k}^{(t)}; \eta)$, 并使用平滑的最佳响应更新价格水平。13: 根据 (4.22) 更新混合策略 $\pi_k^{(t)}$ 。14: **end if**15: **end loop**

接下来, 我们分析算法6的收敛性质。如上所述, 随机虚拟博弈的使用内在地保证了信念的收敛导致混合策略的收敛。因此, 证明算法收敛于混合策略纳什均衡等同于证明服务提供商信念的收敛。与标准虚拟博弈相比, 使用随机虚拟博弈会在原始混合策略定价均衡对应的解与 ϵ -混合策略定价均衡对应的解之间引入一个间隙, 这是对于更好的收敛性能的折衷。我们关于算法6收敛的主要结论如下:

定理 4.5 (算法6的收敛). 对于一个温度参数 $\eta > 0$, 算法6几乎肯定收敛至一个 ϵ -混合策略定价均衡, 即 $\forall k \in \mathcal{K}$,

$$\lim_{t \rightarrow \infty} \pi_k^{(t)} = \pi_k^* \quad (4.23)$$

其中

$$\epsilon(\eta) = \max_{k \in \mathcal{K}} \left(\frac{1}{\eta} \ln(|\mathcal{P}_k|) \right). \quad (4.24)$$

证明. 为了证明算法6的收敛, 我们首先说明服务提供商之间的定价博弈是一个超模博弈。对于每个服务商 $k \in \mathcal{K}$, 其收益 v_k 是联合定价策略 $\mathbf{p} \in \Delta \mathcal{P}$ 的二次函数。进一步, 给定条

件4.9, 我们可以得到对于任意提供商 $k' \in \mathcal{K}/\{k\}$ 不等式 $\frac{\partial v_k}{\partial p_k p_{k'}} \geq 0$ 满足。根据超模博弈的定义^[112], 我们可以得到博弈 \mathcal{G}_P^{PT} 是一个超模博弈。根据文献[113]中的结论, 对于一个超模博弈, 虚拟对弈算法在时间平均意义上可以收敛到其混合策略纳什均衡。因此我们的分布式学习算法从长期来看可以收敛至博弈 \mathcal{G}_P^{PT} 的混合价格策略均衡。

我们接下来证明定理的第二部分。我们的算法中使用了熵形式的平滑函数 $E(\pi_k) = -\sum_{m=1}^{M_k} \pi_k(p_k^m) \ln \pi_k(p_k^m)$, 根据其性质我们有

$$\begin{aligned} \max_{\pi_k \in \Delta \mathcal{P}_k} z_k^{PT}(\pi_k, \pi_{-k}^*) &\leq \max_{\pi_k \in \Delta \mathcal{P}_k} (z_k^{PT}(\pi_k, \pi_{-k}^*) + E_k(\pi_k)) \\ &\leq z_k^{PT}(\pi_k^*, \pi_{-k}^*) + \max \left(-\frac{1}{\eta} \sum_{m=1}^{|\mathcal{P}_k|} \pi_k(p_k^m) \right). \end{aligned}$$

由于 $0 \leq -\frac{1}{\eta} \sum_{m=1}^{|\mathcal{P}_k|} \pi_k(p_k^m) \ln \pi_k(p_k^m) \leq \frac{1}{\eta} \ln(|\mathcal{P}_k|)$, 我们可以得到式(4.24)中的 ϵ 的解析表达。 \square

备注: 使用平滑的最佳响应会导致探索与利用之间的权衡, 而从另一方面看这也符合我们的假设, 即服务提供商作为博弈的参与者其行为具有有限的理性。具体来说, 一方面, 对应于较高预期收益的行动将以较高的概率被选择, 这可以被视为对于较好策略的利用。另一方面, 博弈参与者可能会选择任一具有非零概率的动作, 以对策略空间进行充分探索。温度参数 η 用于控制这种权衡。

4.6 仿真验证

本节中我们通过数值仿真来评估本文所讨论的无线数据服务寡头市场的系统性能。为了便于说明, 我们考虑一个双强垄断市场, 这其中包括 N 个互相之间具有社交联结的移动用户和两个无线提供商 A 和 B 。

我们使用了 Erdős-Rényi 图模型来对移动用户间潜在的社交关系进行建模^[103]。具体而言, 这种模型下每对用户之间的无方向社交联结以固定概率 e 存在, 其值表征了特定社交网络的密集程度。我们进一步令用户 i 和 j 之间的社交联系 g_{ij} 权重服从正态分布 $\mathcal{N}(\mu_G, 1)$ 。对于每个用户 i , 内在系数 a_i 和 b_i 服从正态分布 $\mathcal{N}(\mu_a, 5)$ 和 $\mathcal{N}(\mu_b, 5)$ 。参数具有以下默认值: $N = 10$, $e = 0.5$, $\mu_a = \mu_b = 20$, $c = 1$, $q_A = 1$ 并且 $q_B = 3$ 。每个服务提供商的价格空间设置为 $\mathcal{P}_A = \mathcal{P}_B = \{0.96, 0.98, 1.00, 1.02, 1.04, 1.06, 1.08, 1.10\}$ 。

我们首先考虑理性服务提供商的情况, 来模拟服务商定价-用户数据使用博弈, 并设置参数 $\epsilon = 0.4$ 。为了评估在均衡状态下网络外部性对用户数据使用的影响, 我们分别针对拥




图 4.5 社交联结权值平均值 μ_G 对总数据使用量的影响。




图 4.6 归一化最佳收益与用户数量 N 变化关系。

有 20 个用户的市场和拥有 50 个用户的市场两种情况，将拥塞系数固定在默认值，同时将社交联结权值均值 μ_G 从 2 增加到 5。图 4.5 说明了移动用户的数据总使用量随 μ_G 取值增加而单调增加；对于 50 个用户的情况，数据使用量整体上更多。该结果清楚地表明，通过加强社交联系以增强正网络外部性效应可以推动移动用户从服务提供商那里消费更多数据。

接下来，我们分析评估无线服务提供商可实现的收益。我们将平均社会联结强度固定为 $\mu_G = 2$ ，并针对轻度拥塞 ($c = 1$) 和重度拥塞 ($c = 3$) 分别将系统用户数量从 10 增加到 50 两种情况进行仿真。如图 4.6 所示，服务提供商在均衡状态下的标准化收益随市场规




图 4.7 归一化的最佳收益与服务成本差异之间的关系。




图 4.8 有限理性对服务提供商总收益的影响。

模的增加而单调增加。而且正如预期的那样，当系统自身拥塞情况较轻微时，服务提供商将获得更高的收益。

我们进一步评估服务提供商之间的竞争对其各自收益的影响。我们令 $q_a = 1$ 将 q_b 的值从 3 改变到 9，从而使得服务成本差异从 2 增长到 8（提供商 A 相比提供商 B 在服务成本上更具竞争力）。如图 4.7 所示，随着成本差异的扩大，服务提供商 A 的收益不断增加，而提供商 B 的收益却不断下降。当达到一定成本差异时，提供商 B 的收入减少到零，并且提供商 A 的收益趋于饱和，这意味着所有用户都选择使用服务提供商 A 的数据。

最后，我们通过比较 PT 模型下的最优收益与传统 EUT 模型下的最优收益，来分析服务提供商行为理性的影响。对于 PT 模型，在仿真中我们为两个服务提供商选择相同的参考点和风险规避参数（即 $R_A = R_B = R$, $\beta_A = \beta_B = \beta$ ）。我们进一步设置概率失真参数 $\alpha = 0.6$ 和损失惩罚参数 $\lambda = 1.5$ 。对于分布式学习算法，我们设置学习参数 $\theta^t = 1/t$ ，温度参数 $\eta = 5$ 。我们为风险规避参数选择三个不同的值（即 $\beta = 1, 0.8, 0.6$ ），然后对于 R 取值在 0 到 3 的范围内进行仿真。如图 4.8 所示，总收益会随着参考点取值的增加而减少。从本质上讲，参考点取值偏离零值越多，将导致服务提供商的客观评估发生更大的偏移，从而使他们对收益增益的重视程度降低，而对收益损失的重视程度更高。此外，较小的 β 值会导致收益进一步下降，因为当服务提供商风险规避程度增加时，等量收益增益对于提供商的价值会降低。通过设置 $\beta = 1$ ，我们移除了参数 β 的影响；在 $R = 0$ 处 EUT 曲线和 PT 曲线之间的间隙表示近由于概率失真效应而导致的收入下降。

4.7 本章小结

在本文中，我们探讨了在社交效应与拥塞效应形成的双重网络外部性影响下无线服务提供商的定价策略和移动用户的数据消费行为。为了刻画移动用户和服务提供商之间的交互，我们使用了斯塔克伯格博弈的问题建模并分析了其均衡解。特别地，我们首先求解了博弈第二阶段的链接需求均衡，并证明了博弈均衡的唯一性特征。接着我们分别在传统的完全理性服务提供商场景和更实际的有限理性服务提供商场景下证明了第二阶段中混合策略定价均衡的存在。我们的数值结果体现了社交效应和拥塞效应对系统性能的影响，以及有限理性行为对服务提供商收入造成的负面影响。

第五章 总结与展望

本章摘要：本章总结了全文的主要工作和主要结论，并展望了进一步的研究工作。

5.1 全文总结

移动通信和移动互联网的发展给人们的生活带来了巨大的改变，人们日常生活中的学习、工作、娱乐、社交活动已经与移动设备紧密地结合在一起。近年来，5G 通信技术的成熟大大促使了移动流量的增长，移动社交网络的盛行则使得移动网络呈现出显著的社交效应。然而，由于频谱资源、网络容量的有限性，通信信号干扰、网络拥塞等问题仍然是阻碍移动通信网络发展的主要挑战。从网络经济学的角度，移动网络中的社交效应以及信号干扰、网络拥塞都是网络外部性在移动网络中的具体表现。现有的网络性能优化与机制设计的工作中仍然缺乏对于网络外部性效应的充分挖掘与分析，没有对于个体非完全理性的行为模型进行充分的考量，同时缺乏对于网络性能优化与隐私保护之间权衡的分析。本文针对现有相关研究工作中的不足，结合国内外最新的研究成果，考虑了不同场景中网络外部性影响下移动网络机制设计、性能优化与隐私保护的问题，对不同场景中的网络外部性效应进行了刻画，提出了相应的机制设计以及求解算法。本文的主要结论可以概括为以下几个方面：

1. 研究了隐私保护下群智感知系统平台成本最小化问题，提出了一种用于移动群智感知中隐私数据聚合的拍卖框架。提出了一种用户本地数据加噪的方案，其中用户所允许添加的噪声分布由感知平台设计决定，使得用户的数据隐私可以从差分隐私的量化指标上进行衡量。本文揭示了用户间所存在的负网络外部性效应并根据用户对于隐私保护级别的偏好，分成“消极隐私保护”和“积极隐私保护”两种场景进行问题的建模与求解。基于问题隐藏的单调性特性，针对两种场景分别提出了具有诚实性、个体理性、且计算高效的激励机制设计，使得感知平台可以近似地最小化感知平台的成本，同时满足对于聚合结果准确性的要求。本文通过理论分析结合充分的仿真实验验证了所提出的算法。

2. 研究了隐私保护下数据库辅助频谱共享场景下的网络吞吐量最大化问题。其中移动用户对信号传输功率水平添加随机扰动，以削弱基于 RSS 的潜在位置隐私攻击的威胁，而在制定频谱共享决策时同时考虑了其与其他用户在地理位置上和社交联系上的耦合关系。本文通过对于用户社交群体效用的定义刻画了社交效应（正网络外部性）和信号干扰（负网络外部性）影响下用户的实际效用，并将隐私保护下次级用户的信道共享问题建模成一个社交群体效用最大化（SGUM）博弈。进一步，本文针对性地提出了一个双时间尺度分布式学习算法。算法在较快时间尺度上进行效用学习，在较慢时间尺度上进行基于无悔学习的策略迭代。理论上可以证明提出的算法以概率 1 收敛至博弈的相关均衡集合。数值结果证实算法可以在隐私保护与网络吞吐量最大化的目标之间进行权衡。
3. 研究了无线服务提供商收益最大化问题，其中移动用户的数据使用同时受到社交效应（正网络外部性）和拥塞效应（负网络外部性）的影响。为了刻画移动用户和服务提供商之间的交互，我们使用了斯塔克伯格博弈的问题建模并分析了其均衡解。特别地，我们首先求解了用户博弈的链接需求均衡，并证明了其唯一性特征。接着我们分别在完全理性服务提供商情形和有限理性服务提供商的情形下证明了服务提供商博弈中混合策略定价均衡的存在。我们的数值结果体现了正面网络效应和负面拥塞效应对系统性能的影响，以及有限理性行为对服务提供商收入造成的负面影响。

随着移动网络规模的增长，网络外部性效应在大量移动网络场景中的影响日益凸显出来，为网络优化问题建模分析提出了更高的要求。本文聚焦于三个独立的移动网络场景，分析揭示了其中存在的网络外部性影响，并针对性地提出了有效的网络性能优化机制。同时，本文关注了移动网络中的潜在隐私泄露隐患，在网络性能优化机制设计中结合了隐私保护的措施，研究了隐私保护与性能优化之间的权衡。本文的研究成果为在真实移动网络场景中的性能优化设计提供了一定的指导意义。

5.2 研究展望

由于时间限制，本文所研究的问题还存有进一步深入研究和探索的空间。同时，本文的一些成果对于其他一些移动网络性能优化问题场景也存在一定的借鉴意义价值。现将一些未来潜在的研究方向总结如下：

1. 在移动群智感知平台成本最小化问题中，本文重点考虑了单一感知任务，且总用户集合固定不变的场景。当时间尺度拉大后，将出现多任务用户集合动态变化的情况。在

这种更为复杂的情况下,如何对于任务进行分配,为用户提供长期的激励是一个有趣同时具有挑战的问题。此外,进一步的研究应当考虑构建一个保隐私群智感知测试平台,并基于平台上的系统实验对设计提出的激励机制进行验证和改进,以最大程度减小研究成果与实际应用效果之间的距离。

2. 在频谱共享网络吞吐量最大化问题中,本文所使用的社交群体效用最大化框架(SGUM)对于其他一些移动网络中存在社交效应的问题场景具有一定的通用性,可以用于其他网络性能目标的优化问题中。此外,本文中的模型假设用户之间的社交联系强度为固定的且为用户所已知的信息。而在一些实际情况下,用户之间的社交联系强度可能带有一定的随机性,且需要用户通过社交学习(social learning)的方式获得。这种情况下,如何设计有效的机制使系统达到对应的均衡状态是未来的一个潜在研究方向。
3. 在移动网络服务提供商收益最大化问题中,本文使用了二次函数来刻画用户固有效用函数,使用了流量交叉乘积项来刻画用户之间的社交效应。进一步的研究可以去探索是否有更合适的函数形式可以被用来对用户的个体固有效用、用户间的网络外部性效应进行建模。另外,本研究中提供商的定价策略局限于静态定价模式且定价对于不同用户不进行区分,其好处是使得模型更为简洁,在实际中易于执行。而换用动态定价模式以及对于用户进行差异化定价是否可以在不付出太多机制复杂性代价的情况下提高系统的综合性能是值得深入探讨的问题。

附录 A 第二章相关推导证明

A.1 定理2.4和推论2.5的证明

证明定理2.4需要首先对问题 (2.15) 的最优分配解 \mathbf{x}^{R*} 进行刻画，并在此基础上进一步建立算法 DPDA 的输出与问题 (2.13) 最优解之间的联系。

首先，建立问题 (2.15) 与以下问题的等价关系：

$$\begin{aligned} & \text{minimize} && \sum_{i=1}^N b_i w_i x_i - C \sum_{i=1}^N w_i (1 - x_i) \\ & \text{subject to} && \sum_{i \in \mathcal{N}} w_i x_i \geq W, \\ & && 0 \leq x_i \leq 1, \forall i \in \mathcal{N}. \end{aligned} \quad (\text{A.1.1})$$

引理 A.1.1. 问题 (2.15) 的最优分配解 \mathbf{x}^{R*} 与问题 (A.1.1) 的最优分配解一致。

证明. 由于问题(2.15)和问题(A.1.1)有相同的可行域,任何对于问题(2.15)的可行解 \mathbf{x} 同样为问题(A.1.1)的可行解。注意到 C 是问题(2.15)的最优值,即 $C = \sum_{i=1}^N b_i w_i x_i^{R*} / \sum_{i=1}^N w_i (1 - x_i^{R*})$ 。因此,对于任何可行的 \mathbf{x} , 我们有 $C \leq \sum_{i=1}^N b_i w_i x_i / \sum_{i=1}^N w_i (1 - x_i)$ 。通过一些简单的变换,可以得到 $\sum_{i=1}^N b_i w_i x_i - C \sum_{i=1}^N w_i (1 - x_i) \geq 0$, 其中等号对于 \mathbf{x}^{R*} 成立。换句话说, \mathbf{x}^{R*} 是问题 (A.1.1) 的最优解。因此,引理成立。 \square

基于引理A.1.1, 下一步可以利用问题的单调性特性来刻画问题 (A.1.1) 的最优解, 以此来描述最优分配解 \mathbf{x}^{R*} 。我们有以下引理。

引理 A.1.2. 定义 $l = \max\{j : \sum_{i=1}^j b_i w_i - C(\sum_{i=j+1}^N w_i) \leq 0, \forall j = 1, \dots, N\}$, 则问题 (A.1.1) 的最优解 \mathbf{x}^{R*} 如下所示：

$$x_i^{R*} = \begin{cases} 1, & \text{if } i \leq l \\ \frac{C \sum_{i=l+1}^N w_i - \sum_{i=1}^l b_i w_i}{(b_{l+1} + C) w_{l+1}}, & \text{if } i = l + 1 \\ 0, & \text{if } i > l + 1 \end{cases} \quad (\text{A.1.2})$$

证明. 首先需要证明 l 和 x_i^{R*} 是存在的。定义 $p(k) = \sum_{i=1}^k b_i w_i - C(\sum_{i=k+1}^N w_i)$, 其中 $k = 0, 1, \dots, N$ 。如果 $k = 0$, 则 $p(0) = -C \sum_{i=1}^N w_i < 0$; 而如果 $k = N$, 则 $p(N) = \sum_{i=1}^N b_i w_i > 0$ 。注意到 $p(k)$ 是随 k 严格递增的。因此, 存在 l 使得 $p(l) \leq 0$ 且 $p(l+1) > 0$ 。进一步, 定义 $q(x_{l+1}) = p(l) + (b_{l+1}w_{l+1} - Cw_{l+1})x_{l+1}$ with $0 \leq x_{l+1} \leq 1$, 其中 $q(0) = p(l) \leq 0$ 并且 $q(1) = p(l+1) > 0$ 。由于 $q(x_{l+1})$ 关于 x_{l+1} 是连续且严格递增的, 可知存在唯一的 $x_{l+1}^{R*} \in [0, 1]$ 使得 $q(x_{l+1}^{R*}) = 0$ 。接下来, 利用问题 (A.1.1) 的 KKT 条件来验证式 (A.1.2) 中的最优解 \mathbf{x}^{R*} 。式 (A.1.1) 的拉格朗日表达式可以写为

$$\begin{aligned} L(\mathbf{x}, \lambda, \mu, \nu) &= \sum_{i=1}^N b_i w_i x_i - C \sum_{i=1}^N w_i (1 - x_i) \\ &\quad + \lambda(W - \sum_{i=1}^N w_i x_i) + \sum_{i=1}^N \mu_i (x_i - 1) - \sum_{i=1}^N \nu_i x_i \\ &= \sum_{i=1}^N (b_i w_i + C w_i - \lambda w_i + \mu_i - \nu_i) x_i \\ &\quad - C \sum_{i=1}^N w_i + \lambda W - \sum_{i=1}^N \mu_i, \end{aligned} \quad (\text{A.1.3})$$

其中 λ, μ 和 ν 为拉格朗日乘子。从式 (A.1.3) 可以得出对于所有的 x_i , $b_i w_i + C w_i - \lambda w_i + \mu_i - \nu_i = 0$ 成立。很容易证实当 $\lambda^* = b_{l+1} + C$, $\mu_i^* = \mathbf{1}_{\{i \leq l\}}(b_{l+1} - b_i)w_i$ 并且 $\nu_i^* = \mathbf{1}_{\{i > l+1\}}(b_i - b_{l+1})w_i$ 时, 由引理 A.1.2 得到的 x_i^{R*} 满足 KKT 条件。其中 $\mathbf{1}_{\{\text{condition}\}}$ 为指示函数, 即条件成立时 $\mathbf{1}_{\{\text{condition}\}} = 1$, 不成立时为 0。由此, 引理可证。□

基于引理 A.1.2, 易得到算法 DPDA 将选择 $l+1$ 个用户同时满足准确性要求。

引理 A.1.3. 令 l 的定义如引理 A.1.2 中所述, k 为算法 DPDA 所选的赢家的数量。于是我们有 $k = l+1$ 且 DPDA 算法满足准确性要求, 即 $\delta(\mathbf{x}) \leq \Delta$ 。

证明. 算法 DPDA 的设计使得其会选择最小的整数 k 使得 $\sum_{i=1}^k b_i w_i - C(\sum_{i=k+1}^N w_i) \geq 0$ 。根据引理 A.1.2, 其对应于用户 $1, 2, \dots, l+1$ 。同时, 由于 $x_{l+1}^{R*} \in [0, 1]$, 不等式 $\sum_{i=1}^{l+1} w_i \geq \sum_{i=1}^l w_i + w_{l+1}x_{l+1}^{R*} \geq W$ 可以满足, 因此引理得证。□

接下来, 证明对于平台最优总支付算法 DPDA 可以得到 α -近似解即等价于在引理 2.3.1 和引理 A.1.1 满足的条件下证明算法 DPDA 可以得到针对问题 (A.1.1) 最优解的 α -近似解。注意到式 (A.1.1) 中的目标函数包含一个常数 $C \sum_{i=1}^N w_i$, 而去掉这个常数并不影响问题 (A.1.1) 的优化。因而证明只需关注针对于项 $h(\mathbf{x}) = \sum_{i=1}^N (b_i + C)w_i x_i$ 算法 DPDA 的近似表现。令 \mathbf{x}^{DPDA} 代表算法 DPDA 得到的分配解, \mathbf{x}^* 代表最优分配 $\text{OPT} = h(\mathbf{x}^*)$ 对应的最优分配解。由于问题 (A.1.1) 是问题 (2.14) 的一个松弛, 因而有 $h(\mathbf{x}^{R*}) \leq \text{OPT}$ 。我们接下来证明

$h(\mathbf{x}^{DPDA}) \leq \alpha OPT$ 。基于引理A.1.3, 我们有

$$\begin{aligned}
 h(\mathbf{x}^{DPDA}) &= \sum_{i=1}^{l+1} (b_i + C)w_i \\
 &= \sum_{i=1}^l (b_i + C)w_i + (b_{l+1} + C)w_{l+1}x_{l+1}^{R*} \\
 &\quad + (b_{l+1} + C)w_{l+1}(1 - x_{l+1}^{R*}) \\
 &= h(\mathbf{x}^{R*}) + (b_{l+1} + C)w_{l+1}(1 - x_{l+1}^{R*}),
 \end{aligned} \tag{A.1.4}$$

其中基于 (A.1.2), 有 $h(\mathbf{x}^{R*}) = \sum_{i=1}^l (b_i + C)w_i + (b_{l+1} + C)w_{l+1}x_{l+1}^{R*}$ 。于是,

$$\begin{aligned}
 \frac{h(\mathbf{x}^{R*}) + (b_{l+1} + C)w_{l+1}(1 - x_{l+1}^{R*})}{h(\mathbf{x}^{R*})} &= 1 + \frac{(b_{l+1} + C)w_{l+1}(1 - x_{l+1}^{R*})}{h(\mathbf{x}^{R*})} \\
 &\stackrel{(a)}{\leq} 1 + \frac{(b_{l+1} + C)w_{l+1}(1 - x_{l+1}^{R*})}{(b_{l+1} + C)w_{l+1}x_{l+1}^{R*}} \\
 &= \frac{(b_{l+1} + C)w_{l+1}}{C \sum_{i=l+1}^N w_i - \sum_{i=1}^l b_i w_i} \\
 &= \frac{1}{x_{l+1}^{R*}}
 \end{aligned} \tag{A.1.5}$$

其中不等式 (a) 由不等式 $h(\mathbf{x}^{R*}) \geq (b_{l+1} + C)w_{l+1}x_{l+1}^{R*}$ 得到。由于 $x_{l+1}^{R*} < 1$, 可得 $\alpha \geq 1$ 。因此, 可以得出 $h(\mathbf{x}^{DPDA}) \leq \alpha h(\mathbf{x}^{R*}) \leq \alpha OPT$, 即完成了定理2.4的证明。基于定理2.4和假设2.3.3, 令 $k = l + 1$, 可以得到以下关系,

$$\begin{aligned}
 \frac{h(\mathbf{x}^{DPDA})}{h(\mathbf{x}^{R*})} &\leq \frac{(b_k + C)w_k}{C \sum_{i=k}^N w_i - \sum_{i=1}^{k-1} b_i w_i} \\
 &\leq \frac{Cw_k + b_k w_k}{Cw_k - \sum_{i=1}^{k-1} b_i w_i} \\
 &\leq \frac{Cw_k + b_k w_k}{Cw_k - (k-1)b_k w_k} \\
 &= \frac{C + b_k}{C - (k-1)b_k} \\
 &\leq \frac{C + C/\beta}{C - (k-1)C/\beta} \\
 &= \frac{1 + 1/\beta}{1 + 1/\beta - k/\beta} \\
 &= \frac{1}{1 - k/(\beta + 1)} = \alpha,
 \end{aligned} \tag{A.1.6}$$

由于 $\beta > N \geq k$, 可以得出 $\alpha > 1$ 。因而可以得到 $h(\mathbf{x}^{DPDA}) \leq \alpha h(\mathbf{x}^{R*}) \leq \alpha OPT$, 推论2.5得证。

A.2 引理2.4.3的证明

本小节根据与引理2.3.1和引理2.3.2相同的证明思路对引理2.4.3进行证明。首先, 建立问题 (2.17) 与以下问题的等价性:

$$\begin{aligned}
 &\text{minimize} && \sum_{i \in \mathcal{N}} b_i \epsilon_i(\mathbf{x}) \\
 &\text{subject to} && \sum_{i \in \mathcal{N}} w_i x_i \geq W, \\
 &&& \sum_{j \in \mathcal{N}} w_j x_j + \frac{w_i}{g_i} x_i \leq \sum_{j \in \mathcal{N}} w_i, \forall i \in \mathcal{N}, \\
 &&& x_i \in \{0, 1\}, \forall i \in \mathcal{N},
 \end{aligned} \tag{A.2.7}$$

问题 (A.2.7) 的分数松弛由下式给出：

$$\begin{aligned}
 & \text{minimize} && \sum_{i \in \mathcal{N}} b_i \epsilon_i(\mathbf{x}) \\
 & \text{subject to} && \sum_{i \in \mathcal{N}} w_i x_i \geq W, \\
 & && \sum_{j \in \mathcal{N}} w_j x_j + \frac{w_i}{g_i} x_i \leq \sum_{j \in \mathcal{N}} w_j, \forall i \in \mathcal{N}, \\
 & && 0 \leq x_i \leq 1, \forall i \in \mathcal{N},
 \end{aligned} \tag{A.2.8}$$

下一步建立问题 (A.2.8) 和问题 (2.19) 之间的等价性。很容易得出对于问题 (2.19) 的任意可行解也是问题 (A.2.8) 的可行解，且对应于同样的最优值，反之亦然。如果 \mathbf{x} 对于问题 (A.2.8) 是可行的，则 $y_i = \frac{x_i}{\sum_{i \in \mathcal{N}} w_i (1-x_i)}$, $\forall i \in \mathcal{N}$ 和 $z = \frac{1}{\sum_{i \in \mathcal{N}} w_i (1-x_i)}$ 对于问题 (2.19) 是可行解，对应于同样的最优值 $\sum_{i \in \mathcal{N}} b_i w_i y_i = \sum_{i \in \mathcal{N}} b_i \epsilon_i(\mathbf{x})$ 。于是有问题 (A.2.8) 的最优值大于等于问题 (2.19) 的最优值。反过来，如果 y_i 和 z 是问题 (2.16) 的可行解，则有 $x_i = y_i/z$ 是问题 (2.15) 的可行解，且具有同样的最优值。因此，问题 (A.2.8) 的最优值小于等于问题 (2.19) 的最优值。于是可以得出问题 (A.2.8) 与问题 (2.19) 的等价性。

附录 B 第三章相关推导证明

B.1 定理3.2的证明

证明过程首先将两个迭代学习算法 (3.9) 和 (3.10) 表示为两个随机逼近过程^{[91][114]}。为便于说明, 以下证明过程省去下标 i 和 j , 可以得到

$$\begin{cases} \hat{S}_n^t(a_n) = \hat{S}_n^{t-1}(a_n) + \lambda^t \left\{ F_{\hat{S}_n}(\hat{S}_n^{t-1}(a_n), D_n^{t-1}(a_n)) + M_{\hat{S}_n}^t \right\}, & (\text{B.1.1a}) \\ D_n^t(a_n) = D_n^{t-1}(a_n) + \epsilon^t \left\{ F_{D_n}(\hat{S}_n^{t-1}(a_n), D_n^{t-1}(a_n)) + M_{D_n}^t \right\}. & (\text{B.1.1b}) \end{cases}$$

其中 $F_{\hat{S}_n}$ 和 F_{D_n} 为 Lipschitz 函数, $M_{\hat{S}_n}^t$ 和 $M_{D_n}^t$ 为鞅差异。具体的, Lipschitz 函数 (Lipschitz 常数 $L = 1$) 可以被表示为

$$\begin{cases} F_{\hat{S}_n}(\hat{S}_n^{t-1}(a_n), D_n^{t-1}(a_n)) = \mathbb{E} \left[\frac{\hat{S}_n^t - \hat{S}_n^{t-1}}{\lambda^t} | \hat{S}_n^t, D_n^t \right], & (\text{B.1.2a}) \\ F_{D_n}(\hat{S}_n^{t-1}(a_n), D_n^{t-1}(a_n)) = \mathbb{E} \left[\frac{D_n^t - D_n^{t-1}}{\epsilon^t} | \hat{S}_n^t, D_n^t \right]. & (\text{B.1.2b}) \end{cases}$$

给定鞅差异 $M_{\hat{S}_n}^t$ 和 $M_{D_n}^t$, 在满足条件 **C1** 和 **C2** 的情况下, 使用文献92中的主定理即可证明序列 $\left\{ \sum_{t=0}^k \lambda^t M_{\hat{S}_n}^t \right\}_k$ 和 $\left\{ \sum_{t=0}^k \epsilon^t M_{D_n}^t \right\}_k$ 可以以概率 1 收敛。

然后, 根据随机逼近理论^[91] 的常微分方程 (ODE) 方法, 离散随机过程 (B.1.1a) 和 (B.1.1b) 可以看作是对于连续确定的 ODE 的有噪离散化形式:

$$\begin{cases} \dot{\hat{S}}_n(a_n) = F_{\hat{S}_n}(\hat{S}_n^{t-1}(a_n), D_n^{t-1}(a_n)), & (\text{B.1.3a}) \\ \dot{D}_n(a_n) = F_{D_n}(\hat{S}_n^{t-1}(a_n), D_n^{t-1}(a_n)). & (\text{B.1.3b}) \end{cases}$$

首先, 对于 (B.1.3a), 假设对于每个固定的集合 $\{D_n^t\}_{n \in \mathcal{V}}$ 存在一个极限群体效用期望 $S_n(a_n, \{D_n^t\}_{n \in \mathcal{V}})$ 为 (B.1.3a) 的一个唯一的全局渐近稳定点, 则容易得到对于群体效用期望 $\hat{S}_n^t(a_n)$ 的学习将收敛到一个极限效用期望 $S_n(a_n, \{D_n^t\}_{n \in \mathcal{V}})$ 。因此, 在条件 **C3** 下, 算法5的随机稳定性分析简化为对于较慢时间尺度上遗憾学习过程的收敛性分析。

与针对效用学习的分析类似, 我们应用随机逼近理论的 ODE 方法使得离散随机过程 $\{D_n^t\}$ 的一个连续时间插值是一个由相应的 ODE (B.1.3b) 定义的半流的渐近伪轨迹。通过这种处理, 随机逼近过程 (B.1.1b) 的极限行为与 ODE (B.1.3b) 的轨迹的渐进行为直接相关。然后遵循文献115中推论 4.8 的证明, 定理中的收敛性结论可以得到证明。

参考文献

- [1] S. Shakkottai, R. Srikant. Network optimization and control[J]. Foundations and Trends in Networking, 2008. 2(3):271–379.
- [2] M. J. Osborne, A. Rubinstein. A Course in Game Theory[M]. MIT Press, 1994.
- [3] J. Rohlfs. A theory of interdependent demand for a communications service[J]. The Bell Journal of Economics and Management Science, 1974. 5(1):16–37.
- [4] M. L. Katz, C. Shapiro. Network externalities, competition, and compatibility[J]. The American Economic Review, 1985. 75(3):424–440.
- [5] R. Cornes, T. Sandler. The Theory of Externalities, Public Goods, and Club Goods[M]. Cambridge University Press, 1996.
- [6] W. H. Sandholm. Negative externalities and evolutionary implementation[J]. The Review of Economic Studies, 2005. 72(3):885–915.
- [7] J. Huang, L. Gao. Wireless network pricing[J]. Synthesis Lectures on Communication Networks, 2013. 6(2):1–176.
- [8] D. Kahneman, . Tversky. Prospect theory: An analysis of decision under risk[J]. Econometrica, 1979. 47(2):263–291.
- [9] B. Wang, Y. Wu, K.J. Liu. Game theory for cognitive radio networks: An overview[J]. Computer Networks, 2010. 54(14):2537–2561.
- [10] X. Chen, J. Huang. Spatial spectrum access game: Nash equilibria and distributed learning[C]//Proceedings of ACM MOBIHOC. 2012.
- [11] D. Yang, G. Xue, X. Fang, J. Tang. Crowdsourcing to smartphones: Incentive mechanism design for mobile phone sensing[C]//Proceedings of ACM MobiCom’12. 2012:173–184.
- [12] Connect with friends and the world around you on Facebook. <http://www.facebook.com/>.
- [13] Twitter: It’s What’s Happening. <http://twitter.com/>.
- [14] N. Kayastha, D. Niyato, P. Wang, E. Hossain. Applications, architectures, and protocol design issues for mobile social networks: A survey[J]. Proceedings of the IEEE, 2011. 99(12):2130–2158.
- [15] E. David, K. Jon. Networks, Crowds, and Markets: Reasoning About a Highly Connected World[M]. Cambridge University Press, 2010.

- [16] Y. Chen, B. Li, Q. Zhang. Incentivizing crowdsourcing systems with network effects[C]//Proceedings of 35th IEEE INFOCOM. 2016:1–9.
- [17] F. Malandrino, M. Kurant, A. Markopoulou, C. Westphal, U. C. Kozat. Proactive seeding for information cascades in cellular networks[C]//Proceedings of 31st IEEE INFOCOM. 2012:1719–1727.
- [18] X. Chen, B. Proulx, X. Gong, J. Zhang. Social trust and social reciprocity based cooperative D2D communications[C]//Proceedings of 14th ACM MobiHoc. 2013.
- [19] H. Li, C. Chen, L. Lai. Propagation of spectrum preference in cognitive radio networks: A social network approach[C]//Proceedings of IEEE ICC. 2011:1–5.
- [20] M. I. Ashraf, M. Bennis, W. Saad, M. Katz, C. S. Hong. Dynamic clustering and user association in wireless small-cell networks with social considerations[J]. IEEE Transactions on Vehicular Technology, July 2017. 66(7):6553–6568.
- [21] G. Yang, S. He, Z. Shi, J. Chen. Promoting cooperation by the social incentive mechanism in mobile crowdsensing[J]. IEEE Communications Magazine, 2017. 55(3):86–92.
- [22] X. Chen, X. Gong, L. Yang, J. Zhang. A social group utility maximization framework with applications in database assisted spectrum access[C]//Proc. 33rd IEEE INFOCOM. 2014.
- [23] Daron A., Asuman O. Competition and efficiency in congested markets[J]. Mathematics of Operations Research, 2007:1–31.
- [24] X. Yin, X. Zhou, R. Huang, Y. Fang, S. Li. A fairness-aware congestion control scheme in wireless sensor networks[J]. IEEE Transactions on Vehicular Technology, Nov 2009. 58(9):5225–5234.
- [25] N. H. Tran, C. S. Hong, S. Lee. Joint congestion control and power control with outage constraint in wireless multihop networks[J]. IEEE Transactions on Vehicular Technology, Feb 2012. 61(2):889–894.
- [26] Y. Yang, Y. Chen, C. Jiang, C. Wang, K. J. R. Liu. Wireless access network selection game with negative network externality[J]. IEEE Transactions on Wireless Communications, 2013. 12(10):5048–5060.
- [27] B. Zhang, Y. Chen, C. Wang, K. J. R. Liu. Learning and decision making with negative externality for opportunistic spectrum access[C]//Proceedings of 2012 IEEE Global Communications Conference (GLOBE-COM). 2012:1404–1409.
- [28] C. Jiang, Y. Chen, K. J. R. Liu. Multi-channel sensing and access game: Bayesian social learning with negative network externality[J]. IEEE Transactions on Wireless Communications, April 2014. 13(4):2176–2188.
- [29] D. Christin, A. Reinhardt, S. S. Kanhere, M. Hollick. A survey on privacy in mobile participatory sensing applications[J]. Journal of Systems and Software, 2011. 84(11):1928–1946.
- [30] P. Dandekar, N. Fawaz, S. Ioannidis. Privacy auctions for recommender systems[J]. ACM Transactions on Economics and Computation, 2014. 2(3):12.
- [31] A. Ghosh, A. Roth. Selling privacy at auction[J]. Games and Economic Behavior, 2015. 91:334–346.

- [32] H. Jin, L. Su, H. Xiao, K. Nahrstedt. INCEPTION: Incentivizing privacy-preserving data aggregation for mobile crowd sensing systems[C]//Proceedings of ACM MobiHoc'16. volume 16. 2016:341–350.
- [33] M. Zhang, L. Yang, X. Gong, J. Zhang. Privacy-preserving crowdsensing: Privacy valuation, network effect, and profit maximization[C]//Proceedings of IEEE Globecom'16. 2016:1–6.
- [34] W. Wang, L. Ying, J. Zhang. The value of privacy: Strategic data subjects, incentive mechanisms and fundamental limits[C]//Proceedings of ACM SIGMETRICS'16. 2016:249–260.
- [35] X. Gong, N. B. Shroff. Truthful mobile crowdsensing for strategic users with private qualities[C]//Proceedings of WiOpt'17. 2017.
- [36] W. Wang, L. Ying, J. Zhang. Buying data from privacy-aware individuals: the effect of negative payments[C]//Proceedings of WINE'16. Springer, 2016:87–101.
- [37] D. Yang, G. Xue, X. Fang, J. Tang. Incentive mechanisms for crowdsensing: Crowdsourcing with smartphones[J]. IEEE/ACM Transactions on Networking, 2016. 24(3):1732–1744.
- [38] S. He, D. Shin, J. Zhang, J. Chen, P. Lin. An exchange market approach to mobile crowdsensing: Pricing, task allocation and Walrasian equilibrium[J]. IEEE J. Sel. Areas Commun., 2017.
- [39] G. Yang, S. He, Z. Shi, J. Chen. Promoting cooperation by the social incentive mechanism in mobile crowdsensing[J]. IEEE Commun. Mag., 2017. 55(3):86–92.
- [40] Z. Zhang, S. He, J. Chen, J. Zhang. REAP: An efficient incentive mechanism for reconciling aggregation accuracy and individual privacy in crowdsensing[J]. IEEE Transactions on Information Forensics and Security, 2018. 13(12):2995–3007.
- [41] R. Agrawal, R. Srikant. Privacy-preserving data mining[C]//Proceedings of ACM SIGMOD. 2000.
- [42] A. Beresford, F. Stajano. Mix zones: user privacy in location-aware services[C]//Proceedings of IEEE PerSec. 2004.
- [43] X. Gong, X. Chen, K. Xing, D. H. Shin, M. Zhang, J. Zhang. From social group utility maximization to personalized location privacy in mobile networks[J]. IEEE/ACM Transactions on Networking, June 2017. 25(3):1703–1716.
- [44] M. Shin, C. Cornelius, D. Peebles, A. Kapadia, D. Kotz, N. Triandopoulos. AnonySense: A system for anonymous opportunistic sensing[J]. Journal of Pervasive and Mobile Computing, 2010. 7:16–30.
- [45] G. Ghinita, P. Kalnis, A. Khoshgozaran, C. Shahabi, K. Tan. Private queries in location based services: Anonymizers are not necessary[C]//Proceedings of ACM SIGMOD. 2008.
- [46] A. Khoshgozaran, C. Shahabi. Blind evaluation of nearest neighbor queries using space transformation to preserve location privacy[C]//Proceedings of SSTD. 2007.
- [47] C. Dwork. Differential privacy[C]//Proceedings of ICALP. 2006.
- [48] T. Jiang, H. J. Wang, Y. Hu. Preserving location privacy in wireless LANs[C]//Proceedings of ACM MobiSys. 2007:246–257.

- [49] R. El-Badry, A. Sultan, M. Youssef. HyberLoc: Providing physical layer location privacy in hybrid sensor networks[C]//Proceedings of IEEE ICC. 2010.
- [50] T. Wang, Y. Yang. Location privacy protection from RSS localization system using antenna pattern synthesis[C]//Proceedings of IEEE INFOCOM. April 2011:2408–2416.
- [51] Z. Gao, H. Zhu, Y. Liu, M. Li, Z. Cao. Location privacy in database-driven cognitive radio networks: Attacks and countermeasures[C]//Proceedings of IEEE INFOCOM. April 2013:2751–2759.
- [52] T. Li, N. B. Mandayam. When users interfere with protocols: Prospect theory in wireless networks using random access and data pricing as an example[J]. IEEE Transactions on Wireless Communications, 2014. 13(4):1888–1907.
- [53] J. Yu, M. H. Cheung, J. Huang, H. V. Poor. Mobile data trading: A behavioral economics perspective[C]//Proc. 13th WiOpt. May 2015:363–370.
- [54] X. Sheng, J. Tang, X. Xiao, G. Xue. Sensing as a service: Challenges, solutions and future directions[J]. IEEE Sensors J., 2013. 13(10):3733–3741.
- [55] Z. Feng, Y. Zhu, Q. Zhang, L. M. Ni, A. V. Vasilakos. TRAC: Truthful auction for location-aware collaborative sensing in mobile crowdsourcing[C]//Proceedings of IEEE INFOCOM’14. 2014:1231–1239.
- [56] D. Zhao, X. Li, H. Ma. How to crowdsource tasks truthfully without sacrificing utility: Online incentive mechanisms with budget constraint[C]//Proceedings of IEEE INFOCOM’14. 2014:1213–1221.
- [57] Y. Wen, J. Shi, Q. Zhang, X. Tian, Z. Huang, H. Yu, Y. Cheng, X. Shen. Quality-driven auction-based incentive mechanism for mobile crowd sensing[J]. IEEE Trans. Veh. Technol., 2015. 64(9):4203–4214.
- [58] Q. Zhang, Y. Wen, X. Tian, X. Gan, X. Wang. Incentivize crowd labeling under budget constraint[C]//Proceedings of IEEE INFOCOM’15. 2015:2812–2820.
- [59] X. Zhang, G. Xue, R. Yu, D. Yang, J. Tang. Truthful incentive mechanisms for crowdsourcing[C]//Proceedings of IEEE INFOCOM’15. 2015:2830–2838.
- [60] H. Jin, L. Su, D. Chen, K. Nahrstedt, J. Xu. Quality of information aware incentive mechanisms for mobile crowd sensing systems[C]//Proceedings of ACM MobiHoc’15. 2015:167–176.
- [61] L. Duan, K. Kubo, T. Sugiyama, J. Huang, T. Hasegawa, J. Walrand. Incentive mechanisms for smartphone collaboration in data acquisition and distributed computing[C]//Proceedings of IEEE INFOCOM’12. 2012:1701–1709.
- [62] S. He, D. Shin, J. Zhang, J. Chen. Toward optimal allocation of location dependent tasks in crowdsensing[C]//Proceedings of IEEE INFOCOM’14. 2014.
- [63] D. Peng, F. Wu, G. Chen. Pay as how well you do: A quality based incentive mechanism for crowdsensing[C]//Proceedings of ACM MobiHoc’15. 2015:177–186.
- [64] M. Cheung, R. Southwell, F. Hou, J. Huang. Distributed time-sensitive task selection in mobile crowdsensing[C]//Proc. ACM MobiHoc’15. 2015:157–166.

- [65] A. Archer, Éva Tardos. Frugal path mechanisms[J]. ACM Trans. Algorithms, February 2007. 3(1).
- [66] H. D. Jason, K. R. Anna. Profit Maximization in Mechanism Design[M]//Noam Nisan, Tim Roughgarden, Eva Tardos, Vijay V. Vazirani. Algorithmic Game Theory. Cambridge University Press, 2007:331–362.
- [67] P. R. Milgrom. Putting auction theory to work[M]. Cambridge University Press, 2004.
- [68] Cynthia Dwork. Differential privacy. //Automata, Languages and Programming, volume 4052 of *Lecture Notes in Computer Science*. Springer Berlin Heidelberg, 2006. 1–12.
- [69] L. Duan, T. Kubo, K. Sugiyama, J. Huang, T. Hasegawa, J. C. Walrand. Motivating smartphone collaboration in data acquisition and distributed computing[J]. IEEE Trans. Mob. Comput., 2014. 13(10):2320–2333.
- [70] Q. Li, Y. Li, J. Gao, B. Zhao, W. Fan, J. Han. Resolving conflicts in heterogeneous data by truth discovery and source reliability estimation[C]//Proceedings of ACM SIGMOD’14. 2014:1187–1198.
- [71] C. Meng, W. Jiang, Y. Li, J. Gao, L. Su, H. Ding, Y. Cheng. Truth discovery on crowd sensing of correlated entities[C]//Proceedings of ACM SenSys’15. 2015:169–182.
- [72] S. Kotz, T. Kozubowski, K. Podgorski. The Laplace distribution and generalizations: a revisit with applications to communications, economics, engineering, and finance[M]. Springer Science & Business Media, 2012.
- [73] X. Wang, W. Cheng, P. Mohapatra, T. Abdelzaher. Enabling reputation and trust in privacy-preserving mobile sensing[J]. IEEE Transactions on Mobile Computing, 2014. 13(12):2777–2790.
- [74] ILOG(IBM). Introducing ibm ilog cplex optimization studio v12.5.1[J].
- [75] N. Megiddo. On the complexity of linear programming[M]. IBM Thomas J. Watson Research Division, 1986.
- [76] FCC. Third memorandum opinion and order[C]. April 5, 2012.
- [77] R. Murty, R. Chandra, T. Moscibroda, P. Bahl. Senseless: A database-driven white spaces network[C]//IEEE Symposia on New Frontiers in Dynamic Spectrum Access Networks (DySpan). 2011.
- [78] M. Wang, Z. Yan. Privacy-preserving authentication and key agreement protocols for D2D group communications[J]. IEEE Transactions on Industrial Informatics, Aug 2018. 14(8).
- [79] C. Yin, J. Xi, R. Sun, J. Wang. Location privacy protection based on differential privacy strategy for big data in industrial internet of things[J]. IEEE Transactions on Industrial Informatics, Aug 2018. 14(8).
- [80] J. Lategahn, M. Muller, C. Rohrig. TDoA and RSS based Extended Kalman Filter for indoor person localization[C]//Proc. IEEE 78th Vehicular Technology Conference (VTC Fall). Sept 2013:1–5.
- [81] S. Gezici. A survey on wireless position estimation[J]. Wirel. Pers. Commun., February 2008. 44(3):263–282.
- [82] S. Oh, T. Vu, M. Gruteser, S. Banerjee. Phantom: Physical layer cooperation for location privacy protection[C]//Proceedings of IEEE INFOCOM. 2012:3061–3065.

- [83] T. M. Chiewe, C. F. Mbuya, G. P. Hancke. Using cognitive radio for interference-resistant industrial wireless sensor networks: An overview[J]. IEEE Transactions on Industrial Informatics, Dec 2015. 11(6).
- [84] P. K. Sahoo, S. Mohapatra, J. Sheu. Dynamic spectrum allocation algorithms for industrial cognitive radio networks[J]. IEEE Transactions on Industrial Informatics, July 2018. 14(7).
- [85] X. Chen, X. Gong, L. Yang, J. Zhang. Exploiting social tie structure for cooperative wireless networking: A social group utility maximization framework[J]. IEEE/ACM Transactions on Networking, December 2016. 24(6):3593–3606.
- [86] S. Lasaulce, H. Tembine. Game Theory and Learning for Wireless Networks: Fundamentals and Applications[M]. Academic Press, 2011.
- [87] S. Hart, A. Mas-colell. A reinforcement procedure leading to correlated equilibrium[J]. In: Debreu, G., Neuefeind, W., Trockel, W. (Eds.), Economic:181–200.
- [88] Y. Shu, Y. Huang, J. Zhang, P. CouÃ, P. Cheng, J. Chen, K. G. Shin. Gradient-based fingerprinting for indoor localization and tracking[J]. IEEE Transactions on Industrial Electronics, 2016. 63(4):2424–2433.
- [89] M. R. Gholami, R. M. Vaghefi, E. G. Ström. RSS-based sensor localization in the presence of unknown channel parameters[J]. IEEE Transactions on Signal Processing, Aug 2013. 61(15):3752–3759.
- [90] S. Hart, A. Mas-colell. A simple adaptive procedure leading to correlated equilibrium[J]. Econometrica, 2000:1127–1150.
- [91] H. Kushner, G. Yin. Stochastic Approximation and Recursive Algorithms and Applications[M]. Springer, 2003.
- [92] Vivek S. Borkar. Stochastic approximation with two time scales[J]. Systems & Control Letters, 1997. 29(5):291 – 294.
- [93] M. Zhang, L. Yang, D.-H. Shin, X. Gong, J. Zhang. Privacy-preserving database assisted spectrum access: A socially-aware distributed learning approach[C]//Proceedings of IEEE GLOBECOM. 2015:1–6.
- [94] Digital in 2017: Global Overview. <https://wearesocial.com/special-reports/digital-in-2017-global-overview>.
- [95] J. Walrand. Economic models of communication networks[J]. Performance Modeling and Engineering, 2008:57–89.
- [96] L. Huang, M. J. Neely. The optimality of two prices: Maximizing revenue in a stochastic communication system[J]. IEEE/ACM Transaction on Networking, April 2010. 18(2):406–419.
- [97] H. Yu, L. Gao, Z. Li, X. Wang, E. Hossain. Pricing for uplink power control in cognitive radio networks[J]. IEEE Transactions on Vehicular Technology, May 2010. 59(4):1769–1778.
- [98] Q. Cao, H. V. Zhao, Y. Jing. Power allocation and pricing in multiuser relay networks using Stackelberg and bargaining games[J]. IEEE Transactions on Vehicular Technology, Sept 2012. 61(7):3177–3190.
- [99] X. Duan, C. Zhao, S. He, P. Cheng, J. Zhang. Distributed algorithms to compute Walrasian equilibrium in

- mobile crowdsensing[J]. IEEE Transactions on Industrial Electronics, 2017. 64(5):4048–4057.
- [100] J. D. Hartline, V. S. Mirrokni, M. Sundararajan. Optimal marketing strategies over social networks[C]//Proc. 17th WWW. 2008.
- [101] O. Candogan, K. Bimpikis, A. Ozdaglar. Optimal pricing in networks with externalities[J]. INFORMS Operation Research, 2012. 60(4):883–905.
- [102] B. T. Swapna, A. Eryilmaz, N. B. Shroff. Dynamic pricing strategies for social networks in the presence of externalities[C]//Information Theory and Applications Workshop, San Diego, CA, USA, February 5-10, 2012. 2012.
- [103] X. Gong, L. Duan, X. Chen, J. Zhang. When social network effect meets congestion effect in wireless networks: Data usage equilibrium and optimal pricing[J]. IEEE Journal on Selected Areas in Communications, 2017. 35(2):449–462.
- [104] Google introduces wireless service called Project Fi. <http://goo.gl/aLYgrY>.
- [105] J. V. Neumann, O. Morgenstern. Theory of games and economic behavior[M]. Princeton University Press, 1953.
- [106] C. F. Camerer. Behavioral Game Theory: Experiments in Strategic Interaction[M]. Princeton University Press, 2011.
- [107] K. G. Murty. Linear Complementarity, Linear and Nonlinear Programming[M]. Heldermann Verlag, 1988.
- [108] R. Horn, C. Johnson. Matrix Analysis[M]. Cambridge University Press, 1985.
- [109] J. B. Rosen. Existence and uniqueness of equilibrium points for concave n -person games[J]. Econometrica, 1965. 33:520–534.
- [110] M. Zhang, L. Yang, X. Gong, J. Zhang. Impact of network effect and congestion effect on price competition among wireless service providers[C]//Proc. 50th CISS. 2016.
- [111] D. Prelec, G. Loewenstein. Decision making over time and under uncertainty: A common approach[J]. Management Science, 1991. 37(7):770–786.
- [112] D. Fudenberg, J. Tirole. Game Theory[M]. MIT Press, 1991.
- [113] J. Hofbauer, W. H. Sandholm. On the global convergence of stochastic fictitious play[J]. Econometrica, 2002. 70.
- [114] M. Benaïm, J. Hofbauer, S. Sorin. Stochastic approximations and differential inclusions, part II: Applications[J]. Mathematics of Operations Research, 2006. 31(4):673–695.
- [115] S. Perkins, D. S. Leslie. Asynchronous stochastic approximation with differential inclusions[J]. Stochastic Systems, 2012. 2(2):409–446.

攻读博士学位期间主要研究成果及参与的科研项目

一、完成的学术论文：

发表/录用的期刊论文

1. **First author et al.** Wireless Service Pricing Competition Under Network Effect, Congestion Effect, and Bounded Rationality, **IEEE Transactions on Vehicular Technology (TVT)**, 67(8): 7497-7507, 2018.
2. **First author et al.** Dynamic Pricing for Privacy-preserving Mobile Crowdsensing: A Reinforcement Learning Approach, **IEEE Network Magazine**, 33(2): 160-165, Mar./Apr., 2019.
3. **First author et al.** Socially-Aware Database Assisted Spectrum Access: Location Privacy, Distributed Learning and Spectrum Sharing, **IEEE Transactions on Industrial Electronics (TIE)**, accepted in August 2019.
4. **First author et al.** VANET-Assisted Interference Mitigation for Millimeter-Wave Automotive Radar Sensors, **IEEE Network Magazine**, accepted in October 2019.

发表/录用的会议论文

1. **Second author et al.** Crowd-Empowered Privacy-Preserving Data Aggregation for Mobile Crowdsensing, **ACM MobiHoc**, 2018.

在投期刊论文

1. **First author et al.** Privacy-Preserving Data Aggregation for Mobile Crowdsensing with Externality: An Auction Approach, submitted to **IEEE Transactions on Networking (TON)**
2. **Third author et al.** LEPA: Incentivizing Long-term Privacy-perserving Data Aggregation in Crowdsensing, submitted to **IEEE Transactions on Networking (TON)**

二、参与的科研项目：

1. 国家自然科学基金项目:无线传感器网络分布式安全时钟同步算法研究(No.61503332)